

Chapitre 14

Apprentissage automatique et prédiction

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse quantitative


1 Exercices du chapitre

Correction — Exercice 1

(a) $z = -3 + 0,05 \times 40 - 0,8 \times 1 = -3 + 2 - 0,8 = -1,8$. $\Pr(Y = 1) = \frac{1}{1 + e^{1,8}} \approx 0,1419$, soit environ 14,2 %.

(b) $z = -3 + 0,05 \times 80 - 0,8 \times 0 = -3 + 4 = 1$. $\Pr(Y = 1) = \frac{1}{1 + e^{-1}} \approx 0,7311$, soit environ 73,1 %.

(c) Oui, c'est **cohérent** : un $\hat{\beta}_2$ négatif signifie que chaque retard de paiement supplémentaire **diminue** la probabilité prédite de l'événement $Y = 1$. Si $Y = 1$ désigne le « bon » statut (remboursement), cette relation négative correspond exactement à l'intuition qu'un historique de retards dégrade la probabilité de remboursement.




Correction — Exercice 2

(a) Le naïf classe correctement tous les 9 800 transactions légitimes (et se trompe sur les 200 frauduleuses) : accuracy = $9\,800/10\,000 = 98,00\%$.

(b) Accuracy = $(150 + 9\,500)/10\,000 = 96,50\%$. Précision = $150/(150 + 300) = 150/450 \approx 33,33\%$.

Rappel = $150/(150 + 50) = 150/200 = 75,00\%$. F1 = $2 \times \frac{0,3333 \times 0,75}{0,3333 + 0,75} \approx 46,15\%$.

(c) **Non** : le modèle réel (96,50 %) a même un taux de bonnes réponses **inférieur** au naïf (98,00 %) ! C'est exactement le piège que dénonce le cours. Le rappel révèle la vraie différence : le naïf détecte 0 % des fraudes (rappel nul), le modèle réel en détecte 75 %. Sur données déséquilibrées, l'accuracy est donc trompeuse et c'est le **rappel** (avec la précision et l'AUC) qui doit guider le jugement, jamais l'accuracy seule.




Correction — Exercice 3

(a) $2,1 \times 0,7 = 1,47 \checkmark$, $-1,8 \times 0,7 = -1,26 \checkmark$, $0,3 \times 0,7 = 0,21 \checkmark$, $2,5 \times 0,7 = 1,75 \checkmark$, $-0,1 \times 0,7 = -0,07 \checkmark$: tous les coefficients sont bien rétrécis dans les **mêmes** proportions.

(b) Le premier jeu (1,47 ; -1,26 ; 0,21 ; 1,75 ; -0,07) – où **aucun** coefficient n'est annulé, tous étant simplement rétrécis – correspond à la régression **ridge**, qui pénalise la somme des **carrés** et ne met jamais un coefficient exactement à zéro. Le second jeu (1,8 ; -1,5 ; 0 ; 2,2 ; 0) – où deux coefficients sont exactement nuls – correspond au **LASSO**, dont la pénalité en valeur absolue réalise une véritable sélection de variables.

(c) Pour un modèle **lisible** avec le moins de variables actives possible, il faut choisir le **LASSO** : il élimine explicitement les variables les moins utiles (ici, les variables 3 et 5), ce que ridge ne fait jamais puisqu'il conserve toutes les variables, même avec des coefficients rétrécis proches de zéro.




2 Exercices cumulatifs (introduction au chapitre 14)

Correction — Exercice 4

(a) Coût A = $40 \times 500 + 5 \times 8\,000 = 20\,000 + 40\,000 = 60\,000$ dirhams.

(b) Coût B = $10 \times 500 + 15 \times 8\,000 = 5\,000 + 120\,000 = 125\,000$ dirhams.

(c) Le seuil A minimise le coût total ($60\,000 < 125\,000$), bien qu'il génère **plus** de faux positifs (refuser des bons emprunteurs) que le seuil B. Ce résultat illustre parfaitement l'affirmation du cours : le seuil optimal ne se déduit **pas** d'un simple comptage d'erreurs (le seuil B a pourtant moins d'erreurs totales : $10 + 15 = 25$ contre $40 + 5 = 45$ pour A), mais du **coût économique relatif** des deux types d'erreur – ici, un défaut coûte 16 fois plus cher qu'un refus, ce qui renverse complètement le choix intuitif fondé sur le nombre brut d'erreurs.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Naïf : accuracy = $49\,600 / 50\,000 = 99,20\%$.

(b) Modèle réel : accuracy = $(280 + 49\,000) / 50\,000 = 98,56\%$. Précision = $280 / (280 + 600) = 280 / 880 \approx 31,82\%$. Rappel = $280 / (280 + 120) = 280 / 400 = 70,00\%$.

(c) **Non**, le taux de bonnes réponses du modèle réel (98,56 %) est **inférieur** à celui du naïf (99,20 %) – une nouvelle illustration du piège de l'accuracy sur données déséquilibrées. Un service d'audit devrait néanmoins préférer nettement le modèle réel : il détecte 70 % des fraudes réelles (rappel), contre 0 % pour le modèle naïf qui, par construction, ne signale jamais aucune fraude et est donc **totale**ment inutile en pratique, malgré son accuracy en apparence meilleure.



Correction — Exercice 6

(a) Précision = $18/(18 + 25) = 18/43 \approx 41,86\%$. Rappel = $18/(18 + 12) = 18/30 = 60,00\%$. F1 = $2 \times \frac{0,4186 \times 0,60}{0,4186 + 0,60} \approx 49,32\%$.

(b) Le gérant privilégie un **rappel élevé**. Un faux négatif (baisse non anticipée) expose le portefeuille à une perte de marché non couverte – potentiellement sévère. Un faux positif (couverture inutile) coûte seulement le prix, généralement modeste, d’une protection non utilisée. L’asymétrie des coûts favorise donc clairement la détection maximale des vraies baisses, quitte à tolérer davantage de fausses alertes.

(c) En pratique, le gérant **abaisserait le seuil de décision** du classifieur (par exemple, déclencher une alerte dès que $\text{Pr}(\text{baisse}) > 0,3$ plutôt que $> 0,5$) : cela élargit la zone classée « positive », augmentant mécaniquement le rappel (moins de baisses manquées) au prix d’une précision plus faible (davantage de fausses alertes) – exactement l’arbitrage rappel-précision décrit par la courbe ROC du cours.

