

Chapitre 14

Apprentissage automatique et prédiction

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse quantitative

1 Exercices du chapitre

Exercice 1 — Calculer une probabilité de défaut par régression logistique

Un modèle de score de crédit estime $\Pr(Y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2)}}$ avec $\hat{\beta}_0 = -3$, $\hat{\beta}_1 = 0,05$ (X_1 = revenu en milliers de dirhams) et $\hat{\beta}_2 = -0,8$ (X_2 = nombre de paiements en retard).

- Calculer $\Pr(Y = 1 | X)$ pour un client au revenu $X_1 = 40$ et $X_2 = 1$ retard.
- Calculer $\Pr(Y = 1 | X)$ pour un client au revenu $X_1 = 80$ et $X_2 = 0$ retard.
- Le signe de $\hat{\beta}_2$ est négatif. Est-ce cohérent avec l'intuition économique du score de crédit? Justifier.

Exercice 2 — Le piège du taux de bonnes réponses

Sur $n = 10\,000$ transactions, dont 2 % sont frauduleuses, un modèle de détection produit la matrice de confusion suivante : $VP = 150$, $FN = 50$, $FP = 300$, $VN = 9\,500$.

- Calculer le taux de bonnes réponses (« accuracy ») d'un modèle naïf qui prédirait « jamais de fraude ».
- Calculer le taux de bonnes réponses, la précision, le rappel et le score F1 du modèle réel.
- Le modèle réel a-t-il un taux de bonnes réponses supérieur au modèle naïf? Que révèle pourtant la comparaison des rappels des deux modèles sur l'utilité relative de chacun?

Exercice 3 — Identifier ridge et LASSO à partir des coefficients

Une régression OLS donne les coefficients $(2,1; -1,8; 0,3; 2,5; -0,1)$ pour cinq variables. Deux régularisations donnent respectivement $(1,47; -1,26; 0,21; 1,75; -0,07)$ et $(1,8; -1,5; 0; 2,2; 0)$.

- Vérifier que le premier jeu de coefficients régularisés correspond à un rétrécissement uniforme de facteur 0,7 appliqué à chaque coefficient OLS.
- Lequel des deux jeux régularisés correspond à une régression **ridge**, et lequel à un **LASSO**? Justifier par la définition de chaque pénalité.
- Si l'objectif du projet est d'obtenir un modèle **lisible**, avec le moins de variables actives possible, laquelle des deux régularisations choisir?

2 Exercices cumulatifs (introduction au chapitre 14)

Exercice 4 — Choisir un seuil de score par coût économique (chapitre 5)

On reprend le cadre des erreurs de type I et de type II du chapitre 5, appliqué ici à un score de crédit. Refuser un bon emprunteur (faux positif du modèle de refus, coût 500 dirhams de marge perdue par cas) et accepter un mauvais emprunteur qui fera défaut (faux négatif, coût 8 000 dirhams par cas) ont des coûts très différents. Deux seuils de décision sont envisagés : seuil A donne $FP = 40$, $FN = 5$; seuil B donne $FP = 10$, $FN = 15$.

- Calculer le coût total du seuil A, $FP \times 500 + FN \times 8\,000$.
- Calculer le coût total du seuil B.
- Quel seuil minimise le coût total? Ce résultat illustre-t-il bien l'affirmation du cours selon laquelle « le seuil est une décision économique », et non un choix purement statistique?

3 Applications en sciences économiques

Exercice 5 — Détection de fraude à l'assurance sur données très déséquilibrées

Sur $n = 50\,000$ polices, $0,8\%$ présentent une fraude avérée. Un modèle produit la matrice de confusion $VP = 280$, $FN = 120$, $FP = 600$, $VN = 49\,000$.

- (a) Calculer le taux de bonnes réponses d'un modèle naïf « jamais de fraude ».
- (b) Calculer le taux de bonnes réponses, la précision et le rappel du modèle réel.
- (c) Le taux de bonnes réponses du modèle réel est-il supérieur à celui du modèle naïf? Expliquer pourquoi un service d'audit devrait néanmoins préférer le modèle réel, malgré ce chiffre en apparence défavorable.

Exercice 6 — Un classifieur de retournement de marché

Un modèle tente de prédire, chaque mois, si le marché va connaître une baisse significative le mois suivant. Sur 200 mois testés, la matrice de confusion est $VP = 18$, $FN = 12$, $FP = 25$, $VN = 145$.

- (a) Calculer la précision, le rappel et le score F1 du modèle.
- (b) Un gérant qui utilise ce signal pour réduire son exposition avant chaque alerte préfère-t-il un rappel élevé ou une précision élevée? Justifier par le coût respectif d'un faux négatif (baisse non anticipée) et d'un faux positif (couverture inutile).
- (c) Comment le gérant pourrait-il, en pratique, faire pencher le modèle vers davantage de rappel au prix d'un peu de précision?