

Chapitre 8

Les diagnostics de régression

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Analyse quantitative

1 Exercices du chapitre


Correction — Exercice 1

- (a) $VIF_1 = 1/(1 - 0,50) = 1/0,50 = 2,0$. $VIF_2 = 1/(1 - 0,92) = 1/0,08 = 12,5$.
- (b) $VIF_2 = 12,5 > 10$: c'est X_2 qui pose un problème de multicolinéarité préoccupant ; $VIF_1 = 2,0$ reste largement sous le seuil.
- (c) La multicolinéarité n'affecte pas la valeur **ponctuelle** des coefficients (ils restent, en espérance, corrects), mais gonfle leur **variance**, donc leur erreur type – ce qui les rend imprécis et rend les tests t peu puissants, sans pour autant biaiser l'estimation elle-même.




Correction — Exercice 2

- (a) $AIC_A = 60 \ln(200/60) + 2 \times 3 = 60 \ln(3,333) + 6 = 60 \times 1,2040 + 6 \approx 72,24 + 6 = 78,24$. $AIC_B = 60 \ln(170/60) + 2 \times 6 = 60 \ln(2,833) + 12 = 60 \times 1,0415 + 12 \approx 62,49 + 12 = 74,49$. L'AIC préfère le modèle **B** (critère plus petit).
- (b) $BIC_A = 60 \ln(200/60) + 3 \ln(60) = 72,24 + 3 \times 4,0943 \approx 72,24 + 12,28 = 84,52$. $BIC_B = 60 \ln(170/60) + 6 \ln(60) = 62,49 + 6 \times 4,0943 \approx 62,49 + 24,57 = 87,05$. Le BIC préfère le modèle **A**.
- (c) Les deux critères se **contredisent** : l'AIC choisit le modèle le plus riche (B), le BIC le modèle le plus parcimonieux (A). Ceci illustre exactement ce qu'annonce le cours : le BIC pénalise plus lourdement chaque paramètre supplémentaire (terme $\ln n \approx 4,09$ contre 2 pour l'AIC dès que $n > 7$), et privilégie donc des modèles plus simples – préférable si l'objectif est l'interprétation plutôt que le seul ajustement.



Correction — Exercice 3

- (a) Ce contraste – R^2 élevé et test de Fisher très significatif, mais aucun coefficient individuellement significatif – est **exactement** le « signal caractéristique » de la **multicolinéarité** identifié par le cours, et non une erreur de spécification.
- (b) Le **VIF** (facteur d'inflation de la variance) de chaque variable permettrait de confirmer ce diagnostic : des VIF élevés (typiquement > 10) sur plusieurs variables corroboreraient l'hypothèse de multicolinéarité.
- (c) Non. Le cours est explicite : « si l'objectif est la prévision et non l'interprétation des coefficients, la multicolinéarité n'est pas gênante » – le modèle dans son ensemble (via son R^2 élevé) prévoit bien Y , même si l'on ne peut pas isoler la contribution propre de chaque variable corrélée.




2 Exercices cumulatifs (introduction au chapitre 8)

Correction — Exercice 4

(a) Modèle du chapitre 7 ($k = 3$) : $AIC = 50 \ln(150/50) + 2 \times 4 = 50 \ln(3) + 8 = 50 \times 1,0986 + 8 \approx 54,93 + 8 = 62,93$. Modèle réduit ($k = 1$) : $AIC = 50 \ln(250/50) + 2 \times 2 = 50 \ln(5) + 4 = 50 \times 1,6094 + 4 \approx 80,47 + 4 = 84,47$.

(b) Modèle du chapitre 7 : $BIC = 50 \ln(3) + 4 \ln(50) = 54,93 + 4 \times 3,9120 \approx 54,93 + 15,65 = 70,58$. Modèle réduit : $BIC = 50 \ln(5) + 2 \ln(50) = 80,47 + 2 \times 3,9120 \approx 80,47 + 7,82 = 88,30$.

(c) Les deux critères s'accordent **sans ambiguïté** : AIC et BIC désignent tous deux le modèle du chapitre 7 ($62,93 < 84,47$ et $70,58 < 88,30$). C'est parfaitement cohérent avec le chapitre 7, où ce même modèle affichait déjà un R^2 ajusté de 0,8003, nettement supérieur à ce qu'obtiendrait un modèle à une seule variable avec un SCR bien plus élevé – ici, contrairement à l'exercice 2, l'ajout de variables n'est pas gratuit : il améliore substantiellement l'ajustement (SCR divisé par 1,67), ce qui justifie amplement le coût en degrés de liberté.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $t_{\text{naïf}} = 0,045/0,013 \approx 3,46$. $t_{\text{robuste}} = 0,045/0,028 \approx 1,61$.

(b) **Non** : le test naïf rejette $H_0 : \beta = 0$ ($|t| = 3,46 > 2$), tandis que le test robuste ne rejette pas ($|t| = 1,61 < 2$). Ignorer l'hétéroscédasticité aurait conduit à une conclusion de significativité **erronée**.

(c) La volatilité des rendements financiers varie fortement dans le temps – alternance de périodes calmes et de périodes agitées, phénomène que le cours nomme **agrégation de volatilité** – ce qui viole mécaniquement l'hypothèse d'homoscédasticité sur pratiquement toute donnée financière. C'est précisément ce que les modèles GARCH, évoqués dans le cours, cherchent à modéliser explicitement.



Correction — Exercice 6

(a) $k = 1 : 8,0 + 0,5 = 8,5$. $k = 3 : 3,0 + 1,5 = 4,5$. $k = 6 : 0,8 + 4,5 = 5,3$. $k = 10 : 0,2 + 9,0 = 9,2$.

(b) Le modèle $k = 3$ minimise l'erreur totale (4,5), inférieure à tous les autres.

(c) Le biais² **décroît** continûment avec k ($8,0 \rightarrow 3,0 \rightarrow 0,8 \rightarrow 0,2$) : un modèle plus riche capte mieux la structure réelle. La variance, elle, **croît** continûment ($0,5 \rightarrow 1,5 \rightarrow 4,5 \rightarrow 9,0$) : un modèle plus riche devient plus instable d'un échantillon à l'autre. C'est exactement l'arbitrage **biais-variance** du cours : ni le modèle le plus simple ($k = 1$, sous-ajustement, biais dominant) ni le plus riche ($k = 10$, sur-ajustement, variance dominante) n'est optimal ; l'équilibre se situe à un niveau de complexité intermédiaire.

