

Analyse quantitative

Chapitre 15 : Apprentissage automatique et prédiction



Avant de commencer

Régression et classification

La régularisation

Les méthodes non paramétriques

Évaluer un classifieur

Synthèse

Avant de commencer

Pourquoi ce chapitre ?

Dernier chapitre du cours : il passe des principes de l'apprentissage automatique aux **méthodes de prédiction** proprement dites. Régression logistique, régularisation, arbres et forêts, plus proches voisins, séparateurs à vaste marge, réseaux de neurones — et surtout, comment **évaluer** honnêtement un modèle de classification.

Régression et classification

De la régression linéaire à la régression logistique

Pourquoi la régression linéaire ne suffit pas

Pour prédire une variable **binaire** — défaut ou non —, la régression linéaire produit des valeurs hors de $[0, 1]$, ininterprétables comme probabilités, et suppose une variance d'erreur constante que la nature binaire de la cible interdit.

La régression logistique

$$\Pr(Y = 1 \mid X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \dots + \beta_k X_k)}}$$

La fonction logistique contraint la sortie dans $[0, 1]$. L'estimation se fait par **maximum de vraisemblance**, et les coefficients s'interprètent en termes de **log-cotes** : β_j est la variation du logarithme du rapport de cotes pour une unité de X_j .

L'outil de référence du score de crédit

La régression logistique reste largement dominante en notation de crédit, non par performance brute — d'autres méthodes font mieux — mais parce qu'elle est **interprétable** et **auditable**. Un régulateur ou un client peut se voir expliquer la décision, ce qui n'est pas le cas d'un réseau de neurones.

Deux méthodes

L'encodage **one-hot** crée une variable indicatrice par modalité — approprié aux catégories **non ordonnées** comme le secteur d'activité — au prix d'une forte augmentation du nombre de variables. L'encodage **ordinal** attribue des entiers ordonnés, réservé aux catégories qui possèdent un ordre naturel, comme une notation de crédit.

L'erreur à éviter

Appliquer un encodage ordinal à des catégories non ordonnées introduit une **relation d'ordre fictive** : l'algorithme conclura que le secteur 3 est « plus grand » que le secteur 1, ce qui n'a aucun sens et fausse le modèle.

La régularisation

Contraindre pour mieux généraliser

Le principe

La **régularisation** ajoute à la fonction à minimiser une pénalité sur la taille des coefficients. On accepte un peu de biais en échange d'une forte réduction de la variance — application directe de l'arbitrage du chapitre 9 — pour améliorer la performance **hors échantillon**.

Ridge et LASSO

La **régression ridge** pénalise la somme des **carrés** des coefficients : elle les rétrécit tous vers zéro sans jamais les annuler, ce qui la rend particulièrement efficace contre la **multicolinéarité**. Le **LASSO** pénalise la somme des **valeurs absolues** : il annule exactement certains coefficients et réalise donc une **sélection de variables** automatique.

Lequel choisir

Ridge convient lorsque de nombreuses variables contribuent modestement et sont corrélées. LASSO convient lorsqu'on pense que peu de variables comptent vraiment et qu'on cherche un modèle **parcimonieux** et lisible. L'intensité de la pénalité est un hyperparamètre, réglé sur l'échantillon de **validation**, jamais sur celui de test.

Les méthodes non paramétriques

K plus proches voisins

Pour classer une nouvelle observation, on identifie les K observations les plus proches dans l'échantillon d'entraînement et on retient la classe majoritaire. Aucun paramètre n'est estimé : le modèle **est** l'ensemble des données. La méthode exige une remise à l'échelle préalable et se dégrade fortement en grande dimension.

Séparateur à vaste marge

Le **SVM** cherche l'hyperplan qui sépare les classes en **maximisant la marge**, c'est-à-dire la distance aux points les plus proches de chaque classe. L'astuce du noyau permet de traiter des frontières non linéaires en projetant implicitement les données dans un espace de plus grande dimension.

Arbres et ensembles

L'arbre de décision

Un **arbre** partitionne récursivement les données : à chaque nœud, il choisit la variable et le seuil qui séparent le mieux les classes, selon un critère d'impureté. Chaque feuille porte une prédiction, et le chemin de la racine à la feuille se lit comme une suite de règles — d'où une **interprétabilité** immédiate.

Sa faiblesse

Un arbre profond sur-ajuste massivement : il peut mémoriser l'échantillon entier. Il est aussi très **instable** — quelques observations modifiées changent toute la structure. On le limite donc par élagage ou profondeur maximale.

Les méthodes d'ensemble

Combiner de nombreux modèles faibles produit un prédicteur robuste. Le **bagging** entraîne des modèles sur des rééchantillons bootstrap et moyenne leurs prédictions; la **forêt aléatoire** y ajoute un tirage aléatoire des variables à chaque nœud, ce qui décorrèle les arbres. Le **boosting** procède séquentiellement, chaque modèle corrigeant les erreurs du précédent.

Pourquoi cela fonctionne

Moyenner des modèles instables mais peu biaisés réduit fortement la **variance** sans accroître le biais.

Architecture

Un **réseau de neurones** enchaîne des couches d'unités. Chaque unité calcule une combinaison linéaire pondérée de ses entrées, puis lui applique une **fonction d'activation** non linéaire. L'empilement de couches permet de représenter des relations arbitrairement complexes.

Détermination des poids

Les poids sont obtenus en minimisant une fonction de perte par **descente de gradient**, les gradients étant calculés couche par couche depuis la sortie — c'est la **rétropropagation**. L'entraînement exige beaucoup de données et de puissance de calcul.

Puissance contre transparence

Un réseau de neurones surpasse souvent la régression logistique en pouvoir prédictif, mais reste une **boîte noire**. En finance réglementée, cette opacité est un obstacle sérieux : elle constitue une forme de **risque de modèle** difficile à contrôler, et elle se heurte à l'obligation d'expliquer une décision de crédit.

Évaluer un classifieur

La matrice de confusion

Quatre cases

La **matrice de confusion** croise classe prédite et classe réelle : vrais positifs, faux positifs, vrais négatifs, faux négatifs. Tous les indicateurs de performance en dérivent.

Les indicateurs

La **précision** est la part de vrais positifs parmi les cas prédits positifs. Le **rappel** (ou sensibilité) est la part de positifs réels correctement détectés. Le **score F1** en est la moyenne harmonique. La courbe **ROC** et l'aire sous cette courbe (**AUC**) résument la performance sur l'ensemble des seuils de décision.

Pourquoi le taux de bonnes réponses trompe

Si 1 % des transactions sont frauduleuses, un modèle qui prédit « jamais de fraude » atteint **99 % de justesse** tout en étant parfaitement inutile. Sur données déséquilibrées — le cas général en risque de crédit et en détection de fraude —, seuls le rappel, la précision et l'AUC ont un sens.

Le seuil est une décision économique

Déplacer le seuil de classification échange du rappel contre de la précision. Le point optimal ne se déduit pas des données : il dépend du **coût relatif** des deux erreurs. Refuser un bon emprunteur coûte une marge ; en accepter un mauvais coûte un capital. C'est l'erreur de type I et de type II du chapitre 6,

Synthèse

Synthèse du chapitre

La **régression logistique** contraint la prédiction dans $[0, 1]$ et reste la référence en score de crédit pour son **interprétabilité**. Les variables catégorielles s'encodent en **one-hot** si elles sont non ordonnées, en **ordinal** seulement si un ordre existe. La **régularisation** échange un peu de biais contre beaucoup de variance : **ridge** rétrécit les coefficients et traite la multicolinéarité, **LASSO** en annule certains et sélectionne les variables. Parmi les méthodes non paramétriques, les **KNN** et les **SVM** offrent des frontières souples, les **arbres** une lecture en règles mais une forte instabilité, que corrigent les **forêts aléatoires** et le **boosting** au prix de l'interprétabilité. Les **réseaux de neurones** maximisent le pouvoir prédictif mais restent opaques — un risque de modèle réel en environnement réglementé. Enfin, un classifieur s'évalue par la **matrice de confusion** : sur données déséquilibrées, le taux de bonnes réponses est trompeur, et le choix du seuil est une décision **économique** fondée sur le coût relatif des deux types d'erreur.