

Analyse quantitative

Chapitre 7 : La régression linéaire



Avant de commencer

Le modèle linéaire simple

Les hypothèses des MCO

Qualité de l'ajustement

Synthèse

Avant de commencer

Pourquoi ce chapitre ?

Le chapitre 4 a défini l'**espérance conditionnelle** $E[Y \mid X]$ sans dire comment l'estimer. La **régression linéaire** est l'outil qui la modélise à partir de données. C'est le modèle le plus utilisé de toute la finance quantitative : le bêta du MEDAF, les modèles factoriels, les mesures de sensibilité en sont autant d'applications directes.

Le modèle linéaire simple

Le modèle

$$Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$$

Y est la variable **expliquée**, X la variable **explicative**, β_0 la constante, β_1 la **pente** — l'effet d'une unité de X sur Y — et ε le terme d'erreur, qui regroupe tout ce que X n'explique pas.

Linéaire en quoi?

La linéarité porte sur les **paramètres**, non sur les variables. On peut donc régresser Y sur X^2 , sur $\ln X$ ou sur des produits de variables : le modèle reste linéaire et estimable par les mêmes méthodes. En revanche, un modèle où les paramètres entrent de façon non linéaire — comme $Y = \beta_0 X^{\beta_1} + \varepsilon$ — sort de ce cadre.

Le principe des MCO

Les **moindres carrés ordinaires** choisissent les paramètres qui minimisent la somme des carrés des résidus :

$$\min_{\beta_0, \beta_1} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i)^2.$$

La solution s'écrit

$$\hat{\beta}_1 = \frac{\widehat{\text{Cov}}(X, Y)}{\hat{\sigma}_X^2}, \quad \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}.$$

Lecture de la pente

La pente est une **covariance normalisée par la variance de X** . Elle est donc l'exact analogue empirique du **bêta** du MEDAF, $\beta_i = \text{Cov}(R_i, R_M) / \sigma_M^2$: régresser le rendement d'un actif sur celui du marché estime directement son bêta.

Les hypothèses des MCO

Les hypothèses clés

Linéarité du modèle en ses paramètres. **Espérance nulle des erreurs** conditionnellement à X : $E[\varepsilon | X] = 0$ – l'hypothèse la plus importante. **Homoscédasticité** : variance des erreurs constante. **Absence d'autocorrélation** des erreurs. **Variabilité** de X , sans quoi la pente n'est pas identifiable.

Pourquoi $E[\varepsilon | X] = 0$ est décisive

Si un facteur omis influence à la fois Y et X , il se loge dans l'erreur et s'y trouve corrélé à X . La pente estimée capte alors non seulement l'effet de X mais aussi celui du facteur omis : elle est **biaisée**. C'est le problème du **biais de variable omise**, et il ne se corrige pas en augmentant la taille de l'échantillon.

Le théorème de Gauss-Markov

Sous ces hypothèses, les estimateurs MCO sont **sans biais** et **BLUE** : parmi tous les estimateurs linéaires sans biais, ils ont la variance minimale. Leur loi d'échantillonnage est asymptotiquement normale, ce qui autorise l'usage des tests du chapitre 6.

Tester un coefficient

On teste $H_0 : \beta_1 = 0$ – « X n'a aucun effet » – au moyen de

$$t = \frac{\hat{\beta}_1}{\text{erreur type}(\hat{\beta}_1)},$$

comparé à une loi de Student. Un $|t|$ supérieur à environ 2 conduit à rejeter H_0 au seuil de 5 % pour un échantillon de taille raisonnable.

Qualité de l'ajustement

Décomposition de la variance

La variation totale se décompose en variation **expliquée** et variation **résiduelle** :

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{SCT} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{SCE} + \underbrace{\sum \hat{\varepsilon}_i^2}_{SCR}, \quad R^2 = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}.$$

Le R^2 est la part de la variance de Y expliquée par le modèle.

R^2 et corrélation

Dans une régression à **une seule** variable explicative, le R^2 est exactement le carré du coefficient de corrélation entre X et Y :

$$R^2 = \rho_{X,Y}^2.$$

Le signe de la corrélation se lit alors dans le signe de la pente estimée.

Les limites du R^2

Un R^2 élevé ne garantit ni la validité du modèle, ni un lien causal. Sur des séries temporelles tendanciellles, il approche mécaniquement 100 % sans qu'aucune relation économique n'existe — c'est le phénomène de la **régression fallacieuse**, repris au chapitre 11.

Corrélation n'est pas causalité

La régression mesure une **association conditionnelle**, pas un mécanisme causal. Attribuer un sens causal à une pente estimée exige des hypothèses supplémentaires — expérience contrôlée, variable instrumentale, discontinuité de régression — qui ne se lisent jamais dans les données seules.

Synthèse

Synthèse du chapitre

La régression linéaire modélise l'**espérance conditionnelle** $E[Y \mid X]$, la linéarité portant sur les **paramètres** et non sur les variables. Les **MCO** minimisent la somme des carrés des résidus et donnent une pente $\hat{\beta}_1 = \widehat{\text{Cov}}(X, Y) / \hat{\sigma}_X^2$ – exactement le bêta du MEDAF lorsque X est le rendement de marché. Sous les hypothèses de **Gauss-Markov**, dont la plus critique est $E[\varepsilon \mid X] = 0$, ces estimateurs sont sans biais et **BLUE**. La violation de cette hypothèse par une **variable omise** produit un biais que l'accroissement de l'échantillon ne corrige pas. Le R^2 mesure la part de variance expliquée et vaut ρ^2 en régression simple, mais un R^2 élevé ne prouve ni la validité du modèle ni la causalité.