

Analyse quantitative

Chapitre 8 : La régression multiple



Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 21 août 2026

Où en sommes-nous ?


Le modèle à plusieurs variables

Tester plusieurs coefficients

Mesurer la qualité de l'ajustement

Synthèse

Où en sommes-nous?



Pourquoi ce chapitre ?

Une seule variable explicative suffit rarement. La **régression multiple** en admet plusieurs simultanément, ce qui change l'interprétation des coefficients — ils deviennent des effets *toutes choses égales par ailleurs* — et permet de traiter le biais de variable omise du chapitre 7. C'est le cadre des modèles factoriels vus dans le cours de gestion des risques.

Le modèle à plusieurs variables

Le modèle

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \dots + \beta_k X_{ki} + \varepsilon_i$$

L'estimation se fait toujours par minimisation de la somme des carrés des résidus, et les hypothèses du chapitre 7 se transposent directement.

L'interprétation change

β_j mesure l'effet d'une unité supplémentaire de X_j sur Y , **les autres variables explicatives étant maintenues constantes**. C'est un effet **partiel**, et non l'effet total observé dans une régression simple sur X_j seule.

Pourquoi les coefficients bougent

Ajouter une variable modifie généralement les coefficients déjà présents : chacun ne capte plus que sa contribution **propre**, une fois retirée la part partagée avec les autres. Un coefficient peut ainsi changer de signe entre régression simple et multiple — ce qui n'est pas une anomalie mais l'effet du contrôle.

Le lien avec les modèles factoriels

Régresser le rendement d'un actif sur le marché, la taille et la valorisation estime directement les

Absence de colinéarité parfaite

Aucune variable explicative ne doit être une combinaison linéaire exacte des autres. Sinon les coefficients ne sont pas identifiables : une infinité de jeux de valeurs ajusteraient les données de façon identique.

Tester plusieurs coefficients

Le test de Fisher

Pour tester simultanément plusieurs restrictions — par exemple $H_0 : \beta_1 = \beta_2 = 0$ — on utilise une statistique de **Fisher** comparant la somme des carrés des résidus du modèle contraint à celle du modèle libre. Elle suit une loi F sous H_0 .

Pourquoi un test joint n'est pas une suite de tests individuels

Deux variables fortement corrélées peuvent être individuellement non significatives — chacune, prise seule, semble superflue — tout en étant **conjointement** très significatives. Enchaîner des tests t conduirait à écarter à tort les deux; seul le test joint tranche correctement.

Régions de confiance

De même, une région de confiance jointe pour deux coefficients est une **ellipse**, et non le rectangle formé par les deux intervalles individuels. Lorsque les estimateurs sont corrélés, l'ellipse est inclinée et peut exclure des points que les intervalles séparés accepteraient.

Mesurer la qualité de l'ajustement

Le défaut du R²

Le R^2 ne peut que **croître** lorsqu'on ajoute une variable, même sans aucun pouvoir explicatif réel. Il ne peut donc pas servir à comparer des modèles de tailles différentes.

Le R² ajusté

$$\bar{R}^2 = 1 - \frac{SCR/(n - k - 1)}{SCT/(n - 1)}$$

Il pénalise l'ajout de variables par la perte de degrés de liberté et ne progresse que si la nouvelle variable apporte plus que le coût de son estimation. Il peut être **négatif** pour un modèle très mauvais.

Le vrai problème : le surajustement

Ajouter des variables améliore toujours l'ajustement **dans l'échantillon** et dégrade souvent la prévision **hors échantillon**. C'est le sur-ajustement, thème central des chapitres 9, 14 et 15. Le R^2 ajusté n'en est qu'un correctif rudimentaire.

Synthèse

Synthèse du chapitre

En régression multiple, chaque coefficient mesure un effet **partiel**, les autres variables étant maintenues constantes — d'où le déplacement fréquent des coefficients lorsqu'on enrichit le modèle, phénomène normal et non anomalie. Une hypothèse nouvelle s'ajoute : l'absence de **colinéarité parfaite**, faute de quoi les paramètres ne sont pas identifiables. Les **tests joints** de Fisher ne se réduisent pas à une suite de tests individuels : des variables corrélées peuvent être conjointement significatives tout en étant séparément non significatives. Enfin, le R^2 croît mécaniquement avec le nombre de variables; le R^2 **ajusté** corrige partiellement ce défaut, mais seule l'évaluation **hors échantillon** protège réellement du sur-ajustement.