

Analyse quantitative

Chapitre 10 : Les séries temporelles stationnaires

Jaouad Madkour

31 juillet 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous ?


Stationnarité et autocorrélation

Les processus autorégressifs

Moyennes mobiles et modèles ARMA

Synthèse

Où en sommes-nous?



Pourquoi ce chapitre ?

Jusqu'ici les observations étaient supposées **indépendantes**. Les données financières sont des **séries temporelles** : chaque valeur dépend du passé, et cette dépendance est précisément ce qu'on veut exploiter pour prévoir. Ce chapitre introduit la **stationnarité**, les fonctions d'autocorrélation, et la famille des modèles **ARMA**.

Stationnarité et autocorrélation

Trois conditions

Une série est **stationnaire en covariance** si son **espérance** est constante dans le temps, sa **variance** est constante et finie, et si la **covariance** entre deux dates ne dépend que de l'**écart** qui les sépare, non de leur position. Toute série ne satisfaisant pas ces conditions est non stationnaire.

Pourquoi cette notion est centrale

Sans stationnarité, le passé ne renseigne pas sur l'avenir : les paramètres estimés sur une période n'ont aucune raison de valoir sur une autre. La stationnarité est donc la condition qui rend l'estimation et la prévision possibles. Les **rendements** d'actifs sont raisonnablement stationnaires; les **prix** ne le sont pas — d'où le chapitre 11.

Les fonctions ACF

L'autocovariance d'ordre h est $\gamma_h = \text{Cov}(Y_t, Y_{t-h})$. L'autocorrélation la normalise :

$$\rho_h = \frac{\gamma_h}{\gamma_0}, \quad \rho_0 = 1.$$

La suite des ρ_h forme la **fonction d'autocorrélation** (ACF), qui résume la mémoire du processus.

Le bruit blanc

Un **bruit blanc** est une suite d'espérance nulle, de variance constante et d'**autocorrélations toutes nulles** au-delà de l'ordre 0. Le bruit blanc **indépendant** ajoute l'indépendance complète; le bruit blanc **gaussien** y ajoute la normalité. C'est la brique élémentaire de tous les modèles de ce chapitre, et le comportement attendu des résidus d'un bon modèle.

Tests de bruit blanc

Les statistiques Q de **Box-Pierce** et de **Ljung-Box** testent la nullité conjointe des m premières autocorrélations. Elles suivent une loi du khi-deux sous cette hypothèse. La version de Ljung-Box, mieux calibrée en échantillon fini, est celle qu'on utilise en pratique pour valider les résidus d'un modèle.

Les processus autorégressifs

Processus AR(p)

$$Y_t = \delta + \phi_1 Y_{t-1} + \dots + \phi_p Y_{t-p} + \varepsilon_t$$

La valeur courante dépend linéairement de ses propres valeurs passées. Pour un **AR(1)**, la condition de stationnarité est $|\phi_1| < 1$.

Espérance et retour à la moyenne

Un AR(1) stationnaire a pour espérance

$$E[Y_t] = \frac{\delta}{1 - \phi_1},$$

appelée **niveau de retour à la moyenne**. Après un choc, la série y revient progressivement, à la vitesse ϕ_1 : plus ϕ_1 est proche de 1, plus la mémoire est longue et le retour lent.

Le retour à la moyenne en finance

Les taux d'intérêt et la volatilité présentent un net retour à la moyenne ; les prix d'actions, pratiquement pas. Cette différence structurelle explique pourquoi on modélise la volatilité par des processus autorégressifs, mais les prix par des marches aléatoires.

Moyennes mobiles et modèles ARMA

Processus MA(q)

$$Y_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

La série est une combinaison finie de chocs présents et passés. Un MA(q) est **toujours stationnaire**, quels que soient ses paramètres, et son autocorrélation s'annule strictement au-delà de l'ordre q — c'est sa signature.

Identifier l'ordre par l'ACF

Un **MA(q)** a une ACF qui se **coupe** brutalement après q . Un **AR(p)** a une ACF qui **décroît** progressivement, mais une autocorrélation **partielle** qui se coupe après p . Comparer les deux fonctions est la méthode classique d'identification de l'ordre d'un modèle.

Processus ARMA(p,q)

$$Y_t = \delta + \sum_{i=1}^p \phi_i Y_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}$$

Il combine composantes autorégressive et moyenne mobile. Sa stationnarité ne dépend que de la partie AR. Son intérêt est la **parcimonie** : un ARMA d'ordres faibles reproduit souvent une dynamique qui exigerait un AR d'ordre très élevé.

Les équations de Yule-Walker

Elles relient les autocorrélations théoriques d'un processus AR à ses paramètres. Résolues dans l'autre sens, elles permettent d'**estimer** les ϕ_i à partir des autocorrélations empiriques — méthode classique d'estimation des modèles autorégressifs.

La démarche de modélisation

Vérifier la stationnarité, examiner ACF et autocorrélation partielle pour identifier les ordres, estimer, puis **valider les résidus** par un test de Ljung-Box. Si les résidus ne sont pas un bruit blanc, le modèle laisse échapper de la structure et doit être révisé.

Synthèse

Synthèse du chapitre

La **stationnarité en covariance** — moyenne et variance constantes, autocovariance ne dépendant que de l'écart — est la condition qui rend l'estimation et la prévision possibles. La mémoire du processus se lit dans la fonction d'**autocorrélation**, et le **bruit blanc**, sans autocorrélation, en est la brique de base ainsi que le comportement attendu de résidus corrects, vérifiable par le test de **Ljung-Box**. Un **AR(p)** exprime la série par son propre passé, stationnaire si $|\phi_1| < 1$ pour l'AR(1), avec un **niveau de retour à la moyenne** $\delta/(1 - \phi_1)$. Un **MA(q)** l'exprime par les chocs passés, est toujours stationnaire et voit son ACF se couper après q . Les modèles **ARMA** combinent les deux et offrent une représentation parcimonieuse. L'identification repose sur la lecture conjointe de l'ACF et de l'autocorrélation partielle, et la validation sur l'analyse des résidus.