

Analyse quantitative

Chapitre 13 : Simulation et bootstrap

Jaouad Madkour

21 août 2026

Faculté d'Économie et de Gestion de Tanger

Où en sommes-nous?


Simuler des variables aléatoires

La simulation de Monte Carlo

Le bootstrap

Synthèse

Où en sommes-nous?



Pourquoi ce chapitre ?

Beaucoup de quantités utiles n'admettent aucune expression analytique : espérance d'un produit dérivé complexe, distribution des pertes d'un portefeuille, loi d'un estimateur en petit échantillon. La **simulation** les approche numériquement. Le **bootstrap** poursuit le même but, mais en rééchantillonnant les données observées au lieu de postuler un modèle.

Simuler des variables aléatoires

Pseudo-aléatoire

Un ordinateur ne produit pas de hasard : il applique des fonctions **déterministes** dont les sorties sont difficiles à prévoir. Ces **générateurs de nombres pseudo-aléatoires** sont initialisés par une valeur appelée **graine** (*seed*). Une même graine régénère exactement la même suite.

Pourquoi la graine compte

Elle assure d'abord la **reproductibilité** : comparer deux modèles sur des données identiques, et refaire un calcul des mois plus tard — exigence de conformité réglementaire. Elle permet ensuite de **coordonner des calculs distribués** : quand des milliers d'instruments dépendent des mêmes facteurs, tous les nœuds de calcul doivent recevoir les **mêmes** réalisations de ces facteurs.

La transformation inverse

Pour simuler une variable de fonction de répartition F , on tire U uniforme sur $[0, 1]$ et on pose $X = F^{-1}(U)$. Ce résultat, déjà rencontré au chapitre 3, ramène la simulation de n'importe quelle loi à celle d'une uniforme.

La simulation de Monte Carlo

Les étapes

Spécifier un **processus générateur** complet; en tirer un grand nombre de réalisations indépendantes; appliquer à chacune la fonction d'intérêt g ; approcher l'espérance par la moyenne empirique

$$E[g(X)] \approx \frac{1}{B} \sum_{b=1}^B g(x_b).$$

La précision

L'erreur d'approximation décroît en $1/\sqrt{B}$: quadrupler le nombre de répliques ne divise l'erreur que par deux. La précision est donc **contrôlable** — on choisit B selon le niveau visé — mais son amélioration est **coûteuse**.

Applications

Évaluer une option au payoff complexe ou dépendant du chemin; calculer la VaR et l'*expected shortfall* d'un portefeuille non linéaire; propager des scénarios macroéconomiques dans un bilan bancaire lors d'un test de résistance; mesurer la précision d'un estimateur en petit échantillon.

Réduire l'erreur d'échantillonnage

Variables antithétiques

Pour chaque tirage u , on utilise **aussi** son symétrique $1 - u$ (ou $-\varepsilon$ pour un choc normal). Les deux réalisations étant **négativement corrélées**, leurs erreurs se compensent partiellement et la variance de la moyenne diminue, à coût de calcul quasi inchangé.

Variables de contrôle

On s'appuie sur une quantité **corrélée** à celle qui nous intéresse, mais dont la valeur exacte est **connue analytiquement**. L'écart observé entre la simulation et la valeur vraie du contrôle sert à corriger l'estimation. Exemple typique : évaluer une option exotique en contrôlant par une option vanille comparable, dont le prix Black-Scholes est connu.

Les limites de la simulation

Le résultat ne vaut **jamais mieux que le modèle postulé** : une hypothèse de normalité erronée produira des pertes extrêmes systématiquement sous-estimées, quel que soit le nombre de tirages. S'ajoutent le coût de calcul et l'opacité — un chiffre issu d'un million de tirages est difficile à contester ou à interpréter, ce qui constitue en soi un risque de modèle.

Le bootstrap

Principe

Le **bootstrap** tire de nouveaux échantillons **avec remise** directement dans les données observées, chacun de même taille que l'original. En recalculant la statistique d'intérêt sur chaque rééchantillon, on obtient une approximation de sa distribution.

L'avantage décisif

Il ne requiert **aucune spécification** d'un processus générateur. La distribution empirique des données — avec ses queues épaisses, son asymétrie, ses irrégularités — est utilisée telle quelle. Là où Monte Carlo impose un modèle, le bootstrap laisse parler les données.

Usages

Construire un intervalle de confiance pour un ratio de Sharpe, dont la loi exacte est inconnue; estimer l'incertitude d'une VaR historique; tester la significativité d'une performance de gérant sans hypothèse de normalité.

Trois situations défavorables

Il échoue quand les données sont **dépendantes** — le rééchantillonnage indépendant détruit la structure temporelle, d'où les variantes par blocs. Il échoue pour les statistiques de **queue extrême** : on ne peut rééchantillonner que des valeurs déjà observées, donc jamais un krach plus violent que le pire du passé. Il échoue enfin sur les **petits échantillons**, où la distribution empirique approche mal la vraie distribution.

Deux outils complémentaires

Monte Carlo permet d'explorer des scénarios **jamais observés**, au prix d'un modèle à assumer. Le bootstrap reste fidèle aux données observées, au prix de ne pas pouvoir en sortir. Pour le risque extrême, le bootstrap seul est structurellement insuffisant — d'où le recours conjoint à des scénarios construits.

Synthèse

Synthèse du chapitre

La simulation approche numériquement des quantités sans expression analytique. Les nombres sont **pseudo-aléatoires**, et fixer la **graine** garantit reproductibilité et cohérence des calculs distribués. **Monte Carlo** suppose un processus générateur complet, tire massivement, et voit son erreur décroître en $1/\sqrt{B}$ – décroissance qu'accélèrent les **variables antithétiques** et les **variables de contrôle**. Sa limite est structurelle : le résultat ne vaut pas mieux que le modèle postulé. Le **bootstrap** rééchantillonne avec remise les données observées, sans hypothèse de loi, mais échoue sur les données **dépendantes**, les **queues extrêmes** et les petits échantillons. Les deux méthodes sont complémentaires : Monte Carlo explore l'inobservé, le bootstrap reste fidèle à l'observé.