

Analyse quantitative

Chapitre 6 : Les tests d'hypothèses



Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 29 août 2026

Avant de commencer

Construire un test

Erreurs, taille et puissance

Mettre en œuvre le test

Les tests multiples

Synthèse

Avant de commencer

Pourquoi ce chapitre ?

Le chapitre 5 a montré comment **estimer** un paramètre. Reste à savoir si une estimation est compatible avec une affirmation donnée : la volatilité a-t-elle réellement changé ? ce gérant surperforme-t-il vraiment ? Le **test d'hypothèses** fournit le cadre formel de cette décision — et, tout aussi important, la mesure du risque de se tromper.

Construire un test

Les deux hypothèses

L'**hypothèse nulle** H_0 est l'affirmation testée, celle que l'on maintient tant que les données ne la contredisent pas franchement. L'**hypothèse alternative** H_1 décrit ce que l'on retient si H_0 est rejetée. Les deux doivent être **exclusives** et couvrir l'ensemble des possibilités.

Le statut asymétrique de H_0

La démarche n'est pas symétrique : on ne « prouve » jamais H_0 , on échoue seulement à la rejeter. Cette asymétrie est délibérée — elle place la charge de la preuve sur celui qui affirme un effet, et protège contre les découvertes hâtives.

Choisir la forme du test

Un test **bilatéral** ($H_1 : \theta \neq \theta_0$) détecte un écart dans les deux sens. Un test **unilatéral** ($H_1 : \theta > \theta_0$ ou $\theta < \theta_0$) ne s'intéresse qu'à une direction. Le choix doit être fixé **avant** de voir les données, sous peine d'invalidier le test.

Application

Pour savoir si un gérant bat son indice, seule la surperformance importe : le test est **unilatéral**. Pour vérifier si un modèle de couverture est correctement calibré, tout écart compte, dans un sens comme dans l'autre : le test est **bilatéral**.

Erreurs, taille et puissance

Les deux types d'erreur

Erreur de première et de seconde espèce

L'**erreur de type I** consiste à rejeter H_0 alors qu'elle est vraie — un faux positif. Sa probabilité est la **taille** du test, notée α , choisie par l'analyste (souvent 5 % ou 1 %). L'**erreur de type II** consiste à ne pas rejeter H_0 alors qu'elle est fausse — un faux négatif, de probabilité β .

La puissance

La **puissance** du test vaut $1 - \beta$: c'est la probabilité de détecter un effet réellement présent. Elle croît avec la taille de l'échantillon et avec l'ampleur de l'effet à détecter.

L'arbitrage inévitable

À taille d'échantillon donnée, réduire α augmente mécaniquement β : exiger davantage de preuves pour rejeter H_0 fait manquer plus d'effets réels. Le seul moyen d'améliorer les deux simultanément est d'**augmenter** n .

Quelle erreur est la plus coûteuse ?

En validation de modèle de risque, une erreur de type II — ne pas détecter qu'un modèle est défaillant — est bien plus coûteuse qu'une erreur de type I. C'est pourquoi les tests réglementaires de validation de VaR sont calibrés avec des seuils relativement permissifs, afin de préserver la puissance.

Mettre en œuvre le test

Statistique de test et région de rejet

La statistique de test

On construit une statistique dont la loi est connue **sous** H_0 . Dans le cas usuel d'un test sur une moyenne,

$$T = \frac{\hat{\theta} - \theta_0}{\text{erreur type}(\hat{\theta})},$$

qui suit approximativement une loi normale centrée réduite pour un grand échantillon — conséquence directe du théorème central limite.

Valeur critique et p-value

On rejette H_0 si la statistique dépasse une **valeur critique** fixée par α . De façon équivalente, la **p-value** est la probabilité, sous H_0 , d'observer une statistique au moins aussi extrême que celle obtenue : on rejette lorsque $p < \alpha$.

Ce que la p-value n'est pas

Elle n'est **pas** la probabilité que H_0 soit vraie. C'est une probabilité **conditionnelle à** H_0 portant sur les données. Cette confusion est l'erreur d'interprétation la plus répandue en statistique appliquée.

Deux faces d'un même objet

Un **intervalle de confiance** à $1 - \alpha$ contient toutes les valeurs de θ_0 qui **ne seraient pas rejetées** par un test bilatéral de taille α . Tester revient donc à vérifier si la valeur postulée tombe dans l'intervalle.

Pourquoi préférer l'intervalle

Le test répond par oui ou non ; l'intervalle indique en outre l'**ampleur plausible** de l'effet et la **précision** de l'estimation. Un effet peut être statistiquement significatif tout en étant économiquement négligeable — seul l'intervalle le révèle.

Les tests multiples

Quand multiplier les tests fausse tout

Le problème

Effectuer m tests indépendants au seuil de 5 % donne une probabilité d'au moins un faux positif égale à $1 - 0,95^m$. Pour $m = 20$, elle atteint déjà **64 %**; pour $m = 100$, plus de 99 %. Tester massivement garantit donc de « trouver » des effets inexistants.

Le data mining en finance

C'est précisément le risque des recherches de stratégies : en testant des centaines de règles sur les mêmes données, certaines apparaîtront significatives par pur hasard. Les performances mesurées sur l'échantillon d'estimation ne se reproduisent alors jamais en conditions réelles.

Les correctifs

La correction de **Bonferroni** divise le seuil par le nombre de tests — simple mais très conservatrice. Les approches par **taux de fausses découvertes** sont moins strictes. Le remède le plus robuste reste la **validation hors échantillon** : confirmer le résultat sur des données non utilisées pour le découvrir.

Synthèse

Synthèse du chapitre

Un test oppose une **hypothèse nulle**, maintenue par défaut, à une **alternative**, la forme unilatérale ou bilatérale devant être fixée avant l'examen des données. Deux erreurs sont possibles : le **type I** (faux positif, de probabilité α = taille) et le **type II** (faux négatif, de probabilité β , avec puissance $1 - \beta$). Les deux ne peuvent être réduites simultanément qu'en augmentant l'échantillon. On rejette H_0 lorsque la statistique dépasse la valeur critique, ou de façon équivalente lorsque la **p-value** est inférieure à α — étant entendu que la p-value n'est **pas** la probabilité que H_0 soit vraie. L'**intervalle de confiance** contient l'information du test plus l'ampleur de l'effet. Enfin, les **tests multiples** produisent mécaniquement des faux positifs : c'est le principal danger de la recherche de stratégies par exploration de données, et la validation hors échantillon en est le meilleur remède.