

Chapitre 9

L'attention et les transformeurs

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) $q \cdot k_1 = 2 \times 1 + 0 \times 0 = 2$. $q \cdot k_2 = 2 \times 0 + 0 \times 1 = 0$.
 (b) Scores mis à l'échelle : $2/\sqrt{2} \approx 1,4142$ et $0/\sqrt{2} = 0$. Poids softmax : $e^{1,4142} \approx 4,1133$, $e^0 = 1$, somme $\approx 5,1133$, donc $w_1 \approx 0,8044$ et $w_2 \approx 0,1956$.
 (c) Sortie = $0,8044 \times (4, 0) + 0,1956 \times (0, 6) = (3,2177; 0) + (0; 1,1734) = (3,2177; 1,1734)$.




Correction — Exercice 2

- (a) Sans mise à l'échelle : $e^8 \approx 2980,96$, $e^2 \approx 7,389$, somme $\approx 2988,35$. Poids $\approx 0,9975$ et $0,0025$.
 (b) Scores mis à l'échelle : $8/8 = 1$ et $2/8 = 0,25$. Poids softmax : $e^1 \approx 2,7183$, $e^{0,25} \approx 1,2840$, somme $\approx 4,0023$. Poids $\approx 0,6792$ et $0,3208$.
 (c) Sans mise à l'échelle, la distribution est **presque binaire** (0,9975 contre 0,0025) : c'est exactement le phénomène décrit par le chapitre. Avec la mise à l'échelle, la distribution reste **douce** (0,68 contre 0,32), permettant un gradient utile lors de l'entraînement.



Correction — Exercice 3

- (a) $500^2 = 250\,000$. $2\,000^2 = 4\,000\,000$. $8\,000^2 = 64\,000\,000$.
 (b) De 500 à 2 000 (facteur 4 sur L) : coût multiplié par $4\,000\,000/250\,000 = 16$. De 2 000 à 8 000 (facteur 4 sur L à nouveau) : coût multiplié par $64\,000\,000/4\,000\,000 = 16$.
 (c) Oui, parfaitement cohérent : un coût **quadratique** signifie que multiplier L par un facteur c multiplie le coût par c^2 ; ici $c = 4$ donne $c^2 = 16$ dans les deux cas, exactement ce qui est observé.




2 Exercices cumulatifs (chapitre 9, chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Scores mis à l'échelle : $1,5/3 = 0,5$; $0,5/3 \approx 0,1667$; $-1,0/3 \approx -0,3333$. Softmax : $e^{0,5} \approx 1,6487$, $e^{0,1667} \approx 1,1814$, $e^{-0,3333} \approx 0,7165$, somme $\approx 3,5466$. Probabilités $\approx$ **0,4649**; **0,3331**; **0,2020**.

(b) La probabilité maximale passe de 0,6897 (chapitre 1, sans mise à l'échelle) à **0,4649** (avec mise à l'échelle) : la distribution devient nettement **moins concentrée**, plus proche d'une répartition uniforme entre les trois scores.

(c) Une connexion résiduelle $y = F(x) + x$ (chapitre 7) offre au gradient un chemin **additif**, sans facteur multiplicatif, exactement comme l'état de cellule d'un LSTM (chapitre 8) lorsque sa porte d'oubli reste ouverte. Un bloc de transformeur empile **deux** telles connexions résiduelles (une autour de l'attention, une autour du réseau dense position par position). En empilant N blocs, le gradient dispose donc de $2N$ chemins directs à travers lesquels il peut circuler sans être multiplié par des facteurs potentiellement inférieurs à 1 – exactement le mécanisme qui, au chapitre 7, a permis l'entraînement de réseaux à plus de cent couches malgré le problème d'évanouissement identifié au chapitre 4. Le transformeur hérite ainsi, par construction, du même remède architectural que le LSTM et le ResNet, plutôt que de le redécouvrir.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $200^2 = 40\,000$. $800^2 = 640\,000$. $3\,200^2 = 10\,240\,000$.

(b) $10\,240\,000/40\,000 = 256 = 16^2$: cohérent avec un coût quadratique, une multiplication de la longueur par 16 multiplie le coût par $16^2 = 256$.

(c) Oui, ce contraste illustre exactement l'arbitrage du chapitre : le coût de l'attention croît comme le **carré** de la longueur ($\times 256$ ici), tandis qu'une architecture récurrente aurait un coût **linéaire** (multiplié par 16 seulement pour la même variation de longueur) – au prix, en contrepartie, d'un traitement séquentiel non parallélisable et d'une portée de mémoire plus limitée. Le choix entre les deux architectures dépend donc directement de la longueur de séquence visée et des ressources de calcul disponibles.

Correction — Exercice 6

(a) $15 \times 252 = 3\,780$ points environ.

(b) Rapport $= 3\,780/5\,000 = 0,756$: le gérant dispose d'un volume **inférieur** à la référence de 5 000 points déjà jugée insuffisante par le chapitre.

(c) Compte tenu de ce volume très réduit, des architectures plus simples – GARCH, ARMA, boosting sur variables construites, comme le mentionne explicitement le chapitre – resteraient vraisemblablement plus compétitives qu'un transformeur. La réponse dépend **principalement du volume de données disponible**, et non de la nature du problème (rendement ou volatilité) : le chapitre

est explicite sur ce point («la taille des données commande le choix d'architecture, davantage que la nature du problème»). Ce même volume resterait insuffisant que l'on cherche à prévoir un rendement ou une volatilité.