

Apprentissage profond

Chapitre 9 : L'attention et les transformeurs

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une attention à produit scalaire mis à l'échelle

Une requête $q = (2, 0)$ doit consulter deux positions, de clés $k_1 = (1, 0)$ et $k_2 = (0, 1)$, et de valeurs $v_1 = (4, 0)$ et $v_2 = (0, 6)$. La dimension est $d = 2$.

- (a) Calculer les scores de compatibilité $q \cdot k_1$ et $q \cdot k_2$.
- (b) Diviser ces scores par $\sqrt{d} = \sqrt{2}$, puis calculer les poids d'attention par softmax.
- (c) Calculer la sortie de l'attention, moyenne pondérée des valeurs par ces poids.

Exercice 2 — Pourquoi diviser par $\sqrt{d}$

Deux scores de compatibilité valent 8 et 2 (des valeurs plausibles en dimension $d = 64$, sans mise à l'échelle).

- (a) Calculer les poids d'attention par softmax **sans** diviser par $\sqrt{d}$.
- (b) Diviser les deux scores par $\sqrt{64} = 8$, puis calculer à nouveau les poids d'attention.
- (c) Comparer les deux résultats. Lequel est « presque binaire » comme le décrit le chapitre, et lequel reste « doux » ?

Exercice 3 — Le coût quadratique de l'attention

Calculer le nombre de comparaisons (L^2) pour des séquences de longueur $L = 500$, $L = 2000$ et $L = 8000$.

- (a) Calculer les trois valeurs de L^2 .
- (b) Quand L est multiplié par 4 (de 500 à 2000), par quel facteur le coût est-il multiplié ? Et quand L est multiplié par 4 à nouveau (de 2000 à 8000) ?
- (c) Ce résultat est-il cohérent avec le tableau du chapitre (coût quadratique en longueur) ?

2 Exercices cumulatifs (chapitre 9, chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Remettre le softmax du chapitre 1 à l'échelle de l'attention

L'exercice 2 du chapitre 1 utilisait le softmax sur les scores $(1,5; 0,5; -1,0)$, donnant les probabilités $(0,6897; 0,2537; 0,0566)$. On réinterprète à présent ces trois valeurs comme des scores d'attention QK^T (avant mise à l'échelle), pour une dimension $d = 9$.

- (a) Diviser les trois scores par $\sqrt{9} = 3$, puis calculer les nouvelles probabilités softmax.
- (b) Comparer la probabilité maximale obtenue en (a) à celle du chapitre 1 (0,6897). La mise à l'échelle rend-elle la distribution plus ou moins concentrée sur le score le plus élevé ?
- (c) Le chapitre rappelle que le softmax du chapitre 1, la normalisation par couche du chapitre 6, les connexions résiduelles du chapitre 7 et le réseau dense du chapitre 1 sont les briques déjà connues du transformeur, seule l'attention étant nouvelle. Sachant que le chapitre 8 a justifié le LSTM par un « chemin direct pour le gradient » identique en esprit à la connexion résiduelle du chapitre 7, pourquoi un bloc de transformeur, qui empile deux connexions résiduelles par bloc, hérite-t-il du même avantage face à l'évanouissement du gradient (chapitre 4) qu'un réseau très profond ?

3 Applications en sciences économiques

Exercice 5 — Le coût de l'attention sur des données à haute fréquence

Une salle de marché envisage un transformeur sur des séquences de cotations, de longueurs $L = 200$, $L = 800$ et $L = 3\,200$ (nombre de cotations successives).

- (a) Calculer le coût en comparaisons (L^2) pour chacune des trois longueurs.
- (b) Le passage de $L = 200$ à $L = 3\,200$ correspond à une multiplication par 16 de la longueur. Par quel facteur le coût est-il multiplié ?
- (c) Une architecture récurrente (chapitre 8) aurait, pour cette même multiplication par 16 de la longueur, un coût multiplié par 16 également (coût linéaire). Ce contraste est-il cohérent avec l'arbitrage récurrent contre transformeur décrit dans ce chapitre ?

Exercice 6 — Le volume de données justifie-t-il un transformeur ?


Un gérant dispose de 15 années de cours quotidiens (environ 252 séances de bourse par an).

- (a) Calculer le nombre approximatif de points de sa série (15×252).
- (b) Le chapitre indique qu'une série quotidienne sur vingt ans compte environ 5 000 points, un volume déjà jugé « infime » pour un transformeur. Calculer le rapport entre le nombre de points du gérant et ces 5 000 points de référence.
- (c) Compte tenu de ce volume et de la mise en garde du chapitre, quelles architectures seraient plus vraisemblablement compétitives ici qu'un transformeur ? La réponse dépend-elle de la nature du problème (prévoir un rendement ou une volatilité), ou principalement du volume de données disponible ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $q \cdot k_1 = 2 \times 1 + 0 \times 0 = 2$. $q \cdot k_2 = 2 \times 0 + 0 \times 1 = 0$.
- (b) Scores mis à l'échelle : $2/\sqrt{2} \approx 1,4142$ et $0/\sqrt{2} = 0$. Poids softmax : $e^{1,4142} \approx 4,1133$, $e^0 = 1$, somme $\approx 5,1133$, donc $w_1 \approx 0,8044$ et $w_2 \approx 0,1956$.
- (c) Sortie = $0,8044 \times (4, 0) + 0,1956 \times (0, 6) = (3,2177 ; 0) + (0 ; 1,1734) = (3,2177 ; 1,1734)$.




Correction — Exercice 2

- (a) Sans mise à l'échelle : $e^8 \approx 2980,96$, $e^2 \approx 7,389$, somme $\approx 2988,35$. Poids $\approx 0,9975$ et $0,0025$.
- (b) Scores mis à l'échelle : $8/8 = 1$ et $2/8 = 0,25$. Poids softmax : $e^1 \approx 2,7183$, $e^{0,25} \approx 1,2840$, somme $\approx 4,0023$. Poids $\approx 0,6792$ et $0,3208$.
- (c) Sans mise à l'échelle, la distribution est **presque binaire** (0,9975 contre 0,0025) : c'est exactement le phénomène décrit par le chapitre. Avec la mise à l'échelle, la distribution reste **douce** (0,68 contre 0,32), permettant un gradient utile lors de l'entraînement.



Correction — Exercice 3

- (a) $500^2 = 250\,000$. $2\,000^2 = 4\,000\,000$. $8\,000^2 = 64\,000\,000$.
- (b) De 500 à 2000 (facteur 4 sur L) : coût multiplié par $4\,000\,000/250\,000 = 16$. De 2000 à 8000 (facteur 4 sur L à nouveau) : coût multiplié par $64\,000\,000/4\,000\,000 = 16$.
- (c) Oui, parfaitement cohérent : un coût **quadratique** signifie que multiplier L par un facteur c multiplie le coût par c^2 ; ici $c = 4$ donne $c^2 = 16$ dans les deux cas, exactement ce qui est observé.




2 Exercices cumulatifs (chapitre 9, chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Scores mis à l'échelle : $1,5/3 = 0,5$; $0,5/3 \approx 0,1667$; $-1,0/3 \approx -0,3333$. Softmax : $e^{0,5} \approx 1,6487$, $e^{0,1667} \approx 1,1814$, $e^{-0,3333} \approx 0,7165$, somme $\approx 3,5466$. Probabilités $\approx$ **0,4649**; **0,3331**; **0,2020**.

(b) La probabilité maximale passe de 0,6897 (chapitre 1, sans mise à l'échelle) à **0,4649** (avec mise à l'échelle) : la distribution devient nettement **moins concentrée**, plus proche d'une répartition uniforme entre les trois scores.

(c) Une connexion résiduelle $y = F(x) + x$ (chapitre 7) offre au gradient un chemin **additif**, sans facteur multiplicatif, exactement comme l'état de cellule d'un LSTM (chapitre 8) lorsque sa porte d'oubli reste ouverte. Un bloc de transformeur empile **deux** telles connexions résiduelles (une autour de l'attention, une autour du réseau dense position par position). En empilant N blocs, le gradient dispose donc de $2N$ chemins directs à travers lesquels il peut circuler sans être multiplié par des facteurs potentiellement inférieurs à 1 – exactement le mécanisme qui, au chapitre 7, a permis l'entraînement de réseaux à plus de cent couches malgré le problème d'évanouissement identifié au chapitre 4. Le transformeur hérite ainsi, par construction, du même remède architectural que le LSTM et le ResNet, plutôt que de le redécouvrir.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $200^2 = 40\,000$. $800^2 = 640\,000$. $3\,200^2 = 10\,240\,000$.

(b) $10\,240\,000/40\,000 = 256 = 16^2$: cohérent avec un coût quadratique, une multiplication de la longueur par 16 multiplie le coût par $16^2 = 256$.

(c) Oui, ce contraste illustre exactement l'arbitrage du chapitre : le coût de l'attention croît comme le **carré** de la longueur ($\times 256$ ici), tandis qu'une architecture récurrente aurait un coût **linéaire** (multiplié par 16 seulement pour la même variation de longueur) – au prix, en contrepartie, d'un traitement séquentiel non parallélisable et d'une portée de mémoire plus limitée. Le choix entre les deux architectures dépend donc directement de la longueur de séquence visée et des ressources de calcul disponibles.

Correction — Exercice 6

(a) $15 \times 252 = 3\,780$ points environ.

(b) Rapport $= 3\,780/5\,000 = 0,756$: le gérant dispose d'un volume **inférieur** à la référence de 5 000 points déjà jugée insuffisante par le chapitre.

(c) Compte tenu de ce volume très réduit, des architectures plus simples – GARCH, ARMA, boosting sur variables construites, comme le mentionne explicitement le chapitre – resteraient vraisemblablement plus compétitives qu'un transformeur. La réponse dépend **principalement du volume de données disponible**, et non de la nature du problème (rendement ou volatilité) : le chapitre

est explicite sur ce point («la taille des données commande le choix d'architecture, davantage que la nature du problème»). Ce même volume resterait insuffisant que l'on cherche à prévoir un rendement ou une volatilité.