

Chapitre 9

L'attention et les transformeurs

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Exercice 1 — Calculer une attention à produit scalaire mis à l'échelle

Une requête $q = (2, 0)$ doit consulter deux positions, de clés $k_1 = (1, 0)$ et $k_2 = (0, 1)$, et de valeurs $v_1 = (4, 0)$ et $v_2 = (0, 6)$. La dimension est $d = 2$.

- Calculer les scores de compatibilité $q \cdot k_1$ et $q \cdot k_2$.
- Diviser ces scores par $\sqrt{d} = \sqrt{2}$, puis calculer les poids d'attention par softmax.
- Calculer la sortie de l'attention, moyenne pondérée des valeurs par ces poids.

Exercice 2 — Pourquoi diviser par $\sqrt{d}$

Deux scores de compatibilité valent 8 et 2 (des valeurs plausibles en dimension $d = 64$, sans mise à l'échelle).

- Calculer les poids d'attention par softmax **sans** diviser par $\sqrt{d}$.
- Diviser les deux scores par $\sqrt{64} = 8$, puis calculer à nouveau les poids d'attention.
- Comparer les deux résultats. Lequel est « presque binaire » comme le décrit le chapitre, et lequel reste « doux » ?

Exercice 3 — Le coût quadratique de l'attention

Calculer le nombre de comparaisons (L^2) pour des séquences de longueur $L = 500$, $L = 2000$ et $L = 8000$.

- Calculer les trois valeurs de L^2 .
- Quand L est multiplié par 4 (de 500 à 2000), par quel facteur le coût est-il multiplié ? Et quand L est multiplié par 4 à nouveau (de 2000 à 8000) ?
- Ce résultat est-il cohérent avec le tableau du chapitre (coût quadratique en longueur) ?

2 Exercices cumulatifs (chapitre 9, chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Remettre le softmax du chapitre 1 à l'échelle de l'attention

L'exercice 2 du chapitre 1 utilisait le softmax sur les scores $(1,5 ; 0,5 ; -1,0)$, donnant les probabilités $(0,6897 ; 0,2537 ; 0,0566)$. On réinterprète à présent ces trois valeurs comme des scores d'attention QK^T (avant mise à l'échelle), pour une dimension $d = 9$.

- Diviser les trois scores par $\sqrt{9} = 3$, puis calculer les nouvelles probabilités softmax.
- Comparer la probabilité maximale obtenue en (a) à celle du chapitre 1 (0,6897). La mise à l'échelle rend-elle la distribution plus ou moins concentrée sur le score le plus élevé ?
- Le chapitre rappelle que le softmax du chapitre 1, la normalisation par couche du chapitre 6, les connexions résiduelles du chapitre 7 et le réseau dense du chapitre 1 sont les briques déjà connues du transformeur, seule l'attention étant nouvelle. Sachant que le chapitre 8 a justifié le LSTM par un « chemin direct pour le gradient » identique en esprit à la connexion résiduelle du chapitre 7, pourquoi un bloc de transformeur, qui empile deux connexions résiduelles par bloc, hérite-t-il du même avantage face à l'évanouissement du gradient (chapitre 4) qu'un réseau très profond ?

3 Applications en sciences économiques

Exercice 5 — Le coût de l'attention sur des données à haute fréquence

Une salle de marché envisage un transformeur sur des séquences de cotations, de longueurs $L = 200$, $L = 800$ et $L = 3\,200$ (nombre de cotations successives).

- (a) Calculer le coût en comparaisons (L^2) pour chacune des trois longueurs.
- (b) Le passage de $L = 200$ à $L = 3\,200$ correspond à une multiplication par 16 de la longueur. Par quel facteur le coût est-il multiplié ?
- (c) Une architecture récurrente (chapitre 8) aurait, pour cette même multiplication par 16 de la longueur, un coût multiplié par 16 également (coût linéaire). Ce contraste est-il cohérent avec l'arbitrage récurrent contre transformeur décrit dans ce chapitre ?

Exercice 6 — Le volume de données justifie-t-il un transformeur ?

Un gérant dispose de 15 années de cours quotidiens (environ 252 séances de bourse par an).

- (a) Calculer le nombre approximatif de points de sa série (15×252).
- (b) Le chapitre indique qu'une série quotidienne sur vingt ans compte environ 5 000 points, un volume déjà jugé « infime » pour un transformeur. Calculer le rapport entre le nombre de points du gérant et ces 5 000 points de référence.
- (c) Compte tenu de ce volume et de la mise en garde du chapitre, quelles architectures seraient plus vraisemblablement compétitives ici qu'un transformeur ? La réponse dépend-elle de la nature du problème (prévoir un rendement ou une volatilité), ou principalement du volume de données disponible ?