

Chapitre 3

La descente de gradient et ses variantes

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) $\partial L / \partial w = 6w$, donc $w \leftarrow w - 6\eta w = w(1 - 6\eta)$. Pour $\eta = 0,05$: facteur = $1 - 6 \times 0,05 = 1 - 0,3 = 0,7$.
(b) $w_0 = 2$; $w_1 = 2 \times 0,7 = 1,4$; $w_2 = 1,4 \times 0,7 = 0,98$; $w_3 = 0,98 \times 0,7 \approx 0,686$; $w_4 \approx 0,686 \times 0,7 \approx 0,4802$. Oui, la suite **converge** vers 0 : le facteur 0,7 vérifie $|0,7| < 1$.
(c) Pour $\eta = 0,4$: facteur = $1 - 6 \times 0,4 = 1 - 2,4 = -1,4$. Trajectoire : $w_1 = 2 \times (-1,4) = -2,8$; $w_2 = -2,8 \times (-1,4) = 3,92$; $w_3 \approx -5,488$; $w_4 \approx 7,6832$. La suite **diverge** en oscillant : $|-1,4| > 1$.




Correction — Exercice 2

- (a) $5\,000/64 = 78,125$, soit environ **78** mises à jour par époque.
(b) $2\,000/250 = 8$ mises à jour par époque.
(c) Pour un nombre total d'observations donné, réduire la taille des lots **augmente** le nombre de mises à jour par époque : c'est cohérent avec le tableau du chapitre, où le régime stochastique (un seul exemple par pas) produit le plus grand nombre de mises à jour, tandis que le régime batch (tous les exemples à la fois) n'en produit qu'une seule par époque.



Correction — Exercice 3

- (a) $a = 1$: $\eta_{\max} = 1/1 = 1,0$. $a = 5$: $\eta_{\max} = 1/5 = 0,2$. $a = 0,5$: $\eta_{\max} = 1/0,5 = 2,0$.
(b) De la plus pentue à la plus plate : $a = 5$ (la plus pentue) $> a = 1 > a = 0,5$ (la plus plate). Avec $\eta = 0,3$: pour $a = 5$ ($\eta_{\max} = 0,2$), $0,3 > 0,2$: la descente **diverge**. Pour $a = 1$ ($\eta_{\max} = 1,0$), $0,3 < 1,0$: elle **converge**. Pour $a = 0,5$ ($\eta_{\max} = 2,0$), $0,3 < 2,0$: elle **converge** également.
(c) Un même taux η global peut faire diverger les directions à forte courbure (a grand) tout en faisant progresser trop lentement les directions à faible courbure (a petit) ; un optimiseur adaptatif par paramètre ajuste implicitement un η effectif différent pour chaque direction, sans qu'il soit nécessaire de connaître a à l'avance.




2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\eta' \times 0,0625 = 0,001 \times 1 \Rightarrow \eta' = 0,001/0,0625 = \mathbf{0,016}$.

(b) Rapport $\eta'/\eta = 0,016/0,001 = \mathbf{16}$. Ce n'est **pas** vraiment dans l'esprit des bonnes pratiques du chapitre : celles-ci recommandent d'ajuster par **facteurs de dix** ($10^{-3} \rightarrow 10^{-2} \rightarrow 10^{-1}$), alors qu'ici il faudrait un facteur 16, intermédiaire et peu naturel entre les paliers habituels – un signe que l'on force artificiellement le réglage pour compenser un problème d'une autre nature.

(c) Compenser l'atténuation par un taux plus élevé est fragile pour (au moins) deux raisons qui rejoignent les trois premiers chapitres. D'abord, le facteur 0,0625 est un facteur **au mieux**, calculé pour la dérivée maximale de la sigmoïde (0,25) : dans les zones où les neurones sont proches de la saturation, l'atténuation réelle est bien plus forte, et η' redevient insuffisant. Ensuite, et surtout, l'exercice 3 montre que le taux d'apprentissage optimal dépend de la courbure a , qui **diffère d'une couche et d'un paramètre à l'autre** : un η' calibré pour compenser l'atténuation d'une couche donnée n'a aucune raison de convenir aux autres couches, ni de rester en-deçà du $\eta_{\max} = 1/a$ propre à chacune – avec un risque concret de divergence, comme à l'exercice 1(c). Choisir directement **ReLU** (chapitre 2) supprime le problème à la racine, sans avoir à deviner un taux de compensation instable ; c'est pourquoi ReLU associé à Adam à son taux par défaut (10^{-3} , ce chapitre) forme une combinaison bien plus robuste que sigmoïde + taux ajusté.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $\eta_{\max} = 1/4,5 \approx \mathbf{0,2222}$.

(b) Facteur = $1 - 2 \times 4,5 \times 0,05 = 1 - 0,45 = \mathbf{0,55}$. Trajectoire : $w_1 = 1,5 \times 0,55 = \mathbf{0,825}$; $w_2 \approx \mathbf{0,4538}$; $w_3 \approx \mathbf{0,2496}$; $w_4 \approx \mathbf{0,1373}$ – convergence nette vers 0.

(c) Facteur = $1 - 2 \times 4,5 \times 0,3 = 1 - 2,7 = \mathbf{-1,7}$. Trajectoire : $w_1 = 1,5 \times (-1,7) = \mathbf{-2,55}$; $w_2 \approx \mathbf{4,335}$; $w_3 \approx \mathbf{-7,3695}$; $w_4 \approx \mathbf{12,5281}$ – la suite diverge en oscillant, avec une amplitude qui croît à chaque pas. Oui, le diagnostic du chapitre s'applique directement : ces oscillations d'amplitude croissante sont précisément le symptôme d'un taux d'apprentissage trop grand ($\eta = 0,3 > \eta_{\max} = 0,2222$), et la solution serait de réduire η , pas de changer autre chose au modèle.

Correction — Exercice 6

- (a) Lots de 256 : $120\,000/256 = 468,75$, soit environ **469** mises à jour par époque. Lots de 32 : $120\,000/32 = 3\,750$ mises à jour par époque.
- (b) Rapport = $3\,750/469 \approx 8$ (exactement 8 si l'on compare les tailles de lots sans arrondi : $256/32 = 8$).
- (c) À temps de calcul par mise à jour comparable, les lots de 256 produisent environ 8 fois moins de mises à jour, donc une époque plus rapide en temps total. Cela ne signifie **pas** qu'il faille systématiquement maximiser la taille des lots : le chapitre rappelle que le bruit du mini-batch aide à sortir des minima locaux médiocres et agit comme une régularisation légère, un avantage qui s'amenuise à mesure que les lots grossissent et se rapprochent du régime batch. Le choix de la taille de lot reste donc un compromis entre vitesse d'exécution et qualité de l'exploration, non une simple maximisation de la vitesse.