

# Apprentissage profond

Chapitre 3 : La descente de gradient et ses variantes

**Exercices corrigés**

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

## Table des matières

|                                       |   |
|---------------------------------------|---|
| <b>Partie 1 --- Énoncés</b> .....     | 1 |
| <b>Partie 2 --- Corrections</b> ..... | 3 |

## 1 Exercices du chapitre

### Exercice 1 — Trajectoire d'une descente de gradient

On minimise  $L(w) = 3w^2$ , de dérivée  $6w$ , en partant de  $w_0 = 2$ .

- (a) Écrire la règle de mise à jour  $w \leftarrow w - \eta \partial L / \partial w$  sous la forme  $w \leftarrow w \times (1 - 2 \times 3 \times \eta)$ , puis calculer le facteur multiplicatif pour  $\eta = 0,05$ .
- (b) Calculer les quatre premières valeurs de la trajectoire ( $w_1$  à  $w_4$ ) pour  $\eta = 0,05$ . La suite converge-t-elle ?
- (c) Calculer le facteur multiplicatif et les quatre premières valeurs de la trajectoire pour  $\eta = 0,4$ . Que se passe-t-il ?

### Exercice 2 — Compter les mises à jour par époque

Une base d'apprentissage compte 5 000 observations, avec des lots (mini-batches) de taille 64.

- (a) Calculer le nombre de mises à jour effectuées au cours d'une époque complète.
- (b) Une seconde base compte 2 000 observations, avec des lots de taille 250. Calculer le nombre de mises à jour par époque dans ce second cas.
- (c) Pour un même nombre total d'observations, que se passe-t-il sur le nombre de mises à jour par époque lorsque la taille des lots diminue ? Ce constat est-il cohérent avec le tableau du chapitre opposant les régimes batch, stochastique et mini-batch ?

### Exercice 3 — Le taux d'apprentissage maximal dépend de la courbure

On généralise l'exemple du chapitre à une perte  $L(w) = aw^2$ , de dérivée  $2aw$ , pour laquelle la condition de convergence s'écrit  $0 < \eta < 1/a$ .

- (a) Calculer le taux d'apprentissage maximal  $\eta_{\max} = 1/a$  pour  $a = 1$ ,  $a = 5$  et  $a = 0,5$ .
- (b) Classer ces trois valeurs de  $a$  de la plus « pentue » à la plus « plate », et indiquer, pour chacune, si un même taux  $\eta = 0,3$  ferait converger ou diverger la descente.
- (c) Expliquer, en une phrase, pourquoi un optimiseur qui ajuste le taux **par paramètre** (comme RMSProp ou Adam) est utile lorsque différents paramètres d'un même réseau correspondent à des courbures  $a$  très différentes.

## 2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

### Exercice 4 — Compenser l'atténuation du gradient par le taux d'apprentissage ?

Le chapitre 2 a établi que, pour le réseau officiel du chapitre 1 (architecture  $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$ , deux couches cachées), le facteur d'atténuation au mieux du gradient vaut 1 avec ReLU et 0,0625 avec la sigmoïde. On envisage d'entraîner ce réseau avec Adam au taux par défaut  $\eta = 10^{-3} = 0,001$  rappelé dans ce chapitre.

- (a) Si l'on utilisait la sigmoïde au lieu de ReLU, quel taux d'apprentissage  $\eta'$  faudrait-il utiliser pour que la mise à jour effective ( $\eta \times$  facteur) soit, au mieux, de même ampleur qu'avec ReLU à  $\eta = 0,001$  ? Résoudre  $\eta' \times 0,0625 = 0,001 \times 1$ .
- (b) Calculer le rapport  $\eta' / \eta$ . Ce taux  $\eta'$  reste-t-il dans l'esprit des bonnes pratiques rappelées dans ce chapitre (partir de  $10^{-3}$ , ajuster par facteurs de dix) ?
- (c) En combinant les enseignements des chapitres 1 à 3 : pourquoi chercher à compenser une atténuation du gradient par un taux d'apprentissage plus élevé est-il une stratégie fragile, comparée au choix direct de ReLU en couches cachées ? (Indice : un taux  $\eta'$  pensé pour compenser *une* couche à *une* courbure  $a$  donnée reste-t-il adapté à toutes les autres couches et à tous les autres paramètres du réseau, dont les courbures diffèrent, comme le montre l'exercice

### 3 Applications en sciences économiques

#### Exercice 5 — Calibrer un taux d'apprentissage pour un coût d'inventaire

Une entreprise modélise son coût d'ajustement de stock par une fonction  $L(w) = 4,5 w^2$ , où  $w$  mesure l'écart entre le stock ciblé par le modèle et un stock de référence, en partant de  $w_0 = 1,5$ .

- (a) Calculer le taux d'apprentissage maximal  $\eta_{\max}$  compatible avec la convergence.
- (b) Avec  $\eta = 0,05$  (inférieur à  $\eta_{\max}$ ), calculer les quatre premières valeurs de la trajectoire de  $w$ .
- (c) Avec  $\eta = 0,3$  (supérieur à  $\eta_{\max}$ ), calculer à nouveau les quatre premières valeurs. Le diagnostic du chapitre (« la perte augmente ou oscille violemment  $\Rightarrow \eta$  trop grand ») s'applique-t-il ici ?

#### Exercice 6 — Choisir une taille de lot pour un modèle bancaire


Une banque entraîne un modèle de scoring sur 120 000 dossiers de crédit.

- (a) Calculer le nombre de mises à jour par époque avec des lots de taille 256, puis avec des lots de taille 32.
- (b) Calculer le rapport entre ces deux nombres de mises à jour.
- (c) En supposant que le temps de calcul par mise à jour est comparable pour les deux tailles de lot (ce qui est réaliste sur un grand jeu de données avec un matériel adapté), quelle taille de lot conduit à un entraînement plus rapide par époque ? Cela signifie-t-il qu'il faut systématiquement choisir la plus grande taille de lot possible, au vu de ce que dit le chapitre sur l'utilité du bruit du mini-batch ?

## 1 Exercices du chapitre


### Correction — Exercice 1

- (a)  $\partial L / \partial w = 6w$ , donc  $w \leftarrow w - 6\eta w = w(1 - 6\eta)$ . Pour  $\eta = 0,05$  : facteur =  $1 - 6 \times 0,05 = 1 - 0,3 = 0,7$ .  
 (b)  $w_0 = 2$ ;  $w_1 = 2 \times 0,7 = 1,4$ ;  $w_2 = 1,4 \times 0,7 = 0,98$ ;  $w_3 = 0,98 \times 0,7 \approx 0,686$ ;  $w_4 \approx 0,686 \times 0,7 \approx 0,4802$ .  
 Oui, la suite **converge** vers 0 : le facteur 0,7 vérifie  $|0,7| < 1$ .  
 (c) Pour  $\eta = 0,4$  : facteur =  $1 - 6 \times 0,4 = 1 - 2,4 = -1,4$ . Trajectoire :  $w_1 = 2 \times (-1,4) = -2,8$ ;  $w_2 = -2,8 \times (-1,4) = 3,92$ ;  $w_3 \approx -5,488$ ;  $w_4 \approx 7,6832$ . La suite **diverge** en oscillant :  $|-1,4| > 1$ .




### Correction — Exercice 2

- (a)  $5\,000/64 = 78,125$ , soit environ **78** mises à jour par époque.  
 (b)  $2\,000/250 = 8$  mises à jour par époque.  
 (c) Pour un nombre total d'observations donné, réduire la taille des lots **augmente** le nombre de mises à jour par époque : c'est cohérent avec le tableau du chapitre, où le régime stochastique (un seul exemple par pas) produit le plus grand nombre de mises à jour, tandis que le régime batch (tous les exemples à la fois) n'en produit qu'une seule par époque.



### Correction — Exercice 3

- (a)  $a = 1$  :  $\eta_{\max} = 1/1 = 1,0$ .  $a = 5$  :  $\eta_{\max} = 1/5 = 0,2$ .  $a = 0,5$  :  $\eta_{\max} = 1/0,5 = 2,0$ .  
 (b) De la plus pentue à la plus plate :  $a = 5$  (la plus pentue)  $> a = 1 > a = 0,5$  (la plus plate). Avec  $\eta = 0,3$  : pour  $a = 5$  ( $\eta_{\max} = 0,2$ ),  $0,3 > 0,2$  : la descente **diverge**. Pour  $a = 1$  ( $\eta_{\max} = 1,0$ ),  $0,3 < 1,0$  : elle **converge**. Pour  $a = 0,5$  ( $\eta_{\max} = 2,0$ ),  $0,3 < 2,0$  : elle **converge** également.  
 (c) Un même taux  $\eta$  global peut faire diverger les directions à forte courbure ( $a$  grand) tout en faisant progresser trop lentement les directions à faible courbure ( $a$  petit) ; un optimiseur adaptatif par paramètre ajuste implicitement un  $\eta$  effectif différent pour chaque direction, sans qu'il soit nécessaire de connaître  $a$  à l'avance.




## 2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

### Correction — Exercice 4

(a)  $\eta' \times 0,0625 = 0,001 \times 1 \Rightarrow \eta' = 0,001/0,0625 = \mathbf{0,016}$ .

(b) Rapport  $\eta'/\eta = 0,016/0,001 = \mathbf{16}$ . Ce n'est **pas** vraiment dans l'esprit des bonnes pratiques du chapitre : celles-ci recommandent d'ajuster par **facteurs de dix** ( $10^{-3} \rightarrow 10^{-2} \rightarrow 10^{-1}$ ), alors qu'ici il faudrait un facteur 16, intermédiaire et peu naturel entre les paliers habituels – un signe que l'on force artificiellement le réglage pour compenser un problème d'une autre nature.

(c) Compenser l'atténuation par un taux plus élevé est fragile pour (au moins) deux raisons qui rejoignent les trois premiers chapitres. D'abord, le facteur 0,0625 est un facteur **au mieux**, calculé pour la dérivée maximale de la sigmoïde (0,25) : dans les zones où les neurones sont proches de la saturation, l'atténuation réelle est bien plus forte, et  $\eta'$  redevient insuffisant. Ensuite, et surtout, l'exercice 3 montre que le taux d'apprentissage optimal dépend de la courbure  $a$ , qui **diffère d'une couche et d'un paramètre à l'autre** : un  $\eta'$  calibré pour compenser l'atténuation d'une couche donnée n'a aucune raison de convenir aux autres couches, ni de rester en-deçà du  $\eta_{\max} = 1/a$  propre à chacune – avec un risque concret de divergence, comme à l'exercice 1(c). Choisir directement **ReLU** (chapitre 2) supprime le problème à la racine, sans avoir à deviner un taux de compensation instable ; c'est pourquoi ReLU associé à Adam à son taux par défaut ( $10^{-3}$ , ce chapitre) forme une combinaison bien plus robuste que sigmoïde + taux ajusté.



## 3 Applications en sciences économiques

### Correction — Exercice 5

(a)  $\eta_{\max} = 1/4,5 \approx \mathbf{0,2222}$ .

(b) Facteur =  $1 - 2 \times 4,5 \times 0,05 = 1 - 0,45 = \mathbf{0,55}$ . Trajectoire :  $w_1 = 1,5 \times 0,55 = \mathbf{0,825}$  ;  $w_2 \approx \mathbf{0,4538}$  ;  $w_3 \approx \mathbf{0,2496}$  ;  $w_4 \approx \mathbf{0,1373}$  – convergence nette vers 0.

(c) Facteur =  $1 - 2 \times 4,5 \times 0,3 = 1 - 2,7 = \mathbf{-1,7}$ . Trajectoire :  $w_1 = 1,5 \times (-1,7) = \mathbf{-2,55}$  ;  $w_2 \approx \mathbf{4,335}$  ;  $w_3 \approx \mathbf{-7,3695}$  ;  $w_4 \approx \mathbf{12,5281}$  – la suite diverge en oscillant, avec une amplitude qui croît à chaque pas. Oui, le diagnostic du chapitre s'applique directement : ces oscillations d'amplitude croissante sont précisément le symptôme d'un taux d'apprentissage trop grand ( $\eta = 0,3 > \eta_{\max} = 0,2222$ ), et la solution serait de réduire  $\eta$ , pas de changer autre chose au modèle.

## Correction — Exercice 6

- (a) Lots de 256 :  $120\,000/256 = 468,75$ , soit environ **469** mises à jour par époque. Lots de 32 :  $120\,000/32 = 3\,750$  mises à jour par époque.
- (b) Rapport =  $3\,750/469 \approx 8$  (exactement 8 si l'on compare les tailles de lots sans arrondi :  $256/32 = 8$ ).
- (c) À temps de calcul par mise à jour comparable, les lots de 256 produisent environ 8 fois moins de mises à jour, donc une époque plus rapide en temps total. Cela ne signifie **pas** qu'il faille systématiquement maximiser la taille des lots : le chapitre rappelle que le bruit du mini-batch aide à sortir des minima locaux médiocres et agit comme une régularisation légère, un avantage qui s'amenuise à mesure que les lots grossissent et se rapprochent du régime batch. Le choix de la taille de lot reste donc un compromis entre vitesse d'exécution et qualité de l'exploration, non une simple maximisation de la vitesse.