

Chapitre 3

La descente de gradient et ses variantes

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Exercice 1 — Trajectoire d'une descente de gradient

On minimise $L(w) = 3w^2$, de dérivée $6w$, en partant de $w_0 = 2$.

- (a) Écrire la règle de mise à jour $w \leftarrow w - \eta \partial L / \partial w$ sous la forme $w \leftarrow w \times (1 - 2 \times 3 \times \eta)$, puis calculer le facteur multiplicatif pour $\eta = 0,05$.
- (b) Calculer les quatre premières valeurs de la trajectoire (w_1 à w_4) pour $\eta = 0,05$. La suite converge-t-elle ?
- (c) Calculer le facteur multiplicatif et les quatre premières valeurs de la trajectoire pour $\eta = 0,4$. Que se passe-t-il ?

Exercice 2 — Compter les mises à jour par époque

Une base d'apprentissage compte 5 000 observations, avec des lots (mini-batches) de taille 64.

- (a) Calculer le nombre de mises à jour effectuées au cours d'une époque complète.
- (b) Une seconde base compte 2 000 observations, avec des lots de taille 250. Calculer le nombre de mises à jour par époque dans ce second cas.
- (c) Pour un même nombre total d'observations, que se passe-t-il sur le nombre de mises à jour par époque lorsque la taille des lots diminue ? Ce constat est-il cohérent avec le tableau du chapitre opposant les régimes batch, stochastique et mini-batch ?

Exercice 3 — Le taux d'apprentissage maximal dépend de la courbure

On généralise l'exemple du chapitre à une perte $L(w) = aw^2$, de dérivée $2aw$, pour laquelle la condition de convergence s'écrit $0 < \eta < 1/a$.

- (a) Calculer le taux d'apprentissage maximal $\eta_{\max} = 1/a$ pour $a = 1$, $a = 5$ et $a = 0,5$.
- (b) Classer ces trois valeurs de a de la plus « pentue » à la plus « plate », et indiquer, pour chacune, si un même taux $\eta = 0,3$ ferait converger ou diverger la descente.
- (c) Expliquer, en une phrase, pourquoi un optimiseur qui ajuste le taux **par paramètre** (comme RMSProp ou Adam) est utile lorsque différents paramètres d'un même réseau correspondent à des courbures a très différentes.

2 Exercices cumulatifs (chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Compenser l'atténuation du gradient par le taux d'apprentissage ?

Le chapitre 2 a établi que, pour le réseau officiel du chapitre 1 (architecture $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$, deux couches cachées), le facteur d'atténuation au mieux du gradient vaut 1 avec ReLU et 0,0625 avec la sigmoïde. On envisage d'entraîner ce réseau avec Adam au taux par défaut $\eta = 10^{-3} = 0,001$ rappelé dans ce chapitre.

- (a) Si l'on utilisait la sigmoïde au lieu de ReLU, quel taux d'apprentissage η' faudrait-il utiliser pour que la mise à jour effective ($\eta \times \text{facteur}$) soit, au mieux, de même ampleur qu'avec ReLU à $\eta = 0,001$? Résoudre $\eta' \times 0,0625 = 0,001 \times 1$.
- (b) Calculer le rapport η' / η . Ce taux η' reste-t-il dans l'esprit des bonnes pratiques rappelées dans ce chapitre (partir de 10^{-3} , ajuster par facteurs de dix) ?
- (c) En combinant les enseignements des chapitres 1 à 3 : pourquoi chercher à compenser une atténuation du gradient par un taux d'apprentissage plus élevé est-il une stratégie fragile, comparée au choix direct de ReLU en couches cachées ? (Indice : un taux η' pensé pour compenser *une* couche à *une* courbure a donnée reste-t-il adapté à toutes les autres couches et à tous les autres paramètres du réseau, dont les courbures diffèrent, comme le montre l'exercice

3 Applications en sciences économiques

Exercice 5 — Calibrer un taux d'apprentissage pour un coût d'inventaire

Une entreprise modélise son coût d'ajustement de stock par une fonction $L(w) = 4,5w^2$, où w mesure l'écart entre le stock ciblé par le modèle et un stock de référence, en partant de $w_0 = 1,5$.

- (a) Calculer le taux d'apprentissage maximal $\eta_{\max}$ compatible avec la convergence.
- (b) Avec $\eta = 0,05$ (inférieur à $\eta_{\max}$), calculer les quatre premières valeurs de la trajectoire de w .
- (c) Avec $\eta = 0,3$ (supérieur à $\eta_{\max}$), calculer à nouveau les quatre premières valeurs. Le diagnostic du chapitre (« la perte augmente ou oscille violemment $\Rightarrow \eta$ trop grand ») s'applique-t-il ici ?

Exercice 6 — Choisir une taille de lot pour un modèle bancaire

Une banque entraîne un modèle de scoring sur 120 000 dossiers de crédit.

- (a) Calculer le nombre de mises à jour par époque avec des lots de taille 256, puis avec des lots de taille 32.
- (b) Calculer le rapport entre ces deux nombres de mises à jour.
- (c) En supposant que le temps de calcul par mise à jour est comparable pour les deux tailles de lot (ce qui est réaliste sur un grand jeu de données avec un matériel adapté), quelle taille de lot conduit à un entraînement plus rapide par époque ? Cela signifie-t-il qu'il faut systématiquement choisir la plus grande taille de lot possible, au vu de ce que dit le chapitre sur l'utilité du bruit du mini-batch ?