

Apprentissage profond

Chapitre 3 : La descente de gradient et ses variantes

Jaouad Madkour

25 septembre 2026

Plan du chapitre

Le principe	1
Descendre dans le sens de la pente	1
Le taux d'apprentissage	2
Le paramètre le plus important du cours	2
Les trois régimes de descente	2
Combien d'observations par pas	2
Époque	3
Les optimiseurs	3
Trois améliorations successives	3
Le choix pratique, en une phrase	4
L'ordonnancement du taux	4
Ce qu'il faut retenir	4
Le résumé du chapitre	4

Le principe

Descendre dans le sens de la pente

La règle de mise à jour

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

Le gradient indique la direction de plus forte **montée** ; on va donc dans le sens opposé. η est le **taux d'apprentissage**.

C'est le chapitre 6 de Mathématiques pour la gestion

Chercher un minimum en annulant les dérivées partielles est exactement la condition du premier ordre à plusieurs variables.

La différence est qu'ici le système ne se résout pas : il y a des millions de paramètres, et l'on

descend pas à pas au lieu de résoudre.

Le taux d'apprentissage

Le paramètre le plus important du cours

Une descente entièrement calculable

Minimisons $L(w) = w^2$, de dérivée $2w$, en partant de $w = 1$.

La règle donne $w \leftarrow w(1 - 2\eta)$: chaque pas multiplie w par un facteur fixe.

η	Facteur	Trajectoire
0,1	+0,8	$1 \rightarrow 0,8 \rightarrow 0,64 \rightarrow 0,512 \rightarrow 0,41$
1,1	-1,2	$1 \rightarrow -1,2 \rightarrow 1,44 \rightarrow -1,73 \rightarrow 2,07$

Le premier **converge** vers zéro. Le second **oscille en s'éloignant** : la descente diverge.

La condition de convergence, ici

$$|1 - 2\eta| < 1 \quad \Longleftrightarrow \quad 0 < \eta < 1$$

Un taux trop grand ne ralentit pas la convergence : **il l'empêche**.

Comment le régler en pratique

Symptôme	Diagnostic
La perte augmente ou oscille violemment	η trop grand
La perte baisse très lentement	η trop petit
La perte baisse puis stagne haut	η à réduire en cours de route

On commence typiquement à 10^{-3} , et l'on ajuste par facteurs de dix. **Tracer la courbe de perte à chaque époque est le premier geste de diagnostic.**

Les trois régimes de descente

Combien d'observations par pas

Batch, stochastique, mini-batch

Régime	Observations par pas	Caractère
Batch	toutes	coûteux, trajectoire lisse
Stochastique	une seule	rapide, très bruité
Mini-batch	32 à 256	le compromis employé partout

Pourquoi le bruit est utile

On pourrait croire que la descente batch, plus précise, est préférable.

Le bruit du mini-batch aide en réalité à **sortir des minima locaux médiocres** et des plateaux. Il agit comme une régularisation légère.

De plus, un pas approximatif calculé cent fois vaut mieux qu'un pas exact calculé une fois : à temps égal, le mini-batch progresse davantage.

Définition

Une **époque** est un passage complet sur les données d'apprentissage.

Avec 1 000 observations et des lots de 32, une époque compte environ 32 mises à jour.

Le momentum

On accumule une **inertie** : le pas courant garde une part du précédent.

Cela lisse les oscillations dans les directions instables et accélère dans les directions constantes — comme une bille qui prend de la vitesse dans une vallée.

Le taux adaptatif

RMSProp ajuste le taux **par paramètre**, en divisant par une moyenne des gradients récents.

Les paramètres à gradients forts avancent prudemment, ceux à gradients faibles plus franchement.

Adam

Adam combine les deux : inertie et taux adaptatif par paramètre.

C'est l'optimiseur par défaut, robuste aux réglages approximatifs. On le lance typiquement avec $\eta = 10^{-3}$.

Application en gestion

Commencer par **Adam**. Il fonctionne presque toujours correctement du premier coup. La descente avec momentum, mieux réglée, atteint parfois une meilleure solution finale sur les grands modèles de vision — c’est une optimisation de dernier ressort, pas un point de départ.

Faire décroître le taux

Un taux élevé au début explore ; un taux faible à la fin affine.

Stratégie	Principe
Par paliers	diviser par dix à intervalles fixés
Décroissance cosinus	descente douce et continue
Sur plateau	réduire quand la validation stagne

Ce que le chapitre a établi

Le taux d’apprentissage est le paramètre auquel un réseau est **le plus sensible**. Architecture, activation et optimiseur comptent moins que lui.

Devant un réseau qui n’apprend pas, c’est la première chose à regarder — et souvent la seule à corriger.

Cinq points

1. $w \leftarrow w - \eta \partial L / \partial w$: on descend dans le sens opposé au gradient.
2. Sur $L(w) = w^2$: $\eta = 0,1$ converge, $\eta = 1,1$ **diverge** — la condition est $0 < \eta < 1$.
3. Le **mini-batch** de 32 à 256 est le régime standard ; son bruit est utile.
4. **Adam** — momentum et taux adaptatif — est l’optimiseur par défaut, à 10^{-3} .
5. Le **taux d’apprentissage** est le paramètre le plus sensible de tous.

La suite

Il reste à savoir comment le gradient est calculé pour des millions de paramètres. C’est la rétropropagation, au chapitre 4.