

Chapitre 6

Initialisation et normalisation

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) Variance Xavier = $2/(64 + 32) = 2/96 \approx 0,02083$. Écart-type = $\sqrt{0,02083} \approx 0,1443$.
- (b) Variance He = $2/64 \approx 0,03125$. Écart-type = $\sqrt{0,03125} \approx 0,1768$.
- (c) Rapport = $0,03125/0,02083 = 1,5$. C'est cohérent : la variance He ne dépend que de $n_{\text{entrée}}$, alors que la variance Xavier divise par la moyenne de $n_{\text{entrée}}$ et n_{sortie} (ici $(64 + 32)/2 = 48$ contre $n_{\text{entrée}} = 64$); comme $n_{\text{sortie}} < n_{\text{entrée}}$ ici, la variance Xavier est mécaniquement plus petite. Plus fondamentalement, He double la variance par rapport à ce que donnerait un simple $2/n_{\text{entrée}}$ sans le facteur 2 au numérateur, précisément pour compenser les sorties annulées par ReLU.




Correction — Exercice 2

- (a) Moyenne = $(45\,000 + 52\,000 + 38\,000 + 61\,000 + 47\,000)/5 = 243\,000/5 = 48\,600$. Écart-type $\approx 7\,657,68$.
- (b) $z = (55\,000 - 48\,600)/7\,657,68 \approx 0,8358$.
- (c) Avec les deux observations de test ajoutées, sur huit valeurs : nouvelle moyenne $\approx 61\,142,86$, nouvel écart-type $\approx 20\,904,06$. Nouveau $z = (55\,000 - 61\,142,86)/20\,904,06 \approx -0,2939$. L'écart entre les deux valeurs de z est d'environ 1,13 écart-type, et le **signe change** (+0,84 contre -0,29) : la même observation passe d'« au-dessus de la moyenne » à « en-dessous de la moyenne » selon que l'on inclut ou non le test dans le calcul. C'est une fuite au sens du chapitre : les statistiques de normalisation ne doivent être calculées que sur l'apprentissage, faute de quoi l'information du test « contamine » silencieusement le prétraitement, et l'évaluation qui suivra ne mesurera plus la performance dans des conditions réalistes.



Correction — Exercice 3

- (a) Moyenne = $(2 + 4 + 6 + 8)/4 = 5$. Écart-type $\approx 2,2361$.
- (b) Normalisées : $(2 - 5)/2,2361 \approx -1,3416$; $(4 - 5)/2,2361 \approx -0,4472$; $(6 - 5)/2,2361 \approx 0,4472$; $(8 - 5)/2,2361 \approx 1,3416$.
- (c) Avec $\gamma = 1,5$, $\beta = 0,5$: $1,5 \times (-1,3416) + 0,5 \approx -1,5125$; $1,5 \times (-0,4472) + 0,5 \approx -0,1708$; $1,5 \times 0,4472 + 0,5 \approx 1,1708$; $1,5 \times 1,3416 + 0,5 \approx 2,5125$.




2 Exercices cumulatifs (chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Couche 1 ($n_{\text{entrée}} = 20$) : variance He = $2/20 = 0,1$. Couche 2 ($n_{\text{entrée}} = 32$) : variance He = $2/32 = 0,0625$.

(b) $\text{Var}(z_1) = 20 \times 0,1 \times 1 = 2$. $\text{Var}(a_1) = 0,5 \times 2 = 1$. $\text{Var}(z_2) = 32 \times 0,0625 \times 1 = 2$. $\text{Var}(a_2) = 0,5 \times 2 = 1$.

(c) La variance de la pré-activation est **exactement identique** d'une couche à l'autre : $\text{Var}(z_1) = \text{Var}(z_2) = 2$, et de même $\text{Var}(a_1) = \text{Var}(a_2) = 1$, retrouvant la variance unitaire de l'entrée standardisée. Ce résultat est **distinct** du problème de gradient étudié au chapitre 4 : il porte sur l'échelle des **activations** lors de la passe avant, non sur l'atténuation du **gradient** lors de la passe arrière. Mais les deux phénomènes sont liés par une cause commune : si les activations explosaient ou s'effondraient couche après couche (variance non préservée), les neurones se retrouveraient soit saturés soit constamment nuls, ce qui aggraverait précisément l'évanouissement ou l'explosion du gradient au retour. En préservant la variance dès l'initialisation, He met le réseau dans un régime où ni les activations ni, en conséquence, les gradients ne partent dans des valeurs extrêmes dès les premières passes.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Moyenne = $(120\,000 + 95\,000 + 150\,000 + 88\,000 + 110\,000 + 135\,000)/6 \approx 116\,333,33$. Écart-type $\approx 21\,576,74$.

(b) Avec les deux dossiers de test ajoutés, sur huit observations : nouvelle moyenne = **144 750**, nouvel écart-type $\approx 52\,883,72$.

(c) Avec les statistiques correctes : $z = (130\,000 - 116\,333,33)/21\,576,74 \approx 0,6334$. Avec les statistiques polluées : $z = (130\,000 - 144\,750)/52\,883,72 \approx -0,2789$. Le signe **change** : le même dossier passe d'un profil « au-dessus de la moyenne » à « en-dessous de la moyenne ». Un modèle qui déciderait sur la base d'un seuil sur z (par exemple « accorder le crédit si $z > 0$ ») prendrait une décision **opposée** selon que la fuite s'est produite ou non – une illustration concrète et à fort enjeu de la mise en garde du chapitre.

Correction — Exercice 6

(a) Moyenne = $(30 + 45 + 60 + 25 + 40)/5 = 40$. Écart-type $\approx 12,2474$.

(b) Normalisées : $(30-40)/12,2474 \approx -0,8165$; $(45-40)/12,2474 \approx 0,4082$; $(60-40)/12,2474 \approx 1,6330$; $(25-40)/12,2474 \approx -1,2247$; $(40-40)/12,2474 = 0$.

(c) Avec $\gamma = 0,8$, $\beta = -0,2$: $-0,8532$; $0,1266$; $1,1064$; $-1,1798$; $-0,2$. Avec un lot de taille 1 à l'inférence, la moyenne et l'écart-type du lot seraient calculés sur une **seule** observation : l'écart-type serait nul (ou indéfini), et la normalisation par lot deviendrait impossible ou absurde – la prédiction d'une semaine isolée dépendrait, de façon incohérente, des autres semaines qui se trouveraient par hasard dans le même lot. Le chapitre recommande précisément d'utiliser, à l'inférence, des **moyennes accumulées pendant l'entraînement** plutôt que les statistiques du lot courant, pour que chaque prédiction reste indépendante des autres observations traitées en même temps.