

# Apprentissage profond

Chapitre 6 : Initialisation et normalisation

**Exercices corrigés**

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

## Table des matières

|                                       |   |
|---------------------------------------|---|
| <b>Partie 1 --- Énoncés</b> .....     | 1 |
| <b>Partie 2 --- Corrections</b> ..... | 3 |

## 1 Exercices du chapitre

### Exercice 1 — Comparer Xavier et He

Une couche compte  $n_{\text{entrée}} = 64$  et  $n_{\text{sortie}} = 32$ .

- (a) Calculer la variance Xavier  $2/(n_{\text{entrée}} + n_{\text{sortie}})$ , puis l'écart-type correspondant (racine carrée).
- (b) Calculer la variance He  $2/n_{\text{entrée}}$ , puis l'écart-type correspondant.
- (c) Calculer le rapport entre la variance He et la variance Xavier. Ce rapport est-il cohérent avec l'explication du chapitre sur la raison pour laquelle He est plus large ?

### Exercice 2 — Standardiser sans fuite

Un jeu d'apprentissage compte cinq observations d'une variable de revenu : 45 000 ; 52 000 ; 38 000 ; 61 000 ; 47 000.

- (a) Calculer la moyenne et l'écart-type de ces cinq observations.
- (b) Calculer la valeur standardisée  $z = (x - \text{moyenne})/\text{écart-type}$  pour une nouvelle observation  $x = 55\,000$ , en utilisant les statistiques calculées en (a).
- (c) On recalcule à présent la moyenne et l'écart-type en ajoutant deux observations de test, 90 000 et 95 000, au calcul. Calculer la nouvelle moyenne, le nouvel écart-type, et la nouvelle valeur standardisée de  $x = 55\,000$ . Quel est l'écart entre les deux valeurs de  $z$  obtenues, et pourquoi ce second calcul constitue-t-il une fuite au sens du chapitre ?

### Exercice 3 — Normalisation par lot

Un lot de quatre activations, avant normalisation, vaut 2 ; 4 ; 6 ; 8.

- (a) Calculer la moyenne et l'écart-type de ce lot.
- (b) Calculer les quatre activations normalisées  $(x - \text{moyenne})/\text{écart-type}$ .
- (c) Avec des paramètres appris  $\gamma = 1,5$  et  $\beta = 0,5$ , calculer les quatre activations finales  $\gamma \times (\text{normalisée}) + \beta$ .

## 2 Exercices cumulatifs (chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

### Exercice 4 — L'initialisation He préserve la variance dans le réseau officiel

Le réseau officiel du chapitre 1, d'architecture  $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$ , utilise ReLU dans ses couches cachées (chapitre 2) et des entrées standardisées (chapitre 6), de variance 1 chacune.

- (a) Calculer la variance He  $(2/n_{\text{entrée}})$  pour la première couche cachée ( $n_{\text{entrée}} = 20$ ) et pour la seconde ( $n_{\text{entrée}} = 32$ ).
- (b) On admet que la variance de la pré-activation d'une couche vaut  $\text{Var}(z) = n_{\text{entrée}} \times \text{Var}(w) \times \text{Var}(a_{\text{précédente}})$ , et que ReLU divise par deux la variance qu'elle transmet ( $\text{Var}(a) = 0,5 \times \text{Var}(z)$ ). En partant de  $\text{Var}(\text{entrée}) = 1$ , calculer successivement  $\text{Var}(z_1)$ ,  $\text{Var}(a_1)$ ,  $\text{Var}(z_2)$  et  $\text{Var}(a_2)$ .
- (c) Que remarquez-vous sur la variance de la pré-activation d'une couche à l'autre ( $\text{Var}(z_1)$  contre  $\text{Var}(z_2)$ ) ? En quoi ce résultat éclaire-t-il, indépendamment du problème de gradient étudié au chapitre 4, une seconde raison pour laquelle un réseau ReLU initialisé avec He démarre son entraînement dans de bonnes conditions ?

## 3 Applications en sciences économiques

### Exercice 5 — La fuite de normalisation dans un modèle de crédit aux entreprises

Une banque dispose de six dossiers d'apprentissage, avec les chiffres d'affaires suivants : 120 000 ; 95 000 ; 150 000 ; 88 000 ; 110 000 ; 135 000.

- (a) Calculer la moyenne et l'écart-type de ces six observations d'apprentissage.
- (b) Deux dossiers de test, à chiffre d'affaires nettement plus élevé (220 000 et 240 000), sont ajoutés par erreur au calcul des statistiques. Calculer la nouvelle moyenne et le nouvel écart-type sur les huit observations réunies.
- (c) Calculer la valeur standardisée d'un dossier à 130 000 de chiffre d'affaires, une première fois avec les statistiques correctes (apprentissage seul), une seconde fois avec les statistiques polluées par la fuite. Le signe de  $z$  change-t-il entre les deux calculs ? Quelle conséquence cela aurait-il sur un modèle qui utiliserait un seuil sur  $z$  pour décider ?

### Exercice 6 — Normalisation par lot d'une demande hebdomadaire


Un modèle de prévision de demande traite un lot de cinq observations hebdomadaires : 30 ; 45 ; 60 ; 25 ; 40 (en milliers d'unités).

- (a) Calculer la moyenne et l'écart-type de ce lot.
- (b) Calculer les cinq valeurs normalisées.
- (c) Avec  $\gamma = 0,8$  et  $\beta = -0,2$ , calculer les cinq valeurs finales après remise à l'échelle. Si l'entreprise recevait, à l'inférence, une nouvelle semaine isolée (lot de taille 1), pourquoi la normalisation par lot deviendrait-elle problématique dans ce cas, et que recommande le chapitre pour l'inférence ?

## 1 Exercices du chapitre


### Correction — Exercice 1

- (a) Variance Xavier =  $2/(64 + 32) = 2/96 \approx 0,02083$ . Écart-type =  $\sqrt{0,02083} \approx 0,1443$ .  
(b) Variance He =  $2/64 \approx 0,03125$ . Écart-type =  $\sqrt{0,03125} \approx 0,1768$ .  
(c) Rapport =  $0,03125/0,02083 = 1,5$ . C'est cohérent : la variance He ne dépend que de  $n_{\text{entrée}}$ , alors que la variance Xavier divise par la moyenne de  $n_{\text{entrée}}$  et  $n_{\text{sortie}}$  (ici  $(64 + 32)/2 = 48$  contre  $n_{\text{entrée}} = 64$ ) ; comme  $n_{\text{sortie}} < n_{\text{entrée}}$  ici, la variance Xavier est mécaniquement plus petite. Plus fondamentalement, He double la variance par rapport à ce que donnerait un simple  $2/n_{\text{entrée}}$  sans le facteur 2 au numérateur, précisément pour compenser les sorties annulées par ReLU.




### Correction — Exercice 2

- (a) Moyenne =  $(45\,000 + 52\,000 + 38\,000 + 61\,000 + 47\,000)/5 = 243\,000/5 = 48\,600$ . Écart-type  $\approx 7\,657,68$ .  
(b)  $z = (55\,000 - 48\,600)/7\,657,68 \approx 0,8358$ .  
(c) Avec les deux observations de test ajoutées, sur huit valeurs : nouvelle moyenne  $\approx 61\,142,86$ , nouvel écart-type  $\approx 20\,904,06$ . Nouveau  $z = (55\,000 - 61\,142,86)/20\,904,06 \approx -0,2939$ . L'écart entre les deux valeurs de  $z$  est d'environ **1,13** écart-type, et le **signe change** ( $+0,84$  contre  $-0,29$ ) : la même observation passe d'« au-dessus de la moyenne » à « en-dessous de la moyenne » selon que l'on inclut ou non le test dans le calcul. C'est une fuite au sens du chapitre : les statistiques de normalisation ne doivent être calculées que sur l'apprentissage, faute de quoi l'information du test « contamine » silencieusement le prétraitement, et l'évaluation qui suivra ne mesurera plus la performance dans des conditions réalistes.



### Correction — Exercice 3


- (a) Moyenne =  $(2 + 4 + 6 + 8)/4 = 5$ . Écart-type  $\approx 2,2361$ .  
(b) Normalisées :  $(2 - 5)/2,2361 \approx -1,3416$  ;  $(4 - 5)/2,2361 \approx -0,4472$  ;  $(6 - 5)/2,2361 \approx 0,4472$  ;  $(8 - 5)/2,2361 \approx 1,3416$ .  
(c) Avec  $\gamma = 1,5$ ,  $\beta = 0,5$  :  $1,5 \times (-1,3416) + 0,5 \approx -1,5125$  ;  $1,5 \times (-0,4472) + 0,5 \approx -0,1708$  ;  $1,5 \times 0,4472 + 0,5 \approx 1,1708$  ;  $1,5 \times 1,3416 + 0,5 \approx 2,5125$ .



## 2 Exercices cumulatifs (chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

### Correction — Exercice 4

- (a) Couche 1 ( $n_{\text{entrée}} = 20$ ) : variance He =  $2/20 = 0,1$ . Couche 2 ( $n_{\text{entrée}} = 32$ ) : variance He =  $2/32 = 0,0625$ .
- (b)  $\text{Var}(z_1) = 20 \times 0,1 \times 1 = 2$ .  $\text{Var}(a_1) = 0,5 \times 2 = 1$ .  $\text{Var}(z_2) = 32 \times 0,0625 \times 1 = 2$ .  $\text{Var}(a_2) = 0,5 \times 2 = 1$ .
- (c) La variance de la pré-activation est **exactement identique** d'une couche à l'autre :  $\text{Var}(z_1) = \text{Var}(z_2) = 2$ , et de même  $\text{Var}(a_1) = \text{Var}(a_2) = 1$ , retrouvant la variance unitaire de l'entrée standardisée. Ce résultat est **distinct** du problème de gradient étudié au chapitre 4 : il porte sur l'échelle des **activations** lors de la passe avant, non sur l'atténuation du **gradient** lors de la passe arrière. Mais les deux phénomènes sont liés par une cause commune : si les activations explosaient ou s'effondraient couche après couche (variance non préservée), les neurones se retrouveraient soit saturés soit constamment nuls, ce qui aggraverait précisément l'évanouissement ou l'explosion du gradient au retour. En préservant la variance dès l'initialisation, He met le réseau dans un régime où ni les activations ni, en conséquence, les gradients ne partent dans des valeurs extrêmes dès les premières passes.



## 3 Applications en sciences économiques

### Correction — Exercice 5

- (a) Moyenne =  $(120\,000 + 95\,000 + 150\,000 + 88\,000 + 110\,000 + 135\,000)/6 \approx 116\,333,33$ . Écart-type  $\approx 21\,576,74$ .
- (b) Avec les deux dossiers de test ajoutés, sur huit observations : nouvelle moyenne = **144 750**, nouvel écart-type  $\approx 52\,883,72$ .
- (c) Avec les statistiques correctes :  $z = (130\,000 - 116\,333,33)/21\,576,74 \approx 0,6334$ . Avec les statistiques polluées :  $z = (130\,000 - 144\,750)/52\,883,72 \approx -0,2789$ . Le signe **change** : le même dossier passe d'un profil « au-dessus de la moyenne » à « en-dessous de la moyenne ». Un modèle qui déciderait sur la base d'un seuil sur  $z$  (par exemple « accorder le crédit si  $z > 0$  ») prendrait une décision **opposée** selon que la fuite s'est produite ou non – une illustration concrète et à fort enjeu de la mise en garde du chapitre.

## Correction — Exercice 6

- (a) Moyenne =  $(30 + 45 + 60 + 25 + 40)/5 = 40$ . Écart-type  $\approx 12,2474$ .
- (b) Normalisées :  $(30-40)/12,2474 \approx -0,8165$ ;  $(45-40)/12,2474 \approx 0,4082$ ;  $(60-40)/12,2474 \approx 1,6330$ ;  $(25-40)/12,2474 \approx -1,2247$ ;  $(40-40)/12,2474 = 0$ .
- (c) Avec  $\gamma = 0,8$ ,  $\beta = -0,2$  :  $-0,8532$ ;  $0,1266$ ;  $1,1064$ ;  $-1,1798$ ;  $-0,2$ . Avec un lot de taille 1 à l'inférence, la moyenne et l'écart-type du lot seraient calculés sur une **seule** observation : l'écart-type serait nul (ou indéfini), et la normalisation par lot deviendrait impossible ou absurde – la prédiction d'une semaine isolée dépendrait, de façon incohérente, des autres semaines qui se trouveraient par hasard dans le même lot. Le chapitre recommande précisément d'utiliser, à l'inférence, des **moyennes accumulées pendant l'entraînement** plutôt que les statistiques du lot courant, pour que chaque prédiction reste indépendante des autres observations traitées en même temps.