

Chapitre 11

Ce que l'apprentissage profond ne résout pas

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Correction — Exercice 1

- (a) Groupe à 0,30 : taux réalisé = $200/500 = 0,40$. Groupe à 0,70 : taux réalisé = $250/300 \approx 0,8333$.
- (b) Groupe à 0,30 : écart = $0,40 - 0,30 = 0,10$. Groupe à 0,70 : écart = $0,8333 - 0,70 \approx 0,1333$.
- (c) Dans les deux groupes, le taux **réalisé dépasse** la probabilité **prédite** : le modèle est **sous-confiant sur le risque** (il annonce moins de défauts qu'il n'en survient réellement), ce qui revient à être **sur-confiant sur la sécurité** des dossiers. Cette miscalibration est sérieuse au-delà du seul classement des dossiers : les probabilités prédites alimentent directement des calculs de provisionnement (combien de pertes anticiper, combien de capital réserver) ; une sous-estimation systématique du risque conduit à un provisionnement insuffisant, avec des conséquences financières concrètes indépendantes de la capacité du modèle à bien ordonner les dossiers les uns par rapport aux autres.




Correction — Exercice 2

- (a) (1) Base tabulaire de 3 500 dossiers, variables hétérogènes : **boosting** (tabulaire, quelques milliers de lignes). (2) 2 millions d'images étiquetées : **réseaux profonds** (image, données non structurées, volume massif). (3) Série quotidienne unique de taux de change sur 15 ans : **ARMA, GARCH** (série unique, quotidienne). (4) Refus de prêt à motiver : **modèle linéaire ou arbre** (décision à motiver).
- (b) La seule situation où le tableau recommande l'apprentissage profond est la situation (2), les images médicales.
- (c) La contrainte est réglementaire, non technique, parce qu'elle ne porte pas sur la **performance** du modèle (un réseau pourrait très bien prédire mieux) mais sur l'**obligation légale** de motiver une décision de refus devant le client et le superviseur : un modèle inexplicable, même excellent, peut être juridiquement inutilisable pour ce type de décision, indépendamment de sa qualité prédictive.

Correction — Exercice 3

- (a) Taux réalisé = $96/800 = 0,12$.
- (b) Écart = $0,12 - 0,15 = -0,03$.
- (c) Cet écart, de seulement 3 points de pourcentage et de signe opposé aux deux groupes de l'exercice 1, est **beaucoup plus proche de zéro** : ce modèle est ici raisonnablement bien calibré, bien qu'il surestime légèrement le risque de sinistre (probabilité prédite légèrement supérieure au taux réalisé).




2 Exercices cumulatifs (bilan du cours complet)

Correction — Exercice 4

(a) Chapitre 1 : le réseau 20-32-16-1 compte **1 217** paramètres. Chapitre 2 : la dérivée maximale de la sigmoïde vaut **0,25**, et le facteur de gradient après 10 couches vaut $9,5 \times 10^{-7}$. Chapitre 3 : sur $L(w) = w^2$, $\eta = 0,1$ **converge**, $\eta = 1,1$ **diverge**.

(b) $1\,000\,100/320 = 3\,125,3$, soit très exactement les « trois mille cent vingt-cinq fois moins » annoncés au chapitre 7 (l'arrondi de 3 125,3 à l'entier le plus proche donnant 3 125).

(c) Non. Selon le tableau de ce chapitre, une **série unique et quotidienne** appelle un modèle **ARMA ou GARCH**, et le chapitre 10 a explicitement établi que le GARCH restait compétitif face à des architectures bien plus lourdes pour ce type de série, à une fraction infime du coût de calcul et avec une interprétabilité que le réseau n'offre pas. Le réseau à 1 217 paramètres du chapitre 1 n'était donc, avec le recul de tout le cours, **pas** la méthode que ce tableau aurait recommandée pour son propre scénario fil rouge. Son rôle véritable était **pédagogique** : servir de fil conducteur concret pour illustrer, chapitre après chapitre, le comptage des paramètres, le calcul du gradient, la descente, la régularisation, l'initialisation et les architectures spécialisées – sans jamais prétendre être la solution recommandée pour ce cas d'usage précis. C'est exactement la conclusion à laquelle menait déjà l'exercice cumulatif du chapitre 10.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Rapport = $8\,000/4\,000 = 2,0$: deux paramètres pour chaque police disponible.

(b) Ce rapport élevé (bien au-delà de 1) et la nature **tabulaire** des données plaident nettement pour le **boosting**, conformément au tableau du chapitre : les données tabulaires de quelques milliers de lignes sont précisément le domaine où le boosting domine, et un réseau de ce rapport paramètres/observations risquerait le sur-ajustement identifié depuis le chapitre 1.

(c) Cette contrainte **renforcerait** encore davantage l'argument en faveur du boosting, voire d'un modèle encore plus simple (arbre unique, modèle linéaire) : au-delà de l'argument de performance et de volume de données, l'obligation réglementaire de motiver un refus devant le client ajoute une seconde raison, indépendante, d'écarter un réseau de neurones, dont l'opacité (chapitre 11) le rendrait potentiellement inutilisable pour ce type de décision quelle que soit sa performance.

Correction — Exercice 6

(a) $10 \times 252 = 2\,520$ points environ.

(b) Rapport = $2\,520/5\,000 = 0,504$: la banque centrale dispose d'environ la **moitié** du volume déjà jugé infime pour un transformeur.

(c) Le tableau recommande ici **ARMA ou GARCH**, exactement comme pour la série financière fil rouge du cours (exercice 4). Cette conclusion **changerait** si la banque centrale disposait de plusieurs centaines de paires de devises modélisées **conjointement à haute fréquence** : le tableau recommande alors les **réseaux**, précisément parce que « beaucoup de séries à la fois » et « haute fréquence » figurent

parmi les quatre situations où les réseaux apportent un avantage réel (chapitre 10) – ce n'est donc pas la nature du problème (prévoir un taux de change) qui change la recommandation, mais le volume et la structure des données disponibles, exactement le second des trois principes retenus par ce chapitre.