

Apprentissage profond

Chapitre 11 : Ce que l'apprentissage profond ne résout pas

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Mesurer une mauvaise calibration

Un modèle de scoring de crédit prédit une probabilité de défaut de 0,30 pour 500 dossiers ; parmi eux, 200 ont réellement fait défaut. Pour un second groupe de 300 dossiers, il prédit 0,70 ; parmi eux, 250 ont réellement fait défaut.

- (a) Calculer le taux de défaut réalisé dans chacun des deux groupes.
- (b) Calculer l'écart entre le taux réalisé et la probabilité prédite, pour chacun des deux groupes.
- (c) Le modèle est-il sur-confiant ou sous-confiant sur ces deux groupes (compare-t-il le risque réel à un niveau supérieur ou inférieur à ce qu'il annonce) ? Pourquoi une telle miscalibration est-elle un problème sérieux en crédit, au-delà de la seule qualité de classement du modèle ?

Exercice 2 — Appliquer le tableau de décision

Pour chacune des quatre situations suivantes, indiquer la méthode recommandée par le tableau du chapitre, et justifier en une phrase : (1) une base de 3 500 dossiers clients avec 40 variables hétérogènes ; (2) une base de 2 millions d'images médicales étiquetées ; (3) une série quotidienne unique de taux de change sur 15 ans ; (4) une décision de refus de prêt qui doit être motivée devant un client et un superviseur.

- (a) Identifier la méthode recommandée pour chacune des quatre situations.
- (b) Laquelle de ces quatre situations est la seule où l'apprentissage profond est le choix recommandé par le tableau ?
- (c) Pour la situation (4), pourquoi la contrainte est-elle qualifiée de « réglementaire, non technique » plutôt que de simple préférence de modélisation ?

Exercice 3 — Un second cas de calibration, sur l'assurance

Un modèle d'assurance prédit une probabilité de sinistre de 0,15 pour 800 contrats ; parmi eux, 96 sinistres sont réellement survenus.

- (a) Calculer le taux de sinistre réalisé.
- (b) Calculer l'écart avec la probabilité prédite.
- (c) Le modèle est-il ici sur-confiant ou bien correctement calibré (à un écart proche de zéro près) ?

2 Exercices cumulatifs (bilan du cours complet)

Exercice 4 — Le fil rouge chiffré du cours, reconstitué

Le tableau du chapitre reprend les chiffres marquants du cours. En reprenant la numérotation **actuelle** des chapitres (chapitre 1 : le perceptron multicouche ; chapitre 2 : pertes et activations ; chapitre 3 : la descente de gradient ; chapitre 7 : les réseaux convolutifs) :

- (a) Rappeler, sans recalcul, les quatre valeurs officielles suivantes établies au fil du cours : le nombre de paramètres du réseau 20-32-16-1 (chapitre 1) ; la dérivée maximale de la sigmoïde et le facteur de gradient après 10 couches (chapitre 2) ; le verdict de convergence pour $\eta = 0,1$ contre $\eta = 1,1$ sur $L(w) = w^2$ (chapitre 3).
- (b) Le chapitre 7 comparait 1 000 100 paramètres (couche dense) à 320 paramètres (couche convolutive) pour une image de 100×100 . Calculer le rapport exact entre ces deux nombres, et vérifier qu'il est cohérent avec l'affirmation du chapitre 7 (« trois mille cent vingt-cinq fois moins »).
- (c) Le fil rouge du cours porte sur une série financière quotidienne unique. En s'appuyant sur le tableau de décision de ce chapitre et sur le verdict du chapitre 10 (GARCH compétitif sur ce

type de série), le réseau à 1 217 paramètres du chapitre 1 était-il, avec le recul de tout le cours, la méthode que ce même tableau aurait recommandée pour ce scénario précis ? Quel était alors, plus vraisemblablement, le rôle de ce réseau dans le cours ?

3 Applications en sciences économiques

Exercice 5 — Choisir une méthode pour un assureur

Un assureur dispose de 4 000 polices avec des variables hétérogènes (âge, historique de sinistres, type de contrat, zone géographique), et envisage soit un réseau de neurones à 8 000 paramètres, soit un modèle de boosting de gradient.

- (a) Calculer le rapport entre le nombre de paramètres du réseau envisagé et le nombre de polices disponibles.
- (b) Ce rapport, et la nature tabulaire des données, plaident-ils pour le réseau ou pour le boosting, selon le tableau du chapitre ?
- (c) Si l'assureur devait justifier un refus de couverture auprès d'un client, cette contrainte renforcerait-elle ou affaiblirait-elle l'argument en faveur du boosting (ou d'un modèle encore plus simple) ?

Exercice 6 — Une banque centrale face à une série de taux de change


Une banque centrale dispose de 10 années de cours quotidiens d'une paire de devises (environ 252 séances par an).

- (a) Calculer le nombre approximatif de points de cette série.
- (b) Comparer ce nombre au seuil de 5 000 points déjà jugé « infime » pour un transformeur (chapitre 9). Calculer le rapport correspondant.
- (c) En s'appuyant sur le tableau de décision de ce chapitre, quelle famille de méthodes serait recommandée ici ? Cette conclusion serait-elle différente si la banque centrale disposait, à la place, de plusieurs centaines de paires de devises à modéliser conjointement à haute fréquence ?

1 Exercices du chapitre

Correction — Exercice 1

- (a) Groupe à 0,30 : taux réalisé = $200/500 = 0,40$. Groupe à 0,70 : taux réalisé = $250/300 \approx 0,8333$.
- (b) Groupe à 0,30 : écart = $0,40 - 0,30 = 0,10$. Groupe à 0,70 : écart = $0,8333 - 0,70 \approx 0,1333$.
- (c) Dans les deux groupes, le taux **réalisé dépasse** la probabilité **prédite** : le modèle est **sous-confiant sur le risque** (il annonce moins de défauts qu'il n'en survient réellement), ce qui revient à être **sur-confiant sur la sécurité** des dossiers. Cette miscalibration est sérieuse au-delà du seul classement des dossiers : les probabilités prédites alimentent directement des calculs de provisionnement (combien de pertes anticiper, combien de capital réserver) ; une sous-estimation systématique du risque conduit à un provisionnement insuffisant, avec des conséquences financières concrètes indépendantes de la capacité du modèle à bien ordonner les dossiers les uns par rapport aux autres.




Correction — Exercice 2

- (a) (1) Base tabulaire de 3 500 dossiers, variables hétérogènes : **boosting** (tabulaire, quelques milliers de lignes). (2) 2 millions d'images étiquetées : **réseaux profonds** (image, données non structurées, volume massif). (3) Série quotidienne unique de taux de change sur 15 ans : **ARMA, GARCH** (série unique, quotidienne). (4) Refus de prêt à motiver : **modèle linéaire ou arbre** (décision à motiver).
- (b) La seule situation où le tableau recommande l'apprentissage profond est la situation (2), les images médicales.
- (c) La contrainte est réglementaire, non technique, parce qu'elle ne porte pas sur la **performance** du modèle (un réseau pourrait très bien prédire mieux) mais sur l'**obligation légale** de motiver une décision de refus devant le client et le superviseur : un modèle inexplicable, même excellent, peut être juridiquement inutilisable pour ce type de décision, indépendamment de sa qualité prédictive.

Correction — Exercice 3

- (a) Taux réalisé = $96/800 = 0,12$.
- (b) Écart = $0,12 - 0,15 = -0,03$.
- (c) Cet écart, de seulement 3 points de pourcentage et de signe opposé aux deux groupes de l'exercice 1, est **beaucoup plus proche de zéro** : ce modèle est ici raisonnablement bien calibré, bien qu'il surestime légèrement le risque de sinistre (probabilité prédite légèrement supérieure au taux réalisé).




2 Exercices cumulatifs (bilan du cours complet)

Correction — Exercice 4

(a) Chapitre 1 : le réseau 20-32-16-1 compte **1 217** paramètres. Chapitre 2 : la dérivée maximale de la sigmoïde vaut **0,25**, et le facteur de gradient après 10 couches vaut $9,5 \times 10^{-7}$. Chapitre 3 : sur $L(w) = w^2$, $\eta = 0,1$ **converge**, $\eta = 1,1$ **diverge**.

(b) $1\,000\,100/320 = 3\,125,3$, soit très exactement les « trois mille cent vingt-cinq fois moins » annoncés au chapitre 7 (l'arrondi de 3 125,3 à l'entier le plus proche donnant 3 125).

(c) Non. Selon le tableau de ce chapitre, une **série unique et quotidienne** appelle un modèle **ARMA ou GARCH**, et le chapitre 10 a explicitement établi que le GARCH restait compétitif face à des architectures bien plus lourdes pour ce type de série, à une fraction infime du coût de calcul et avec une interprétabilité que le réseau n'offre pas. Le réseau à 1 217 paramètres du chapitre 1 n'était donc, avec le recul de tout le cours, **pas** la méthode que ce tableau aurait recommandée pour son propre scénario fil rouge. Son rôle véritable était **pédagogique** : servir de fil conducteur concret pour illustrer, chapitre après chapitre, le comptage des paramètres, le calcul du gradient, la descente, la régularisation, l'initialisation et les architectures spécialisées – sans jamais prétendre être la solution recommandée pour ce cas d'usage précis. C'est exactement la conclusion à laquelle menait déjà l'exercice cumulatif du chapitre 10.



3 Applications en sciences économiques

Correction — Exercice 5

(a) Rapport = $8\,000/4\,000 = 2,0$: deux paramètres pour chaque police disponible.

(b) Ce rapport élevé (bien au-delà de 1) et la nature **tabulaire** des données plaident nettement pour le **boosting**, conformément au tableau du chapitre : les données tabulaires de quelques milliers de lignes sont précisément le domaine où le boosting domine, et un réseau de ce rapport paramètres/observations risquerait le sur-ajustement identifié depuis le chapitre 1.

(c) Cette contrainte **renforcerait** encore davantage l'argument en faveur du boosting, voire d'un modèle encore plus simple (arbre unique, modèle linéaire) : au-delà de l'argument de performance et de volume de données, l'obligation réglementaire de motiver un refus devant le client ajoute une seconde raison, indépendante, d'écarter un réseau de neurones, dont l'opacité (chapitre 11) le rendrait potentiellement inutilisable pour ce type de décision quelle que soit sa performance.

Correction — Exercice 6

(a) $10 \times 252 = 2\,520$ points environ.

(b) Rapport = $2\,520/5\,000 = 0,504$: la banque centrale dispose d'environ la **moitié** du volume déjà jugé infime pour un transformeur.

(c) Le tableau recommande ici **ARMA ou GARCH**, exactement comme pour la série financière fil rouge du cours (exercice 4). Cette conclusion **changerait** si la banque centrale disposait de plusieurs centaines de paires de devises modélisées **conjointement à haute fréquence** : le tableau recommande alors les **réseaux**, précisément parce que « beaucoup de séries à la fois » et « haute fréquence » figurent

parmi les quatre situations où les réseaux apportent un avantage réel (chapitre 10) – ce n'est donc pas la nature du problème (prévoir un taux de change) qui change la recommandation, mais le volume et la structure des données disponibles, exactement le second des trois principes retenus par ce chapitre.