

Chapitre 1

Le perceptron multicouche

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) $15 \rightarrow 24 : 15 \times 24 + 24 = 360 + 24 = 384$. $24 \rightarrow 8 : 24 \times 8 + 8 = 192 + 8 = 200$. $8 \rightarrow 1 : 8 \times 1 + 1 = 9$.
(b) Total = $384 + 200 + 9 = 593$ paramètres.
(c) Rapport = $593/16 \approx 37,1$: le réseau compte environ 37 fois plus de paramètres que la régression linéaire équivalente.




Correction — Exercice 2

- (a) $e^{1,5} \approx 4,4817$; $e^{0,5} \approx 1,6487$; $e^{-1,0} \approx 0,3679$.
(b) Somme des exponentielles $\approx 6,4983$. Probabilités : $4,4817/6,4983 \approx 0,6897$; $1,6487/6,4983 \approx 0,2537$; $0,3679/6,4983 \approx 0,0566$.
(c) Somme = $0,6897 + 0,2537 + 0,0566 = 1,0000$ ✓. Rapport des probabilités = $0,6897/0,2537 \approx 2,72$, alors que l'écart des scores bruts n'est que de $1,5 - 0,5 = 1$ (soit un rapport de 3 en exponentielle directe, $e^1 \approx 2,72$) : oui, la probabilité du score le plus élevé est bien plus de deux fois supérieure à celle du score suivant, illustrant l'amplification opérée par le softmax.



Correction — Exercice 3


- (a) Régression : $h + 1 = 20 + 1 = 21$ paramètres.
(b) Classification à $K = 5$: $h \times K + K = 20 \times 5 + 5 = 105$ paramètres.
(c) En classification, chaque classe supplémentaire nécessite son **propre** vecteur de poids (un pour chaque neurone de sortie), d'où une croissance de $h + 1$ paramètre par classe ajoutée. En régression, il n'existe qu'un **seul** neurone de sortie, quel que soit le problème : le nombre de paramètres de cette dernière couche reste donc fixé à $h + 1$, indépendamment de toute considération sur le nombre de catégories, puisqu'il n'y en a pas.



2 Exercices cumulatifs (chapitre 1 et introduction)

Correction — Exercice 4


- (a) $(20 + 1)H + (H + 1) = 1\,217 \Leftrightarrow 22H + 1 = 1\,217 \Leftrightarrow H = 1\,216/22 \approx 55,27$, arrondi à **H = 55**.
- (b) Paramètres exacts = $(20 + 1) \times 55 + (55 + 1) \times 1 = 1\,155 + 56 = \mathbf{1\,211}$ – très proche des 1 217 paramètres du réseau officiel.
- (c) Non, le réseau large trouvé n'échappe pas au problème : avec 1 211 paramètres, il dépasse lui aussi les 1 000 observations disponibles, presque autant que le réseau profond officiel (1 217). Cela confirme, comme annoncé dans l'introduction, que ce n'est pas la **forme** de l'architecture (large ou profonde) qui détermine si l'on se trouve dans le régime où les paramètres excèdent les données, mais bien le nombre **total** de paramètres visé pour une capacité de représentation donnée. Dans les deux cas, le modèle risque de **mémoriser** plutôt que de généraliser, sauf à recourir à une forme de régularisation ou à disposer de davantage de données.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $e^{1,8} \approx 6,0496$; $e^{0,9} \approx 2,4596$; $e^{-0,2} \approx 0,8187$; $e^{-1,5} \approx 0,2231$.
- (b) Somme $\approx 9,5510$. Probabilités : **0,6334**; **0,2575**; **0,0857**; **0,0234**. Somme = $0,6334 + 0,2575 + 0,0857 + 0,0234 = 1,0000$ ✓.
- (c) Rapport des probabilités = $0,6334/0,2575 \approx \mathbf{2,46}$, contre un rapport des scores bruts de $1,8/0,9 = 2$. Le rapport des probabilités est bien supérieur à celui des scores bruts : le softmax **amplifie** l'écart entre le régime le plus probable et les autres, exactement comme le montre l'exemple du chapitre sur les trois régimes de marché.



Correction — Exercice 6

- (a) $12 \rightarrow 40 : 12 \times 40 + 40 = 480 + 40 = 520$. $40 \rightarrow 1 : 40 + 1 = 41$. Total = $520 + 41 = 561$ paramètres.
- (b) Rapport = $561/60 \approx 9,35$ paramètres par observation.
- (c) Ce rapport n'est absolument pas compatible avec un entraînement raisonnable : avec plus de neuf paramètres pour chaque trimestre observé, le réseau est en mesure de mémoriser exactement les 60 observations sans avoir rien appris de généralisable. Compte tenu du premier réflexe de prudence rappelé dans le chapitre – compter les paramètres avant d'entraîner –, la PME devrait envisager un réseau beaucoup plus petit (une couche cachée de quelques neurones seulement), voire renoncer à un réseau de neurones au profit d'un modèle bien plus parcimonieux, adapté à un historique aussi court.