

Apprentissage profond

Chapitre 1 : Le perceptron multicouche

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Compter les paramètres d’une architecture

Un réseau enchaîne 15 variables d’entrée, une couche cachée de 24 neurones, une seconde couche cachée de 8 neurones, et une sortie unique.

- (a) Calculer le nombre de paramètres de chacune des trois couches ($15 \rightarrow 24$, $24 \rightarrow 8$, $8 \rightarrow 1$).
- (b) Calculer le nombre total de paramètres du réseau.
- (c) Une régression linéaire sur les mêmes 15 variables compterait 16 paramètres (coefficients + constante). Calculer le rapport entre le nombre de paramètres du réseau et celui de la régression linéaire.

Exercice 2 — Calculer une sortie softmax

Une couche de sortie à trois classes produit les scores 1,5; 0,5; -1,0.

- (a) Calculer e^{z_k} pour chacun des trois scores.
- (b) Calculer les probabilités softmax correspondantes.
- (c) Vérifier que leur somme vaut 1. Le score le plus élevé produit-il une probabilité plus de deux fois supérieure au score immédiatement inférieur ?

Exercice 3 — Adapter la couche de sortie à la tâche

On dispose d’une dernière couche cachée de largeur $h = 20$.

- (a) Calculer le nombre de paramètres de la couche de sortie pour une tâche de **régression** (un seul neurone de sortie, sans activation).
- (b) Calculer le nombre de paramètres de la couche de sortie pour une classification à $K = 5$ classes (activation softmax).
- (c) Pourquoi le nombre de paramètres de la couche de sortie croît-il linéairement avec le nombre de classes K en classification, alors qu’il reste fixe (égal à $h + 1$) en régression, quel que soit le problème ?

2 Exercices cumulatifs (chapitre 1 et introduction)

Exercice 4 — Trouver un réseau large équivalent au réseau officiel du chapitre (introduction)

Le réseau officiel du chapitre, pour la série financière à 20 indicateurs, a l’architecture $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$ et compte 1 217 paramètres.

- (a) On cherche un réseau à **une seule** couche cachée de largeur H , avec les mêmes 20 entrées et une sortie unique, comptant approximativement le même nombre total de paramètres. Sachant que ce réseau compte $(20 + 1)H + (H + 1)$ paramètres, résoudre $(20 + 1)H + (H + 1) = 1\,217$ pour H , et arrondir à l’entier le plus proche.
- (b) Calculer le nombre exact de paramètres du réseau large ainsi obtenu.
- (c) Le chapitre rappelle que, avec 1 000 observations disponibles, le réseau officiel (1 217 paramètres) comporte déjà plus de paramètres que de données. Le réseau large trouvé en (b) échappe-t-il à ce problème ? Quelle conséquence, déjà annoncée dans l’introduction, cela a-t-il sur la capacité du modèle à généraliser sans précaution supplémentaire ?

3 Applications en sciences économiques

Exercice 5 — Classer un régime de marché à quatre états

Une société de gestion d'actifs classe chaque séance boursière en quatre régimes. La couche de sortie produit les scores $1,8; 0,9; -0,2; -1,5$.

- (a) Calculer e^{z_k} pour chacun des quatre scores.
- (b) Calculer les quatre probabilités softmax, et vérifier que leur somme vaut 1.
- (c) Calculer le rapport entre la probabilité du régime le plus probable et celle du second. Ce rapport est-il supérieur au rapport des scores bruts correspondants ($1,8/0,9 = 2$) ? Que cela illustre-t-il sur le softmax ?

Exercice 6 — Dimensionner un réseau avec peu d'historique


Une PME veut prévoir son chiffre d'affaires trimestriel à partir de 12 variables, avec une couche cachée de 40 neurones et une sortie unique. Elle ne dispose que de 60 trimestres d'historique.

- (a) Calculer le nombre de paramètres de chacune des deux couches, puis le total.
- (b) Calculer le rapport entre le nombre de paramètres et le nombre d'observations disponibles.
- (c) Ce rapport est-il compatible avec un entraînement raisonnable de ce réseau ? Quel type d'architecture, ou quelle précaution, faudrait-il envisager compte tenu du premier réflexe de prudence rappelé dans le chapitre ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $15 \rightarrow 24 : 15 \times 24 + 24 = 360 + 24 = 384$. $24 \rightarrow 8 : 24 \times 8 + 8 = 192 + 8 = 200$. $8 \rightarrow 1 : 8 \times 1 + 1 = 9$.
(b) Total = $384 + 200 + 9 = 593$ paramètres.
(c) Rapport = $593/16 \approx 37,1$: le réseau compte environ 37 fois plus de paramètres que la régression linéaire équivalente.




Correction — Exercice 2

- (a) $e^{1,5} \approx 4,4817$; $e^{0,5} \approx 1,6487$; $e^{-1,0} \approx 0,3679$.
(b) Somme des exponentielles $\approx 6,4983$. Probabilités : $4,4817/6,4983 \approx 0,6897$; $1,6487/6,4983 \approx 0,2537$; $0,3679/6,4983 \approx 0,0566$.
(c) Somme = $0,6897 + 0,2537 + 0,0566 = 1,0000$ ✓. Rapport des probabilités = $0,6897/0,2537 \approx 2,72$, alors que l'écart des scores bruts n'est que de $1,5 - 0,5 = 1$ (soit un rapport de 3 en exponentielle directe, $e^1 \approx 2,72$) : oui, la probabilité du score le plus élevé est bien plus de deux fois supérieure à celle du score suivant, illustrant l'amplification opérée par le softmax.



Correction — Exercice 3


- (a) Régression : $h + 1 = 20 + 1 = 21$ paramètres.
(b) Classification à $K = 5$: $h \times K + K = 20 \times 5 + 5 = 105$ paramètres.
(c) En classification, chaque classe supplémentaire nécessite son **propre** vecteur de poids (un pour chaque neurone de sortie), d'où une croissance de $h + 1$ paramètre par classe ajoutée. En régression, il n'existe qu'un **seul** neurone de sortie, quel que soit le problème : le nombre de paramètres de cette dernière couche reste donc fixé à $h + 1$, indépendamment de toute considération sur le nombre de catégories, puisqu'il n'y en a pas.



2 Exercices cumulatifs (chapitre 1 et introduction)

Correction — Exercice 4


- (a) $(20 + 1)H + (H + 1) = 1\,217 \Leftrightarrow 22H + 1 = 1\,217 \Leftrightarrow H = 1\,216/22 \approx 55,27$, arrondi à **H = 55**.
- (b) Paramètres exacts = $(20 + 1) \times 55 + (55 + 1) \times 1 = 1\,155 + 56 = \mathbf{1\,211}$ – très proche des 1 217 paramètres du réseau officiel.
- (c) Non, le réseau large trouvé n'échappe pas au problème : avec 1 211 paramètres, il dépasse lui aussi les 1 000 observations disponibles, presque autant que le réseau profond officiel (1 217). Cela confirme, comme annoncé dans l'introduction, que ce n'est pas la **forme** de l'architecture (large ou profonde) qui détermine si l'on se trouve dans le régime où les paramètres excèdent les données, mais bien le nombre **total** de paramètres visé pour une capacité de représentation donnée. Dans les deux cas, le modèle risque de **mémoriser** plutôt que de généraliser, sauf à recourir à une forme de régularisation ou à disposer de davantage de données.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $e^{1,8} \approx 6,0496$; $e^{0,9} \approx 2,4596$; $e^{-0,2} \approx 0,8187$; $e^{-1,5} \approx 0,2231$.
- (b) Somme $\approx 9,5510$. Probabilités : **0,6334**; **0,2575**; **0,0857**; **0,0234**. Somme = $0,6334 + 0,2575 + 0,0857 + 0,0234 = 1,0000$ ✓.
- (c) Rapport des probabilités = $0,6334/0,2575 \approx \mathbf{2,46}$, contre un rapport des scores bruts de $1,8/0,9 = \mathbf{2}$. Le rapport des probabilités est bien supérieur à celui des scores bruts : le softmax **amplifie** l'écart entre le régime le plus probable et les autres, exactement comme le montre l'exemple du chapitre sur les trois régimes de marché.



Correction — Exercice 6

- (a) $12 \rightarrow 40 : 12 \times 40 + 40 = 480 + 40 = 520$. $40 \rightarrow 1 : 40 + 1 = 41$. Total = $520 + 41 = 561$ paramètres.
- (b) Rapport = $561/60 \approx 9,35$ paramètres par observation.
- (c) Ce rapport n'est absolument pas compatible avec un entraînement raisonnable : avec plus de neuf paramètres pour chaque trimestre observé, le réseau est en mesure de mémoriser exactement les 60 observations sans avoir rien appris de généralisable. Compte tenu du premier réflexe de prudence rappelé dans le chapitre – compter les paramètres avant d'entraîner –, la PME devrait envisager un réseau beaucoup plus petit (une couche cachée de quelques neurones seulement), voire renoncer à un réseau de neurones au profit d'un modèle bien plus parcimonieux, adapté à un historique aussi court.