

Chapitre 2

Fonctions de perte et d'activation

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Correction — Exercice 1

(a) Observation 1 ($y = 1, \hat{p} = 0,9$) : $-\ln(0,9) \approx 0,1054$. Observation 2 ($y = 0, \hat{p} = 0,2$) : $-\ln(0,8) \approx 0,2231$. Observation 3 ($y = 1, \hat{p} = 0,6$) : $-\ln(0,6) \approx 0,5108$. Observation 4 ($y = 0, \hat{p} = 0,05$) : $-\ln(0,95) \approx 0,0513$.

(b) Perte moyenne = $(0,1054 + 0,2231 + 0,5108 + 0,0513)/4 \approx 0,2227$.

(c) L'observation 3 contribue le plus (0,5108). C'est cohérent : $\hat{p} = 0,6$ pour $y = 1$ est la prédiction la moins assurée du lot dans le bon sens (proche de 0,5), donc celle qui reflète le plus d'incertitude résiduelle, tandis que les observations 1, 2 et 4 sont toutes confiantes et correctes.




Correction — Exercice 2

(a) $z = -2$: $\sigma \approx 0,1192, \sigma' \approx 0,1050$. $z = 0$: $\sigma = 0,5, \sigma' = 0,2500$. $z = 1$: $\sigma \approx 0,7311, \sigma' \approx 0,1966$. $z = 3$: $\sigma \approx 0,9526, \sigma' \approx 0,0452$.

(b) La dérivée la plus élevée est obtenue en $z = 0$ (0,25). C'est cohérent : le chapitre rappelle que la dérivée de la sigmoïde est maximale en $z = 0$, où elle atteint précisément 0,25.

(c) Lorsque z s'éloigne fortement de 0 (positivement ou négativement), $\sigma'(z)$ tend vers 0 : la sigmoïde **sature**. Ce phénomène, combiné à la multiplication des dérivées lors de la rétropropagation, porte le nom de **gradient qui s'évanouit** (vanishing gradient).




Correction — Exercice 3

(a) 3 couches : $0,25^3 \approx 1,56 \times 10^{-2}$. 8 couches : $0,25^8 \approx 1,53 \times 10^{-5}$. 15 couches : $0,25^{15} \approx 9,31 \times 10^{-10}$.

(b) Avec ReLU, le facteur au mieux vaut $1^n = 1$ à n'importe quelle profondeur : la dérivée 1 ne diminue rien, quel que soit le nombre de couches.


(c) Non. Avec un facteur d'environ $1,53 \times 10^{-5}$ après 8 couches sigmoïdes, le gradient qui atteint les premières couches est réduit d'un facteur proche de 65 000 : ces couches ne reçoivent plus de signal exploitable et leurs poids ne bougent pratiquement pas. Un tel réseau est, en pratique, inentraînable avec des activations sigmoïdes sur toute sa profondeur.



2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4


- (a) Deux couches cachées sigmoïdes : $0,25^2 = 0,0625$. Au mieux, le gradient qui atteint la première couche cachée est déjà divisé par 16.
- (b) Avec ReLU sur les deux couches : $1^2 = 1$. Aucune atténuation.
- (c) Les deux risques sont bien **distincts et indépendants**. Le premier, identifié au chapitre 1, concerne la **capacité** du modèle : avec 1 217 paramètres pour 1 000 observations, le réseau risque de mémoriser au lieu de généraliser, quelle que soit l'activation choisie – c'est un problème de *variance* lié au surdimensionnement. Le second, propre à ce chapitre, concerne l'**entraînabilité** : avec des sigmoïdes, le gradient qui devrait ajuster les premiers poids du réseau est atténué avant même d'y parvenir – c'est un problème d'*optimisation*, qui empêcherait le réseau d'exploiter pleinement sa capacité, même démesurée. On recommande donc **ReLU** dans les deux couches cachées : cela ne résout pas le premier risque (qui appelle plutôt une régularisation ou davantage de données), mais élimine le second, purement lié au choix de l'activation.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $EQM = (0,5^2 + 0,3^2 + 0,8^2 + 0,4^2 + 6,2^2)/5 \approx 7,9160$. $EAM = (0,5 + 0,3 + 0,8 + 0,4 + 6,2)/5 = 1,6400$.
- (b) Sans la séance de krach : $EQM = (0,5^2 + 0,3^2 + 0,8^2 + 0,4^2)/4 = 0,2850$; $EAM = (0,5 + 0,3 + 0,8 + 0,4)/4 = 0,5000$. Rapport EQM (avec/sans) = $7,9160/0,2850 \approx 27,8$. Rapport EAM (avec/sans) = $1,6400/0,5000 = 3,28$.
- (c) L'EQM est nettement plus sensible à l'observation extrême : elle est multipliée par un facteur 27,8 contre seulement 3,28 pour l'EAM, parce que le carré amplifie les grands écarts alors que la valeur absolue les traite proportionnellement. Pour ce type de série, l'erreur **absolue** est préférable : le chapitre indique explicitement que l'erreur absolue convient mieux aux rendements financiers, dont les queues sont épaisses – un krach occasionnel ne doit pas dominer entièrement l'apprentissage du modèle.



Correction — Exercice 6

- (a) Sigmoides, 6 couches : $0,25^6 \approx 2,44 \times 10^{-4}$. ReLU, 6 couches : $1^6 = 1$. Le facteur sigmoïde est environ 4 100 fois plus petit que celui de ReLU à profondeur égale.
- (b) $-\ln(0,02) \approx 3,9120$, contre $-\ln(0,5) \approx 0,6931$ pour la prédiction non informative. La prédiction confiante et fausse coûte donc environ 5,6 fois plus cher en perte qu'une prédiction neutre.
- (c) Le réseau serait pénalisé sur deux plans indépendants. D'une part, à l'entraînement, l'usage de sigmoïdes sur 6 couches atténuerait le gradient d'un facteur proche de 4 100 par rapport à ReLU, empêchant les premières couches d'apprendre correctement – exactement le problème identifié à la question (a) et illustré à l'exercice 3. D'autre part, une fois le modèle mal entraîné, ses erreurs confiantes – comme celle de la question (b), où $\hat{p} = 0,02$ pour un défaut réel – coûteraient particulièrement cher en entropie croisée, sans que le gradient defectueux permette de les corriger efficacement au fil des itérations. La banque a donc doublement intérêt à préférer ReLU dans les couches cachées de ce réseau profond.