

Apprentissage profond

Chapitre 2 : Fonctions de perte et d'activation

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une entropie croisée

Un modèle de classification binaire produit, sur quatre observations, les prédictions $\hat{p}_i$ suivantes en face des labels y_i observés :

observation	1	2	3	4
y_i	1	0	1	0
$\hat{p}_i$	0,9	0,2	0,6	0,05

- (a) Calculer la perte d'entropie croisée $-[y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)]$ pour chacune des quatre observations.
- (b) Calculer la perte moyenne sur l'échantillon.
- (c) Quelle observation contribue le plus à la perte moyenne ? Est-ce cohérent avec la qualité de la prédiction correspondante ?

Exercice 2 — Dérivée de la sigmoïde

On considère la fonction sigmoïde $\sigma(z) = 1/(1 + e^{-z})$, de dérivée $\sigma(z)(1 - \sigma(z))$.

- (a) Calculer $\sigma(z)$ et $\sigma'(z)$ pour $z = -2$, $z = 0$, $z = 1$ et $z = 3$.
- (b) Parmi ces quatre valeurs, laquelle donne la dérivée la plus élevée ? Est-ce cohérent avec la propriété rappelée dans le chapitre ?
- (c) Que devient $\sigma'(z)$ lorsque z s'éloigne fortement de 0, dans un sens ou dans l'autre ? Quel est le nom de ce phénomène ?

Exercice 3 — Atténuation du gradient selon la profondeur

On suppose que chaque couche cachée d'un réseau utilise la sigmoïde, et que la dérivée locale vaut, au mieux, 0,25 à chaque couche.

- (a) Calculer le facteur multiplicatif au mieux appliqué au gradient après avoir traversé 3 couches, puis 8 couches, puis 15 couches.
- (b) Si les mêmes couches utilisaient ReLU (dérivée 1 pour une entrée positive), quel serait ce facteur, à profondeur égale ?
- (c) Un réseau à 8 couches cachées sigmoïdes est-il raisonnablement entraînable en pratique, au vu du facteur obtenu en (a) ?

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Choisir l'activation du réseau officiel du chapitre 1

Le réseau officiel du chapitre 1, pour la série financière à 20 indicateurs, a l'architecture $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$: il compte donc **deux** couches cachées ($20 \rightarrow 32$ et $32 \rightarrow 16$) avant la couche de sortie, et 1 217 paramètres au total pour 1 000 observations disponibles.

- (a) Si les deux couches cachées utilisent la sigmoïde, calculer le facteur multiplicatif au mieux appliqué au gradient après les avoir traversées.
- (b) Si l'on remplace la sigmoïde par ReLU dans ces deux couches, calculer ce même facteur.
- (c) Le chapitre 1 avait déjà identifié un premier risque pour ce réseau, lié au rapport entre son nombre de paramètres et le nombre d'observations. En quoi le choix de l'activation ajoute-t-il, ou non, un second risque distinct, indépendant du premier ? Quelle activation recommanderiez-

vous pour les couches cachées de ce réseau, et pourquoi ?

3 Applications en sciences économiques

Exercice 5 — Choisir une perte pour des rendements financiers

Un gérant de portefeuille dispose de cinq erreurs de prévision (rendement réalisé moins rendement prévu, en points de pourcentage) : 0,5 ; -0,3 ; 0,8 ; -0,4 ; 6,2. La dernière valeur correspond à une séance de krach, un événement rare mais bien réel sur ce marché.

- (a) Calculer l'erreur quadratique moyenne (EQM) et l'erreur absolue moyenne (EAM) sur les cinq erreurs.
- (b) Calculer à nouveau l'EQM et l'EAM en retirant la séance de krach des quatre autres erreurs, puis calculer le rapport entre l'EQM avec et sans cette observation, et le même rapport pour l'EAM.
- (c) Laquelle des deux pertes est la plus sensible à cette observation extrême ? Quelle perte choisiriez-vous pour entraîner un modèle sur ce type de série, et pourquoi ce choix est-il cohérent avec ce qui est dit des rendements financiers dans le chapitre ?

Exercice 6 — Profondeur et activation dans un scoring de crédit

Une banque envisage un réseau à 6 couches cachées pour son modèle de scoring de crédit, afin de capter des interactions complexes entre variables.

- (a) Si les 6 couches utilisent la sigmoïde, calculer le facteur multiplicatif au mieux appliqué au gradient. Comparer ce facteur à celui obtenu avec ReLU sur la même profondeur.
- (b) Le modèle produit, pour un dossier qui a réellement fait défaut ($y = 1$), une probabilité prédite $\hat{p} = 0,02$ (donc une prédiction confiante et fausse). Calculer $-\ln(0,02)$, puis comparer à $-\ln(0,5)$, la perte obtenue pour une prédiction non informative ($\hat{p} = 0,5$).
- (c) En combinant les deux résultats précédents, expliquer pourquoi une architecture profonde à activations sigmoïdes serait doublement pénalisée dans ce contexte : à l'entraînement (question a) et sur des erreurs confiantes (question b).


1 Exercices du chapitre

Correction — Exercice 1

(a) Observation 1 ($y = 1, \hat{p} = 0,9$) : $-\ln(0,9) \approx 0,1054$. Observation 2 ($y = 0, \hat{p} = 0,2$) : $-\ln(0,8) \approx 0,2231$. Observation 3 ($y = 1, \hat{p} = 0,6$) : $-\ln(0,6) \approx 0,5108$. Observation 4 ($y = 0, \hat{p} = 0,05$) : $-\ln(0,95) \approx 0,0513$.

(b) Perte moyenne = $(0,1054 + 0,2231 + 0,5108 + 0,0513)/4 \approx 0,2227$.

(c) L'observation 3 contribue le plus (0,5108). C'est cohérent : $\hat{p} = 0,6$ pour $y = 1$ est la prédiction la moins assurée du lot dans le bon sens (proche de 0,5), donc celle qui reflète le plus d'incertitude résiduelle, tandis que les observations 1, 2 et 4 sont toutes confiantes et correctes.




Correction — Exercice 2

(a) $z = -2$: $\sigma \approx 0,1192$, $\sigma' \approx 0,1050$. $z = 0$: $\sigma = 0,5$, $\sigma' = 0,2500$. $z = 1$: $\sigma \approx 0,7311$, $\sigma' \approx 0,1966$. $z = 3$: $\sigma \approx 0,9526$, $\sigma' \approx 0,0452$.

(b) La dérivée la plus élevée est obtenue en $z = 0$ (0,25). C'est cohérent : le chapitre rappelle que la dérivée de la sigmoïde est maximale en $z = 0$, où elle atteint précisément 0,25.

(c) Lorsque z s'éloigne fortement de 0 (positivement ou négativement), $\sigma'(z)$ tend vers 0 : la sigmoïde **sature**. Ce phénomène, combiné à la multiplication des dérivées lors de la rétropropagation, porte le nom de **gradient qui s'évanouit** (vanishing gradient).




Correction — Exercice 3

(a) 3 couches : $0,25^3 \approx 1,56 \times 10^{-2}$. 8 couches : $0,25^8 \approx 1,53 \times 10^{-5}$. 15 couches : $0,25^{15} \approx 9,31 \times 10^{-10}$.

(b) Avec ReLU, le facteur au mieux vaut $1^n = 1$ à n'importe quelle profondeur : la dérivée 1 ne diminue rien, quel que soit le nombre de couches.


(c) Non. Avec un facteur d'environ $1,53 \times 10^{-5}$ après 8 couches sigmoïdes, le gradient qui atteint les premières couches est réduit d'un facteur proche de 65 000 : ces couches ne reçoivent plus de signal exploitable et leurs poids ne bougent pratiquement pas. Un tel réseau est, en pratique, inentraînable avec des activations sigmoïdes sur toute sa profondeur.



2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4


- (a) Deux couches cachées sigmoïdes : $0,25^2 = 0,0625$. Au mieux, le gradient qui atteint la première couche cachée est déjà divisé par 16.
- (b) Avec ReLU sur les deux couches : $1^2 = 1$. Aucune atténuation.
- (c) Les deux risques sont bien **distincts** et **indépendants**. Le premier, identifié au chapitre 1, concerne la **capacité** du modèle : avec 1 217 paramètres pour 1 000 observations, le réseau risque de mémoriser au lieu de généraliser, quelle que soit l'activation choisie – c'est un problème de *variance* lié au surdimensionnement. Le second, propre à ce chapitre, concerne l'**entraînabilité** : avec des sigmoïdes, le gradient qui devrait ajuster les premiers poids du réseau est atténué avant même d'y parvenir – c'est un problème d'*optimisation*, qui empêcherait le réseau d'exploiter pleinement sa capacité, même démesurée. On recommande donc **ReLU** dans les deux couches cachées : cela ne résout pas le premier risque (qui appelle plutôt une régularisation ou davantage de données), mais élimine le second, purement lié au choix de l'activation.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $EQM = (0,5^2 + 0,3^2 + 0,8^2 + 0,4^2 + 6,2^2)/5 \approx 7,9160$. $EAM = (0,5 + 0,3 + 0,8 + 0,4 + 6,2)/5 = 1,6400$.
- (b) Sans la séance de krach : $EQM = (0,5^2 + 0,3^2 + 0,8^2 + 0,4^2)/4 = 0,2850$; $EAM = (0,5 + 0,3 + 0,8 + 0,4)/4 = 0,5000$. Rapport EQM (avec/sans) = $7,9160/0,2850 \approx 27,8$. Rapport EAM (avec/sans) = $1,6400/0,5000 = 3,28$.
- (c) L'EQM est nettement plus sensible à l'observation extrême : elle est multipliée par un facteur 27,8 contre seulement 3,28 pour l'EAM, parce que le carré amplifie les grands écarts alors que la valeur absolue les traite proportionnellement. Pour ce type de série, l'erreur **absolue** est préférable : le chapitre indique explicitement que l'erreur absolue convient mieux aux rendements financiers, dont les queues sont épaisses – un krach occasionnel ne doit pas dominer entièrement l'apprentissage du modèle.



Correction — Exercice 6

- (a) Sigmoides, 6 couches : $0,25^6 \approx 2,44 \times 10^{-4}$. ReLU, 6 couches : $1^6 = 1$. Le facteur sigmoïde est environ 4 100 fois plus petit que celui de ReLU à profondeur égale.
- (b) $-\ln(0,02) \approx 3,9120$, contre $-\ln(0,5) \approx 0,6931$ pour la prédiction non informative. La prédiction confiante et fausse coûte donc environ 5,6 fois plus cher en perte qu'une prédiction neutre.
- (c) Le réseau serait pénalisé sur deux plans indépendants. D'une part, à l'entraînement, l'usage de sigmoïdes sur 6 couches atténuerait le gradient d'un facteur proche de 4 100 par rapport à ReLU, empêchant les premières couches d'apprendre correctement – exactement le problème identifié à la question (a) et illustré à l'exercice 3. D'autre part, une fois le modèle mal entraîné, ses erreurs confiantes – comme celle de la question (b), où $\hat{p} = 0,02$ pour un défaut réel – coûteraient particulièrement cher en entropie croisée, sans que le gradient defectueux permette de les corriger efficacement au fil des itérations. La banque a donc doublement intérêt à préférer ReLU dans les couches cachées de ce réseau profond.