

Chapitre 2

Fonctions de perte et d'activation

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Exercice 1 — Calculer une entropie croisée

Un modèle de classification binaire produit, sur quatre observations, les prédictions $\hat{p}_i$ suivantes en face des labels y_i observés :

observation	1	2	3	4
y_i	1	0	1	0
$\hat{p}_i$	0,9	0,2	0,6	0,05

- (a) Calculer la perte d'entropie croisée $-[y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)]$ pour chacune des quatre observations.
- (b) Calculer la perte moyenne sur l'échantillon.
- (c) Quelle observation contribue le plus à la perte moyenne? Est-ce cohérent avec la qualité de la prédiction correspondante?

Exercice 2 — Dérivée de la sigmoïde

On considère la fonction sigmoïde $\sigma(z) = 1/(1 + e^{-z})$, de dérivée $\sigma(z)(1 - \sigma(z))$.

- (a) Calculer $\sigma(z)$ et $\sigma'(z)$ pour $z = -2, z = 0, z = 1$ et $z = 3$.
- (b) Parmi ces quatre valeurs, laquelle donne la dérivée la plus élevée? Est-ce cohérent avec la propriété rappelée dans le chapitre?
- (c) Que devient $\sigma'(z)$ lorsque z s'éloigne fortement de 0, dans un sens ou dans l'autre? Quel est le nom de ce phénomène?

Exercice 3 — Atténuation du gradient selon la profondeur

On suppose que chaque couche cachée d'un réseau utilise la sigmoïde, et que la dérivée locale vaut, au mieux, 0,25 à chaque couche.

- (a) Calculer le facteur multiplicatif au mieux appliqué au gradient après avoir traversé 3 couches, puis 8 couches, puis 15 couches.
- (b) Si les mêmes couches utilisaient ReLU (dérivée 1 pour une entrée positive), quel serait ce facteur, à profondeur égale?
- (c) Un réseau à 8 couches cachées sigmoïdes est-il raisonnablement entraînable en pratique, au vu du facteur obtenu en (a)?

2 Exercices cumulatifs (chapitre 2, chapitre 1 et introduction)

Exercice 4 — Choisir l'activation du réseau officiel du chapitre 1

Le réseau officiel du chapitre 1, pour la série financière à 20 indicateurs, a l'architecture $20 \rightarrow 32 \rightarrow 16 \rightarrow 1$: il compte donc **deux** couches cachées ($20 \rightarrow 32$ et $32 \rightarrow 16$) avant la couche de sortie, et 1 217 paramètres au total pour 1 000 observations disponibles.

- (a) Si les deux couches cachées utilisent la sigmoïde, calculer le facteur multiplicatif au mieux appliqué au gradient après les avoir traversées.
- (b) Si l'on remplace la sigmoïde par ReLU dans ces deux couches, calculer ce même facteur.
- (c) Le chapitre 1 avait déjà identifié un premier risque pour ce réseau, lié au rapport entre son nombre de paramètres et le nombre d'observations. En quoi le choix de l'activation ajoute-t-il, ou non, un second risque distinct, indépendant du premier? Quelle activation recommanderiez-

3 Applications en sciences économiques

Exercice 5 — Choisir une perte pour des rendements financiers

Un gérant de portefeuille dispose de cinq erreurs de prévision (rendement réalisé moins rendement prévu, en points de pourcentage) : 0,5 ; -0,3 ; 0,8 ; -0,4 ; 6,2. La dernière valeur correspond à une séance de krach, un événement rare mais bien réel sur ce marché.

- (a) Calculer l'erreur quadratique moyenne (EQM) et l'erreur absolue moyenne (EAM) sur les cinq erreurs.
- (b) Calculer à nouveau l'EQM et l'EAM en retirant la séance de krach des quatre autres erreurs, puis calculer le rapport entre l'EQM avec et sans cette observation, et le même rapport pour l'EAM.
- (c) Laquelle des deux pertes est la plus sensible à cette observation extrême ? Quelle perte choisiriez-vous pour entraîner un modèle sur ce type de série, et pourquoi ce choix est-il cohérent avec ce qui est dit des rendements financiers dans le chapitre ?

Exercice 6 — Profondeur et activation dans un scoring de crédit

Une banque envisage un réseau à 6 couches cachées pour son modèle de scoring de crédit, afin de capter des interactions complexes entre variables.

- (a) Si les 6 couches utilisent la sigmoïde, calculer le facteur multiplicatif au mieux appliqué au gradient. Comparer ce facteur à celui obtenu avec ReLU sur la même profondeur.
- (b) Le modèle produit, pour un dossier qui a réellement fait défaut ($y = 1$), une probabilité prédite $\hat{p} = 0,02$ (donc une prédiction confiante et fausse). Calculer $-\ln(0,02)$, puis comparer à $-\ln(0,5)$, la perte obtenue pour une prédiction non informative ($\hat{p} = 0,5$).
- (c) En combinant les deux résultats précédents, expliquer pourquoi une architecture profonde à activations sigmoïdes serait doublement pénalisée dans ce contexte : à l'entraînement (question a) et sur des erreurs confiantes (question b).