

Apprentissage profond

Chapitre 2 : Fonctions de perte et d'activation

Jaouad Madkour

25 septembre 2026

Plan du chapitre

La fonction de perte	1
Ce que le réseau cherche à minimiser	1
Les activations	2
La sigmoïde et son défaut	2
ReLU, et pourquoi elle a tout changé	3
Son défaut, et ses variantes	3
Ce qu'il faut faire en pratique	3
Ce qu'il faut retenir	3
Le résumé du chapitre	3

La fonction de perte

Ce que le réseau cherche à minimiser

Les pertes usuelles

Tâche	Perte	Formule
Régression	erreur quadratique	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$
Régression robuste	erreur absolue	$\frac{1}{n} \sum y_i - \hat{y}_i $
Classification binaire	entropie croisée	$-\frac{1}{n} \sum [y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)]$

L'entropie croisée n'est pas une nouveauté

Minimiser l'entropie croisée revient exactement à **maximiser la vraisemblance** du modèle logistique.

C'est le maximum de vraisemblance du chapitre 7 de *Statistique inférentielle*, sous un autre nom. Le vocabulaire change ; le critère est identique.

Pourquoi l'entropie croisée plutôt que l'erreur quadratique

En classification, l'erreur quadratique produit des gradients qui **s'annulent** quand le réseau se trompe avec assurance — précisément quand il faudrait corriger le plus fort.

L'entropie croisée, au contraire, pénalise très lourdement une prédiction confiante et fautive : $-\ln(0,01)$ vaut plus de 4,6. Le gradient reste vif, et l'apprentissage progresse.

Choisir la perte selon le problème

L'erreur **quadratique** punit fortement les grands écarts : elle est sensible aux valeurs aberrantes.

L'erreur **absolue** les traite plus doucement : elle convient aux rendements financiers, dont les queues sont épaisses — un fait établi à l'introduction de *Modélisation GARCH*.

La perte encode ce qui compte pour vous. Ce n'est pas un détail technique.

Les activations

La sigmoïde et son défaut

La sigmoïde

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Elle ramène toute valeur dans $]0, 1[$. Sa dérivée vaut $\sigma(z)(1 - \sigma(z))$.

Le problème, chiffré

La dérivée de la sigmoïde est **maximale en** $z = 0$, où elle vaut 0,25. Elle est plus faible partout ailleurs.

Or la rétropropagation **multiplie** ces dérivées couche après couche :

Couches	Facteur au mieux
1	0,25
5	$9,8 \times 10^{-4}$
10	$9,5 \times 10^{-7}$
20	$9,1 \times 10^{-13}$

Après dix couches, le gradient est divisé par plus d'un million — et c'est le cas le plus favorable.

Le gradient qui s'évanouit

Les couches profondes ne reçoivent plus de signal d'apprentissage : leurs poids ne bougent pratiquement pas.

C'est la raison technique pour laquelle les réseaux profonds sont restés inutilisables pendant des décennies.

ReLU, et pourquoi elle a tout changé

ReLU

$$\text{ReLU}(z) = \max(0, z)$$

Sa dérivée vaut 1 pour $z > 0$ et 0 sinon.

La dérivée de 1 est décisive

Multiplier des 1 ne diminue rien. Le gradient traverse donc les couches sans s'atténuer, et l'entraînement de réseaux profonds devient possible.

À cela s'ajoutent deux avantages : le calcul est trivial, et la **parcimonie** — les neurones à sortie nulle ne participent pas, ce qui allège le réseau.

Le passage de la sigmoïde à ReLU est l'une des raisons principales du succès de l'apprentissage profond, davantage qu'une astuce d'implémentation.

Son défaut, et ses variantes

Définition

Un neurone dont l'entrée reste négative a un gradient nul en permanence : il est **mort**, définitivement.

Variante	Correction
Leaky ReLU	pente faible du côté négatif
ELU	transition douce, sortie négative bornée
GELU	version lissée, usuelle dans les transformeurs

Ce qu'il faut faire en pratique

Application en gestion

Commencer par **ReLU** dans les couches cachées. Passer à une variante seulement si l'on observe des neurones morts.

Ne jamais mettre de sigmoïde ou de tangente hyperbolique dans les couches cachées d'un réseau profond — sauf dans les portes des architectures récurrentes du chapitre 8, où leur bornage est justement ce qu'on recherche.

Ce qu'il faut retenir

Le résumé du chapitre

Cinq points

1. La **perte** encode l'objectif : quadratique, absolue, ou entropie croisée.
2. L'**entropie croisée** est le maximum de vraisemblance logistique, sous un autre nom.
3. La dérivée de la sigmoïde plafonne à 0,25 : après dix couches, le gradient est divisé par un million.
4. **ReLU** a une dérivée de 1 : le gradient traverse sans s'atténuer.

5. ReLU dans les couches cachées ; sigmoïde ou softmax **uniquement en sortie**.

La suite

Perte et activations sont choisies. Le chapitre 3 aborde l'algorithme qui minimise effectivement cette perte.