

Chapitre 5

Régularisation : décrochage, pénalisation, arrêt précoce

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sum_j w_j^2 = 0,6^2 + (-0,9)^2 + 1,1^2 + (-0,4)^2 = 0,36 + 0,81 + 1,21 + 0,16 = 2,54$.

(b) Pénalité = $0,001 \times 2,54 = 0,00254$.

(c) $L_{\text{total}} = 0,35 + 0,00254 = 0,35254$. La pénalité ne modifie que très marginalement la perte (0,7 % environ) : c'est attendu, puisque $\lambda = 0,001$ se situe précisément dans la plage usuelle (10^{-5} à 10^{-3}) rappelée par le chapitre – ces valeurs sont conçues pour agir en douceur, pas pour dominer la perte de base.




Correction — Exercice 2

(a) La perte de validation atteint son minimum à l'époque 6 (0,46).

(b) Après l'époque 6, la perte d'apprentissage continue de **baisser** (0,25 → 0,21 → 0,18 → 0,15) tandis que la perte de validation **remonte** (0,47 → 0,50 → 0,55 → 0,62). C'est exactement le diagnostic « apprentissage baisse, validation remonte ⇒ sur-ajustement » du tableau du chapitre.

(c) Avec une patience de 3 époques, l'entraînement s'arrête dès que la validation n'a pas battu son meilleur score (0,46, époque 6) pendant 3 époques consécutives : les époques 7, 8 et 9 (0,47, 0,50, 0,55) ne l'améliorent pas, donc l'entraînement s'arrête à la fin de l'époque 9. Les poids conservés sont ceux de l'époque 6, le meilleur point observé.




Correction — Exercice 3

(a) Nombre espéré de neurones actifs = $50 \times (1 - 0,3) = 50 \times 0,7 = 35$.

(b) Facteur de mise à l'échelle = $1 - p = 1 - 0,3 = 0,7$.

(c) Sortie mise à l'échelle = $120 \times 0,7 = 84$.




2 Exercices cumulatifs (chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\partial L_{\text{total}} / \partial w = \partial L / \partial w + 2\lambda w$, donc $w \leftarrow w - \eta (\partial L / \partial w + 2\lambda w) = w - 2\eta\lambda w - \eta \partial L / \partial w = w(1 - 2\eta\lambda) - \eta \partial L / \partial w$.

(b) Facteur = $1 - 2 \times 0,001 \times 0,0001 = 1 - 0,0000002 = 0,9999998$.

(c) Ce facteur est extrêmement proche de 1 : à **chaque** mise à jour, le rétrécissement dû au weight decay seul est infime (moins de deux millièmes). Sur 20 époques à 32 mises à jour chacune, le nombre total de mises à jour est $20 \times 32 = 640$. Oui, cela explique le besoin d'un grand nombre d'itérations cumulées : un effet individuellement négligeable, répété 640 fois, produit un rétrécissement composé $0,9999998^{640} \approx 0,99987$ – toujours modeste, mais qui continuerait de s'accumuler sur des entraînements plus longs, exactement comme un taux d'intérêt infinitésimal composé sur de nombreuses périodes.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $\sum w_{A,j}^2 = 0,8^2 + (-1,2)^2 + 0,5^2 = 0,64 + 1,44 + 0,25 = 2,33$. $\sum w_{B,j}^2 = 2,0^2 + (-3,5)^2 + 1,8^2 = 4,00 + 12,25 + 3,24 = 19,49$.

(b) Pénalité A = $0,0005 \times 2,33 = 0,001165$. Pénalité B = $0,0005 \times 19,49 = 0,009745$.

(c) Rapport = $0,009745 / 0,001165 \approx 8,37$. Ce rapport est bien plus élevé que le rapport des poids eux-mêmes (les poids de B sont environ 2 à 3 fois plus grands que ceux de A, terme à terme). C'est cohérent avec le caractère **quadratique** de la pénalité : doubler un poids quadruple sa contribution à $\sum w_j^2$, de sorte que les poids les plus grands sont pénalisés de façon disproportionnée – exactement l'effet recherché par le weight decay, qui décourage particulièrement les poids excessifs plutôt que de pénaliser uniformément tous les poids.



Correction — Exercice 6

- (a) La perte de validation atteint son minimum à l'**époque 5** (0,66).
- (b) Avec une patience de 2 époques : après l'époque 5, les époques 6 et 7 (0,67, 0,71) n'améliorent pas le score, donc l'entraînement s'arrête à la fin de l'**époque 7**. Les poids conservés sont ceux de l'époque 5.
- (c) Non, ce n'est **pas** cohérent avec l'ordre recommandé dans le chapitre. L'arrêt précoce doit être activé **systématiquement** et en premier (il est gratuit), mais le weight decay et le décrochage n'arrivent qu'en **dernier**, après avoir envisagé plus de données ou de l'augmentation, puis un réseau plus petit – et ils devraient être ajoutés **un à la fois**, jamais simultanément, précisément pour pouvoir diagnostiquer lequel produit l'effet observé. La banque devrait donc d'abord garder l'arrêt précoce seul, vérifier si le sur-ajustement persiste, puis envisager plus de données ou un réseau plus petit, et n'introduire le weight decay puis, séparément, le décrochage que si cela reste nécessaire – chaque changement étant suivi d'une nouvelle lecture des courbes de perte.