

Apprentissage profond

Chapitre 5 : Régularisation : décrochage, pénalisation, arrêt précoce

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une pénalité de weight decay

Un petit réseau compte quatre poids : $w = (0,6; -0,9; 1,1; -0,4)$, avec $\lambda = 0,001$. La perte de base (sans pénalité) vaut $L = 0,35$.

- (a) Calculer $\sum_j w_j^2$.
- (b) Calculer la pénalité $\lambda \sum_j w_j^2$.
- (c) Calculer la perte totale $L_{\text{total}} = L + \lambda \sum_j w_j^2$. La pénalité modifie-t-elle sensiblement la perte ici ? La valeur de λ utilisée est-elle dans la plage usuelle rappelée par le chapitre (10^{-5} à 10^{-3}) ?

Exercice 2 — Lire un diagnostic de sur-ajustement

Un modèle est entraîné pendant 10 époques. Les pertes d'apprentissage et de validation sont :

époque	1	2	3	4	5	6	7	8	9	10
apprentissage	0,90	0,70	0,55	0,44	0,36	0,30	0,25	0,21	0,18	0,15
validation	0,92	0,72	0,58	0,50	0,47	0,46	0,47	0,50	0,55	0,62

- (a) À quelle époque la perte de validation atteint-elle son minimum ?
- (b) Après cette époque, comment évoluent la perte d'apprentissage et la perte de validation l'une par rapport à l'autre ? Quel diagnostic du tableau du chapitre cela correspond-il ?
- (c) Avec une patience de 3 époques (arrêt si la validation ne s'améliore pas pendant 3 époques consécutives après le meilleur point), à quelle époque l'entraînement s'arrêterait-il, et quels poids seraient conservés ?

Exercice 3 — Décrochage : neurones actifs et mise à l'échelle

Une couche compte $h = 50$ neurones, avec un taux de décrochage $p = 0,3$ à l'entraînement.

- (a) Calculer le nombre **espéré** de neurones actifs à chaque passage d'entraînement.
- (b) À l'inférence, tous les neurones sont actifs et les sorties sont mises à l'échelle par un facteur $(1-p)$ pour compenser. Calculer ce facteur.
- (c) Si la somme des sorties brutes de la couche (avant mise à l'échelle) vaut 120 à l'inférence, calculer la sortie effectivement utilisée après mise à l'échelle.

2 Exercices cumulatifs (chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Weight decay et la règle de mise à jour du chapitre 3

Le réseau officiel du chapitre 1 (1 217 paramètres, 1 000 observations) est entraîné avec Adam à $\eta = 0,001$ (chapitre 3) et une pénalisation weight decay $\lambda = 0,0001$.

- (a) Sachant que $\partial(\lambda w^2)/\partial w = 2\lambda w$, écrire la règle de mise à jour complète d'un poids w soumis à la fois au gradient de la perte $\partial L/\partial w$ (calculé par rétropropagation, chapitre 4) et à la pénalité, sous la forme $w \leftarrow w(1 - 2\eta\lambda) - \eta \partial L/\partial w$.
- (b) Calculer le facteur de contraction $1 - 2\eta\lambda$ pour $\eta = 0,001$ et $\lambda = 0,0001$.
- (c) Ce facteur est-il proche de 1 ou de 0 ? Sachant que ce réseau, entraîné sur $n = 1\,000$ observations avec des lots de 32, effectue environ 32 mises à jour par époque (chapitre 3), calculer le nombre total de mises à jour sur 20 époques. Le faible rétrécissement obtenu à **chaque** mise à jour explique-t-il pourquoi le weight decay a malgré tout besoin d'un grand nombre d'itérations

cumulées pour produire un effet visible sur l'amplitude des poids ?

3 Applications en sciences économiques

Exercice 5 — Comparer deux régimes de poids pour un modèle fintech

Une fintech compare deux configurations entraînées pour le même réseau à trois poids, avec $\lambda = 0,0005$: la configuration A, $w_A = (0,8; -1,2; 0,5)$, et la configuration B, aux poids plus grands, $w_B = (2,0; -3,5; 1,8)$.

- (a) Calculer $\sum_j w_j^2$ pour chacune des deux configurations.
- (b) Calculer la pénalité $\lambda \sum_j w_j^2$ pour chacune.
- (c) Calculer le rapport entre la pénalité de B et celle de A. Ce rapport est-il proportionnel au rapport des poids eux-mêmes, ou plus élevé ? Pourquoi (indice : la pénalité porte sur le **carré** des poids) ?

Exercice 6 — Arrêt précoce pour un modèle de risque de crédit

Une banque entraîne un modèle de risque de crédit sur 8 époques :

époque	1	2	3	4	5	6	7	8
apprentissage	1,10	0,85	0,68	0,55	0,46	0,39	0,33	0,28
validation	1,15	0,90	0,75	0,68	0,66	0,67	0,71	0,78

- (a) À quelle époque la perte de validation atteint-elle son minimum ?
- (b) Avec une patience de 2 époques, à quelle époque l'entraînement s'arrêterait-il ?
- (c) La banque envisage, en plus de l'arrêt précoce, d'ajouter du weight decay et du décrochage simultanément dès le départ. Est-ce cohérent avec l'ordre de procédure recommandé dans le chapitre ? Que faudrait-il faire à la place ?


1 Exercices du chapitre

Correction — Exercice 1

(a) $\sum_j w_j^2 = 0,6^2 + (-0,9)^2 + 1,1^2 + (-0,4)^2 = 0,36 + 0,81 + 1,21 + 0,16 = 2,54$.

(b) Pénalité = $0,001 \times 2,54 = 0,00254$.

(c) $L_{\text{total}} = 0,35 + 0,00254 = 0,35254$. La pénalité ne modifie que très marginalement la perte (0,7 % environ) : c'est attendu, puisque $\lambda = 0,001$ se situe précisément dans la plage usuelle (10^{-5} à 10^{-3}) rappelée par le chapitre – ces valeurs sont conçues pour agir en douceur, pas pour dominer la perte de base.




Correction — Exercice 2

(a) La perte de validation atteint son minimum à l'époque 6 (0,46).

(b) Après l'époque 6, la perte d'apprentissage continue de **baissier** ($0,25 \rightarrow 0,21 \rightarrow 0,18 \rightarrow 0,15$) tandis que la perte de validation **remonte** ($0,47 \rightarrow 0,50 \rightarrow 0,55 \rightarrow 0,62$). C'est exactement le diagnostic « apprentissage baisse, validation remonte $\Rightarrow$ sur-ajustement » du tableau du chapitre.

(c) Avec une patience de 3 époques, l'entraînement s'arrête dès que la validation n'a pas battu son meilleur score (0,46, époque 6) pendant 3 époques consécutives : les époques 7, 8 et 9 (0,47, 0,50, 0,55) ne l'améliorent pas, donc l'entraînement s'arrête à la fin de l'époque 9. Les poids conservés sont ceux de l'époque 6, le meilleur point observé.




Correction — Exercice 3

(a) Nombre espéré de neurones actifs = $50 \times (1 - 0,3) = 50 \times 0,7 = 35$.

(b) Facteur de mise à l'échelle = $1 - p = 1 - 0,3 = 0,7$.

(c) Sortie mise à l'échelle = $120 \times 0,7 = 84$.




2 Exercices cumulatifs (chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $\partial L_{\text{total}}/\partial w = \partial L/\partial w + 2\lambda w$, donc $w \leftarrow w - \eta(\partial L/\partial w + 2\lambda w) = w - 2\eta\lambda w - \eta\partial L/\partial w = w(1 - 2\eta\lambda) - \eta\partial L/\partial w$.

(b) Facteur = $1 - 2 \times 0,001 \times 0,0001 = 1 - 0,0000002 = 0,9999998$.

(c) Ce facteur est extrêmement proche de 1 : à **chaque** mise à jour, le rétrécissement dû au weight decay seul est infime (moins de deux millièmes). Sur 20 époques à 32 mises à jour chacune, le nombre total de mises à jour est $20 \times 32 = 640$. Oui, cela explique le besoin d'un grand nombre d'itérations cumulées : un effet individuellement négligeable, répété 640 fois, produit un rétrécissement composé $0,9999998^{640} \approx 0,99987$ – toujours modeste, mais qui continuerait de s'accumuler sur des entraînements plus longs, exactement comme un taux d'intérêt infinitésimal composé sur de nombreuses périodes.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $\sum w_{A,j}^2 = 0,8^2 + (-1,2)^2 + 0,5^2 = 0,64 + 1,44 + 0,25 = 2,33$. $\sum w_{B,j}^2 = 2,0^2 + (-3,5)^2 + 1,8^2 = 4,00 + 12,25 + 3,24 = 19,49$.

(b) Pénalité A = $0,0005 \times 2,33 = 0,001165$. Pénalité B = $0,0005 \times 19,49 = 0,009745$.

(c) Rapport = $0,009745/0,001165 \approx 8,37$. Ce rapport est bien plus élevé que le rapport des poids eux-mêmes (les poids de B sont environ 2 à 3 fois plus grands que ceux de A, terme à terme). C'est cohérent avec le caractère **quadratique** de la pénalité : doubler un poids quadruple sa contribution à $\sum w_j^2$, de sorte que les poids les plus grands sont pénalisés de façon disproportionnée – exactement l'effet recherché par le weight decay, qui décourage particulièrement les poids excessifs plutôt que de pénaliser uniformément tous les poids.



Correction — Exercice 6

- (a) La perte de validation atteint son minimum à l'**époque 5** (0,66).
- (b) Avec une patience de 2 époques : après l'époque 5, les époques 6 et 7 (0,67, 0,71) n'améliorent pas le score, donc l'entraînement s'arrête à la fin de l'**époque 7**. Les poids conservés sont ceux de l'époque 5.
- (c) Non, ce n'est **pas** cohérent avec l'ordre recommandé dans le chapitre. L'arrêt précoce doit être activé **systématiquement** et en premier (il est gratuit), mais le weight decay et le décrochage n'arrivent qu'en **dernier**, après avoir envisagé plus de données ou de l'augmentation, puis un réseau plus petit – et ils devraient être ajoutés **un à la fois**, jamais simultanément, précisément pour pouvoir diagnostiquer lequel produit l'effet observé. La banque devrait donc d'abord garder l'arrêt précoce seul, vérifier si le sur-ajustement persiste, puis envisager plus de données ou un réseau plus petit, et n'introduire le weight decay puis, séparément, le décrochage que si cela reste nécessaire – chaque changement étant suivi d'une nouvelle lecture des courbes de perte.