

# Chapitre 5

Régularisation : décrochage, pénalisation, arrêt précoce

## Feuille d'exercices

---

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger  
Exercices et corrigés · Apprentissage profond

## 1 Exercices du chapitre

### Exercice 1 — Calculer une pénalité de weight decay

Un petit réseau compte quatre poids :  $w = (0,6; -0,9; 1,1; -0,4)$ , avec  $\lambda = 0,001$ . La perte de base (sans pénalité) vaut  $L = 0,35$ .

- (a) Calculer  $\sum_j w_j^2$ .
- (b) Calculer la pénalité  $\lambda \sum_j w_j^2$ .
- (c) Calculer la perte totale  $L_{\text{total}} = L + \lambda \sum_j w_j^2$ . La pénalité modifie-t-elle sensiblement la perte ici ? La valeur de  $\lambda$  utilisée est-elle dans la plage usuelle rappelée par le chapitre ( $10^{-5}$  à  $10^{-3}$ ) ?

### Exercice 2 — Lire un diagnostic de sur-ajustement

Un modèle est entraîné pendant 10 époques. Les pertes d'apprentissage et de validation sont :

| époque        | 1    | 2    | 3    | 4    | 5    | 6    | 7    | 8    | 9    | 10   |
|---------------|------|------|------|------|------|------|------|------|------|------|
| apprentissage | 0,90 | 0,70 | 0,55 | 0,44 | 0,36 | 0,30 | 0,25 | 0,21 | 0,18 | 0,15 |
| validation    | 0,92 | 0,72 | 0,58 | 0,50 | 0,47 | 0,46 | 0,47 | 0,50 | 0,55 | 0,62 |

- (a) À quelle époque la perte de validation atteint-elle son minimum ?
- (b) Après cette époque, comment évoluent la perte d'apprentissage et la perte de validation l'une par rapport à l'autre ? Quel diagnostic du tableau du chapitre cela correspond-il ?
- (c) Avec une patience de 3 époques (arrêt si la validation ne s'améliore pas pendant 3 époques consécutives après le meilleur point), à quelle époque l'entraînement s'arrêterait-il, et quels poids seraient conservés ?

### Exercice 3 — Décrochage : neurones actifs et mise à l'échelle

Une couche compte  $h = 50$  neurones, avec un taux de décrochage  $p = 0,3$  à l'entraînement.

- (a) Calculer le nombre **espéré** de neurones actifs à chaque passage d'entraînement.
- (b) À l'inférence, tous les neurones sont actifs et les sorties sont mises à l'échelle par un facteur  $(1-p)$  pour compenser. Calculer ce facteur.
- (c) Si la somme des sorties brutes de la couche (avant mise à l'échelle) vaut 120 à l'inférence, calculer la sortie effectivement utilisée après mise à l'échelle.

## 2 Exercices cumulatifs (chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

### Exercice 4 — Weight decay et la règle de mise à jour du chapitre 3

Le réseau officiel du chapitre 1 (1 217 paramètres, 1 000 observations) est entraîné avec Adam à  $\eta = 0,001$  (chapitre 3) et une pénalisation weight decay  $\lambda = 0,0001$ .

- (a) Sachant que  $\partial(\lambda w^2)/\partial w = 2\lambda w$ , écrire la règle de mise à jour complète d'un poids  $w$  soumis à la fois au gradient de la perte  $\partial L/\partial w$  (calculé par rétropropagation, chapitre 4) et à la pénalité, sous la forme  $w \leftarrow w(1 - 2\eta\lambda) - \eta \partial L/\partial w$ .
- (b) Calculer le facteur de contraction  $1 - 2\eta\lambda$  pour  $\eta = 0,001$  et  $\lambda = 0,0001$ .
- (c) Ce facteur est-il proche de 1 ou de 0 ? Sachant que ce réseau, entraîné sur  $n = 1\,000$  observations avec des lots de 32, effectue environ 32 mises à jour par époque (chapitre 3), calculer le nombre total de mises à jour sur 20 époques. Le faible rétrécissement obtenu à **chaque** mise à jour explique-t-il pourquoi le weight decay a malgré tout besoin d'un grand nombre d'itérations

### 3 Applications en sciences économiques

#### Exercice 5 — Comparer deux régimes de poids pour un modèle fintech

Une fintech compare deux configurations entraînées pour le même réseau à trois poids, avec  $\lambda = 0,0005$  : la configuration A,  $w_A = (0,8; -1,2; 0,5)$ , et la configuration B, aux poids plus grands,  $w_B = (2,0; -3,5; 1,8)$ .

- Calculer  $\sum_j w_j^2$  pour chacune des deux configurations.
- Calculer la pénalité  $\lambda \sum_j w_j^2$  pour chacune.
- Calculer le rapport entre la pénalité de B et celle de A. Ce rapport est-il proportionnel au rapport des poids eux-mêmes, ou plus élevé? Pourquoi (indice : la pénalité porte sur le **carré** des poids)?

#### Exercice 6 — Arrêt précoce pour un modèle de risque de crédit

Une banque entraîne un modèle de risque de crédit sur 8 époques :

| époque        | 1    | 2    | 3    | 4    | 5    | 6    | 7    | 8    |
|---------------|------|------|------|------|------|------|------|------|
| apprentissage | 1,10 | 0,85 | 0,68 | 0,55 | 0,46 | 0,39 | 0,33 | 0,28 |
| validation    | 1,15 | 0,90 | 0,75 | 0,68 | 0,66 | 0,67 | 0,71 | 0,78 |

- À quelle époque la perte de validation atteint-elle son minimum?
- Avec une patience de 2 époques, à quelle époque l'entraînement s'arrêterait-il?
- La banque envisage, en plus de l'arrêt précoce, d'ajouter du weight decay et du décrochage simultanément dès le départ. Est-ce cohérent avec l'ordre de procédure recommandé dans le chapitre? Que faudrait-il faire à la place?