

Chapitre 7

Les réseaux convolutifs

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) $64 \times 64 \times 50 + 50 = 4096 \times 50 + 50 = 204\,800 + 50 = 204\,850$ paramètres.
(b) $(5 \times 5 \times 1 + 1) \times 16 = (25 + 1) \times 16 = 26 \times 16 = 416$ paramètres.
(c) Rapport = $204\,850/416 \approx 492,4$: la couche dense compte près de 500 fois plus de paramètres.




Correction — Exercice 2

- (a) $\lfloor (32 - 3 + 2 \times 1)/1 \rfloor + 1 = \lfloor 31/1 \rfloor + 1 = 31 + 1 = 32$: la taille est conservée, ce qui est l'effet recherché du remplissage.
(b) $\lfloor (28 - 5 + 0)/1 \rfloor + 1 = \lfloor 23/1 \rfloor + 1 = 23 + 1 = 24$.
(c) $\lfloor (28 - 5 + 2 \times 2)/2 \rfloor + 1 = \lfloor 27/2 \rfloor + 1 = \lfloor 13,5 \rfloor + 1 = 13 + 1 = 14$. Un pas supérieur à 1 **réduit** nettement la taille de sortie par rapport à un pas de 1 (ici 14 contre ce que donnerait un pas de 1 avec le même remplissage, $\lfloor 27/1 \rfloor + 1 = 28$) : le filtre saute des positions, sous-échantillonnant directement la carte de sortie.



Correction — Exercice 3


- (a) $t = 3 : z = 0,5 \times 9 + 0,3 \times 12 + 0,2 \times 10 + 0,1 = 4,5 + 3,6 + 2,0 + 0,1 = 10,2$. $\text{ReLU}(10,2) = 10,2$ (positif).
(b) $t = 4 : z = 0,5 \times 15 + 0,3 \times 9 + 0,2 \times 12 + 0,1 = 7,5 + 2,7 + 2,4 + 0,1 = 12,7$. $t = 5 : z = 0,5 \times 11 + 0,3 \times 15 + 0,2 \times 9 + 0,1 = 5,5 + 4,5 + 1,8 + 0,1 = 11,9$.
(c) Le filtre calcule, à chaque instant, une combinaison linéaire pondérée des trois dernières valeurs de la série (y_t, y_{t-1}, y_{t-2}) suivie d'une non-linéarité : c'est structurellement un MA(3), à ceci près que les poids (0,5 ; 0,3 ; 0,2) sont **appris** par apprentissage plutôt que fixés par une modélisation a priori, et qu'une activation ReLU est appliquée ensuite. Le filtre n'utilise jamais y_{t+1} parce qu'il est **causal** : en prévision, la valeur future n'est simplement pas encore observée au moment où la prédiction est produite.



2 Exercices cumulatifs (chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

- (a) $(5 \times 1 + 1) \times 32 = 6 \times 32 = 192$ paramètres.
- (b) Rapport = $672/192 = 3,5$: la couche dense compte 3,5 fois plus de paramètres que son équivalent convolutif.
- (c) Variance He convolutive = $2/5 = 0,4$ (écart-type $\approx 0,6325$), contre variance He dense = $2/20 = 0,1$ (écart-type $\approx 0,3162$) pour la couche entièrement connectée. La couche convolutive, avec un champ récepteur plus étroit ($n_{\text{entrée}} = 5$ contre 20), reçoit une variance d'initialisation par poids plus large – cohérent avec la logique du chapitre 6 : moins d'entrées par neurone appelle des poids individuellement plus variables pour conserver la même variance totale du signal. Sur le fond, le passage à la convolution met bien en œuvre le remède « réseau plus petit » du chapitre 5 (192 au lieu de 672 paramètres pour cette couche), mais ce n'est pas une réduction arbitraire : elle exploite l'hypothèse structurelle, propre à une série temporelle, qu'un motif utile est **local** (les quelques dernières valeurs) et se répète de façon similaire à différents instants – exactement les deux premières des trois propriétés du chapitre (connectivité locale, partage des poids), appliquées ici à l'axe temporel plutôt qu'à une image.




3 Applications en sciences économiques

Correction — Exercice 5

- (a) L'image compte $200 \times 200 \times 3 = 120\,000$ entrées (une par pixel et par canal de couleur). Couche dense = $120\,000 \times 100 + 100 = 12\,000\,000 + 100 = 12\,000\,100$ paramètres.
- (b) $(7 \times 7 \times 3 + 1) \times 64 = (147 + 1) \times 64 = 148 \times 64 = 9\,472$ paramètres.
- (c) Rapport = $12\,000\,100/9\,472 \approx 1\,267$: la couche dense compte plus de mille fois plus de paramètres. Oui, l'équivariance par translation est précieuse au-delà de ce seul gain en paramètres : une signature ou un motif caractéristique (numéro de chèque, motif de fraude) peut apparaître à des positions légèrement différentes d'un chèque scanné à l'autre selon le cadrage ; un réseau équivariant par translation le reconnaît quelle que soit sa position exacte dans l'image, alors qu'une couche entièrement connectée devrait apprendre à reconnaître séparément le même motif à chacune de ses positions.

possibles – un gaspillage à la fois de paramètres et de données d'apprentissage.



Correction — Exercice 6

(a) $t = 3 : z = 0,6 \times 2,5 + 0,25 \times 1,8 + 0,15 \times 2,1 - 0,05 = 1,5 + 0,45 + 0,315 - 0,05 = 2,215$. $t = 4 : z = 0,6 \times 3,0 + 0,25 \times 2,5 + 0,15 \times 1,8 - 0,05 = 1,8 + 0,625 + 0,27 - 0,05 = 2,645$. $t = 5 : z = 0,6 \times 2,2 + 0,25 \times 3,0 + 0,15 \times 2,5 - 0,05 = 1,32 + 0,75 + 0,375 - 0,05 = 2,395$. $t = 6 : z = 0,6 \times 1,5 + 0,25 \times 2,2 + 0,15 \times 3,0 - 0,05 = 0,9 + 0,55 + 0,45 - 0,05 = 1,850$. Tous ces résultats étant positifs, ReLU les laisse inchangés.

(b) Sur les trimestres 3 à 6, la série brute varie entre 1,5 et 3,0 (étendue = 1,5), tandis que la série filtrée varie entre 1,850 et 2,645 (étendue $\approx 0,795$). L'étendue est presque **divisée par deux** : le filtre a bien un effet lissant net, cohérent avec sa nature de moyenne mobile pondérée.

(c) Un filtre non causal utilisant y_{t+1} nécessiterait de connaître la croissance du trimestre **suivant** au moment de publier la prévision du trimestre courant – une information qui n'existe simplement pas encore en temps réel. Ce serait la même erreur que l'utilisation de données futures dénoncée au chapitre sur le découpage temporel d'*Apprentissage statistique* : une performance illusoire en rétrospective, inexploitable et invérifiable en prévision réelle.

