

Apprentissage profond

Chapitre 7 : Les réseaux convolutifs

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — L'économie de paramètres de la convolution

Une image en niveaux de gris de 64×64 pixels doit être traitée par une première couche produisant 50 sorties.

- (a) Calculer le nombre de paramètres d'une couche **entièrement connectée** vers ces 50 sorties.
- (b) Calculer le nombre de paramètres d'une couche **convolutive** de 16 filtres 5×5 (un seul canal d'entrée).
- (c) Calculer le rapport entre les deux nombres de paramètres.

Exercice 2 — Calculer la taille de sortie d'une convolution

La taille de sortie d'une convolution est donnée par $\lfloor (\text{taille entrée} - \text{taille filtre} + 2 \times \text{remplissage}) / \text{pas} \rfloor + 1$.

- (a) Calculer la taille de sortie pour une entrée de 32×32 , un filtre 3×3 , un remplissage de 1 et un pas de 1.
- (b) Calculer la taille de sortie pour une entrée de 28×28 , un filtre 5×5 , sans remplissage, avec un pas de 1.
- (c) Calculer la taille de sortie pour la même entrée de 28×28 et le même filtre 5×5 , mais avec un remplissage de 2 et un pas de 2. Quel est l'effet d'un pas supérieur à 1 sur la taille de sortie, par rapport à un pas de 1 ?

Exercice 3 — Une convolution causale comme moyenne mobile apprise

Une série hebdomadaire de ventes vaut, pour les semaines 1 à 6 : 10; 12; 9; 15; 11; 14. On applique un filtre causal de taille 3, de poids $w = (0,5; 0,3; 0,2)$ appliqués respectivement à (y_t, y_{t-1}, y_{t-2}) , avec un biais $b = 0,1$ et une activation ReLU.

- (a) Calculer la sortie du filtre pour $t = 3$ (utilisant y_3, y_2, y_1).
- (b) Calculer la sortie du filtre pour $t = 4$ et pour $t = 5$.
- (c) En quoi cette opération correspond-elle exactement à ce que fait un processus MA(3), à ceci près que les poids sont appris plutôt que fixés a priori ? Pourquoi le filtre n'utilise-t-il jamais y_{t+1} ?

2 Exercices cumulatifs (chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Remplacer la première couche du réseau officiel par une convolution

La première couche du réseau officiel du chapitre 1 ($20 \rightarrow 32$, entièrement connectée) compte 672 paramètres. On envisage de la remplacer par une couche convolutive causale de 32 filtres de taille 5 (un seul canal, puisque la série financière est univariée), appliquée aux 20 valeurs d'entrée traitées comme une séquence temporelle.

- (a) Calculer le nombre de paramètres de cette couche convolutive.
- (b) Calculer le rapport entre les paramètres de la couche dense (672) et ceux de la couche convolutive.
- (c) Calculer la variance He pour cette couche convolutive ($n_{\text{entrée}} = 5 \times 1 = 5$, chapitre 6), et la comparer à la variance He de la couche dense équivalente ($n_{\text{entrée}} = 20$). Enfin, sachant que le chapitre 1 avait signalé un risque de surdimensionnement pour un réseau de 1 217 paramètres face à 1 000 observations (chapitre 5, réduire le réseau est un des remèdes), en quoi le passage à une couche convolutive constitue-t-il une mise en œuvre concrète de ce remède, tout en

exploitant une propriété structurelle de la série (motifs locaux) plutôt qu'une simple réduction arbitraire de taille ?

3 Applications en sciences économiques

Exercice 5 — Dimensionner un réseau de lecture de chèques

Une banque traite des images de chèques scannés en couleur, de 200×200 pixels sur 3 canaux (rouge, vert, bleu), pour une première couche de 100 sorties.

- (a) Calculer le nombre de paramètres d'une couche entièrement connectée vers ces 100 sorties.
- (b) Calculer le nombre de paramètres d'une couche convolutive de 64 filtres 7×7 sur les 3 canaux d'entrée.
- (c) Calculer le rapport entre les deux. Une banque qui traiterait des millions de chèques par jour a-t-elle intérêt, au-delà du gain en paramètres, à ce que l'architecture soit **équivalente par translation** (un même motif de signature reconnu quelle que soit sa position sur le chèque) ?

Exercice 6 — Lisser la croissance du PIB par une moyenne mobile apprise


Un institut de conjoncture dispose des taux de croissance trimestriels du PIB (en %) : 2,1 ; 1,8 ; 2,5 ; 3,0 ; 2,2 ; 1,5, pour les trimestres 1 à 6. On applique un filtre causal de taille 3, poids $w = (0,6 ; 0,25 ; 0,15)$, biais $b = -0,05$, activation ReLU.

- (a) Calculer la sortie filtrée pour les trimestres 3, 4, 5 et 6.
- (b) Comparer la volatilité (écart entre valeur minimale et valeur maximale) de la série brute des six trimestres à celle des quatre sorties filtrées. Le filtre a-t-il un effet lissant, comme attendu d'une moyenne mobile ?
- (c) Pourquoi serait-il incorrect, pour une prévision publiée chaque trimestre en temps réel, d'utiliser un filtre **non causal** (centré, utilisant y_{t+1}) ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $64 \times 64 \times 50 + 50 = 4096 \times 50 + 50 = 204\,800 + 50 = \mathbf{204\,850}$ paramètres.
(b) $(5 \times 5 \times 1 + 1) \times 16 = (25 + 1) \times 16 = 26 \times 16 = \mathbf{416}$ paramètres.
(c) Rapport = $204\,850/416 \approx \mathbf{492,4}$: la couche dense compte près de 500 fois plus de paramètres.




Correction — Exercice 2

- (a) $\lfloor (32 - 3 + 2 \times 1)/1 \rfloor + 1 = \lfloor 31/1 \rfloor + 1 = 31 + 1 = \mathbf{32}$: la taille est conservée, ce qui est l'effet recherché du remplissage.
(b) $\lfloor (28 - 5 + 0)/1 \rfloor + 1 = \lfloor 23/1 \rfloor + 1 = 23 + 1 = \mathbf{24}$.
(c) $\lfloor (28 - 5 + 2 \times 2)/2 \rfloor + 1 = \lfloor 27/2 \rfloor + 1 = \lfloor 13,5 \rfloor + 1 = 13 + 1 = \mathbf{14}$. Un pas supérieur à 1 **réduit** nettement la taille de sortie par rapport à un pas de 1 (ici 14 contre ce que donnerait un pas de 1 avec le même remplissage, $\lfloor 27/1 \rfloor + 1 = 28$) : le filtre saute des positions, sous-échantillonnant directement la carte de sortie.



Correction — Exercice 3

- (a) $t = 3 : z = 0,5 \times 9 + 0,3 \times 12 + 0,2 \times 10 + 0,1 = 4,5 + 3,6 + 2,0 + 0,1 = \mathbf{10,2}$. $\text{ReLU}(10,2) = \mathbf{10,2}$ (positif).
(b) $t = 4 : z = 0,5 \times 15 + 0,3 \times 9 + 0,2 \times 12 + 0,1 = 7,5 + 2,7 + 2,4 + 0,1 = \mathbf{12,7}$. $t = 5 : z = 0,5 \times 11 + 0,3 \times 15 + 0,2 \times 9 + 0,1 = 5,5 + 4,5 + 1,8 + 0,1 = \mathbf{11,9}$.
(c) Le filtre calcule, à chaque instant, une combinaison linéaire pondérée des trois dernières valeurs de la série (y_t, y_{t-1}, y_{t-2}) suivie d'une non-linéarité : c'est structuellement un MA(3), à ceci près que les poids (0,5 ; 0,3 ; 0,2) sont **appris** par apprentissage plutôt que fixés par une modélisation a priori, et qu'une activation ReLU est appliquée ensuite. Le filtre n'utilise jamais y_{t+1} parce qu'il est **causal** : en prévision, la valeur future n'est simplement pas encore observée au moment où la prédiction est produite.




2 Exercices cumulatifs (chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $(5 \times 1 + 1) \times 32 = 6 \times 32 = 192$ paramètres.

(b) Rapport = $672/192 = 3,5$: la couche dense compte 3,5 fois plus de paramètres que son équivalent convolutif.

(c) Variance He convolutive = $2/5 = 0,4$ (écart-type $\approx 0,6325$), contre variance He dense = $2/20 = 0,1$ (écart-type $\approx 0,3162$) pour la couche entièrement connectée. La couche convolutive, avec un champ récepteur plus étroit ($n_{\text{entrée}} = 5$ contre 20), reçoit une variance d'initialisation par poids plus large – cohérent avec la logique du chapitre 6 : moins d'entrées par neurone appelle des poids individuellement plus variables pour conserver la même variance totale du signal. Sur le fond, le passage à la convolution met bien en œuvre le remède « réseau plus petit » du chapitre 5 (192 au lieu de 672 paramètres pour cette couche), mais ce n'est pas une réduction arbitraire : elle exploite l'hypothèse structurelle, propre à une série temporelle, qu'un motif utile est **local** (les quelques dernières valeurs) et se répète de façon similaire à différents instants – exactement les deux premières des trois propriétés du chapitre (connectivité locale, partage des poids), appliquées ici à l'axe temporel plutôt qu'à une image.



3 Applications en sciences économiques


Correction — Exercice 5

(a) L'image compte $200 \times 200 \times 3 = 120\,000$ entrées (une par pixel et par canal de couleur). Couche dense = $120\,000 \times 100 + 100 = 12\,000\,100$ paramètres.

(b) $(7 \times 7 \times 3 + 1) \times 64 = (147 + 1) \times 64 = 148 \times 64 = 9\,472$ paramètres.

(c) Rapport = $12\,000\,100/9\,472 \approx 1\,267$: la couche dense compte plus de mille fois plus de paramètres. Oui, l'équivariance par translation est précieuse au-delà de ce seul gain en paramètres : une signature ou un motif caractéristique (numéro de chèque, motif de fraude) peut apparaître à des positions légèrement différentes d'un chèque scanné à l'autre selon le cadrage ; un réseau équivariant par translation le reconnaît quelle que soit sa position exacte dans l'image, alors qu'une couche entièrement connectée devrait apprendre à reconnaître séparément le même motif à chacune de ses positions

possibles – un gaspillage à la fois de paramètres et de données d'apprentissage.



Correction — Exercice 6

(a) $t = 3 : z = 0,6 \times 2,5 + 0,25 \times 1,8 + 0,15 \times 2,1 - 0,05 = 1,5 + 0,45 + 0,315 - 0,05 = \mathbf{2,215}$. $t = 4 : z = 0,6 \times 3,0 + 0,25 \times 2,5 + 0,15 \times 1,8 - 0,05 = 1,8 + 0,625 + 0,27 - 0,05 = \mathbf{2,645}$. $t = 5 : z = 0,6 \times 2,2 + 0,25 \times 3,0 + 0,15 \times 2,5 - 0,05 = 1,32 + 0,75 + 0,375 - 0,05 = \mathbf{2,395}$. $t = 6 : z = 0,6 \times 1,5 + 0,25 \times 2,2 + 0,15 \times 3,0 - 0,05 = 0,9 + 0,55 + 0,45 - 0,05 = \mathbf{1,850}$. Tous ces résultats étant positifs, ReLU les laisse inchangés.

(b) Sur les trimestres 3 à 6, la série brute varie entre 1,5 et 3,0 (étendue = 1,5), tandis que la série filtrée varie entre 1,850 et 2,645 (étendue $\approx 0,795$). L'étendue est presque **divisée par deux** : le filtre a bien un effet lissant net, cohérent avec sa nature de moyenne mobile pondérée.

(c) Un filtre non causal utilisant y_{t+1} nécessiterait de connaître la croissance du trimestre **suivant** au moment de publier la prévision du trimestre courant – une information qui n'existe simplement pas encore en temps réel. Ce serait la même erreur que l'utilisation de données futures dénoncée au chapitre sur le découpage temporel d'*Apprentissage statistique* : une performance illusoire en rétrospective, inexploitable et invérifiable en prévision réelle.

