

Chapitre 8

Les réseaux récurrents : RNN, LSTM, GRU

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre


Correction — Exercice 1

- (a) $z_1 = 0,8 \times 0 + 0,5 \times 1 + 0,1 = 0,6$. $h_1 = \tanh(0,6) \approx 0,5370$.
(b) $z_2 = 0,8 \times 0,5370 + 0,5 \times 2 + 0,1 \approx 0,4296 + 1,0 + 0,1 = 1,5296$. $h_2 = \tanh(1,5296) \approx 0,9104$.
(c) $z_3 = 0,8 \times 0,9104 + 0,5 \times (-1) + 0,1 \approx 0,7283 - 0,5 + 0,1 = 0,3283$. $h_3 = \tanh(0,3283) \approx 0,3170$. Oui : à chaque étape, h_t ne dépend que de h_{t-1} (l'état résumant tout le passé) et de x_t (l'entrée courante), exactement comme y_t dans un AR(1) ne dépend que de y_{t-1} et du choc courant ε_t – la seule différence étant la non-linéarité $\tanh$ et la dimension éventuellement vectorielle de h_t .




Correction — Exercice 2

- (a) $T = 10 : 0,9^{10} \approx 3,487 \times 10^{-1}$. $T = 50 : 0,9^{50} \approx 5,154 \times 10^{-3}$. $T = 100 : 0,9^{100} \approx 2,656 \times 10^{-5}$.
(b) Une séquence de 100 séances déroulée pour la rétropropagation dans le temps équivaut à un réseau de **100** couches effectives.
(c) Le facteur pour $T = 10$ ($\approx 0,349$) reste d'un ordre de grandeur raisonnable – le gradient est réduit de moins des deux tiers, pas anéanti : c'est cohérent avec le fait qu'un RNN simple retient encore de l'information sur une dizaine de pas. En revanche, le facteur pour $T = 100$ ($\approx 2,7 \times 10^{-5}$) est extrêmement faible : le gradient qui atteint les tout premiers pas est pratiquement nul, confirmant que le RNN simple ne peut pas apprendre de dépendances à si longue portée.



Correction — Exercice 3

- (a) $f_t = \sigma(1,5) \approx 0,8176$. $i_t = \sigma(-0,5) \approx 0,3775$. $g_t = \tanh(0,8) \approx 0,6640$. $o_t = \sigma(1,0) \approx 0,7311$.
(b) $C_t = 0,8176 \times 2,0 + 0,3775 \times 0,6640 \approx 1,6352 + 0,2507 = 1,8858$.
(c) $h_t = 0,7311 \times \tanh(1,8858) \approx 0,7311 \times 0,9548 \approx 0,6982$. La porte d'oubli $f_t \approx 0,8176$ est proche de 1 : elle laisse passer la **majorité** de la mémoire précédente (environ 82 %), n'en effaçant qu'une petite part.




2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Un RNN simple qui déroule 20 pas de temps pour la rétropropagation dans le temps constitue, exactement comme une couche sigmoïde profonde, une chaîne de 20 multiplications de facteurs locaux : le chiffage du chapitre 2 ($9,1 \times 10^{-13}$ après 20 couches sigmoïdes) s'applique donc directement, à ceci près que ces 20 « couches » sont ici les 20 pas de temps déroulés plutôt que 20 couches empilées dans l'espace – c'est précisément la lecture du chapitre 4 « appliquée au temps ».

(b) Le remède est le **LSTM** (ou le **GRU**) : son état de cellule transporté par des opérations essentiellement **additives** (via la porte d'oubli proche de 1) offre au gradient un chemin sans facteur multiplicatif à chaque pas, exactement comme une connexion résiduelle $y = F(x) + x$ du chapitre 7 offre un chemin direct à travers les couches.

(c) Paramètres du RNN = $H \times H + H \times 1 + H = 16 \times 16 + 16 + 16 = 256 + 32 = 288$. Rapport = $1217/288 \approx 4,23$. Oui, ce gain répond à la même logique que le partage des poids en convolution : les **mêmes** poids W_h, W_x, b servent à **chaque** pas de temps, au lieu d'avoir des poids séparés pour chacune des 20 positions temporelles – exactement comme un filtre convolutif partage ses poids à travers toutes les positions spatiales. Ce gain, cependant, ne suffit **pas** à faire du RNN simple un bon choix ici : le problème n'est pas le nombre de paramètres mais la portée de la mémoire, et un RNN simple qui ne retient qu'une dizaine de pas serait incapable d'exploiter les 20 rendements nécessaires – il faudrait au minimum passer à un LSTM ou un GRU pour espérer couvrir cette portée.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $f_t = \sigma(0,8) \approx 0,6900$. $i_t = \sigma(1,2) \approx 0,7685$. $g_t = \tanh(-0,3) \approx -0,2913$. $o_t = \sigma(0,6) \approx 0,6457$.

(b) $C_t = 0,6900 \times 1,5 + 0,7685 \times (-0,2913) \approx 1,0350 - 0,2239 = 0,8111$. $h_t = 0,6457 \times \tanh(0,8111) \approx 0,6457 \times 0,6706 \approx 0,4327$.

(c) Une porte d'entrée largement ouverte ($i_t \approx 0,77$) combinée à un candidat négatif ($g_t \approx -0,29$) signifie que le modèle **intègre fortement** ce signal de dégradation dans sa mémoire : le mois de paiement dégradé n'est pas ignoré, il pèse significativement sur l'état de cellule. C'est

un comportement souhaitable pour un modèle de risque : une porte d'entrée qui laisserait passer l'information seulement quand elle est **significative** (ici, un événement de paiement inhabituel) est exactement ce qui distingue un LSTM d'un simple RNN qui mélangerait uniformément toute l'information, bonne ou mauvaise, à chaque pas.

Correction — Exercice 6

(a) $y_1 = 0,7 \times 100 + 2 = 72,0$. $y_2 = 0,7 \times 72 + (-1) = 49,4$. $y_3 = 0,7 \times 49,4 + 3 = 37,58$. $y_4 = 0,7 \times 37,58 + (-2) = 24,306$.

(b) $h_1 = 0,7 \times 100 + 2 = 72,0$. $h_2 = 0,7 \times 72 + (-1) = 49,4$. $h_3 = 0,7 \times 49,4 + 3 = 37,58$. $h_4 = 0,7 \times 37,58 + (-2) = 24,306$.

(c) Les deux trajectoires sont **rigoureusement identiques**, valeur par valeur. Cela confirme bien la lecture du chapitre : un RNN dont l'activation g est l'identité (au lieu d'un tanh ou d'une sigmoïde) et dont le poids d'entrée joue le même rôle que le choc ε_t d'un AR(1) se réduit exactement à ce processus autorégressif. C'est la **non-linéarité** g – absente ici – qui, en pratique, distingue véritablement un RNN d'un simple modèle autorégressif linéaire, en lui permettant de capter des dynamiques que l'AR(1) ne peut pas représenter.

