

Apprentissage profond

Chapitre 8 : Les réseaux récurrents : RNN, LSTM, GRU

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Dérouler un RNN simple

Un RNN scalaire ($h_t \in \mathbb{R}$) obéit à $h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$, avec $W_h = 0,8$, $W_x = 0,5$, $b = 0,1$, et $h_0 = 0$. La séquence d'entrée est $x = (1; 2; -1)$.

- (a) Calculer $z_1 = W_h h_0 + W_x x_1 + b$, puis $h_1 = \tanh(z_1)$.
- (b) Calculer z_2 et h_2 , en utilisant h_1 obtenu en (a).
- (c) Calculer z_3 et h_3 . Ce calcul est-il cohérent avec la lecture du chapitre selon laquelle un RNN est un « AR non linéaire à état caché » : chaque h_t dépend-il bien uniquement de h_{t-1} et de x_t , comme le ferait $y_t = \phi y_{t-1} + \varepsilon_t$?

Exercice 2 — Atténuation du gradient dans la rétropropagation dans le temps

Le facteur local au mieux, à chaque pas de temps remonté, vaut 0,9.

- (a) Calculer le facteur cumulé après $T = 10$ pas, $T = 50$ pas et $T = 100$ pas.
- (b) Une séquence financière de 100 séances correspond, une fois dépliée pour la rétropropagation dans le temps, à un réseau de combien de couches effectives ?
- (c) Le chapitre indique qu'un RNN simple retient efficacement « une dizaine de pas, guère plus ». Le facteur obtenu pour $T = 10$ en (a) est-il déjà préoccupant ? Et celui pour $T = 100$?

Exercice 3 — Les trois portes d'un LSTM

À un instant t , les pré-activations des portes d'un LSTM valent : oubli $z_f = 1,5$, entrée $z_i = -0,5$, candidat $z_g = 0,8$ (activation $\tanh$), sortie $z_o = 1,0$. L'état de cellule précédent vaut $C_{t-1} = 2,0$.

- (a) Calculer les valeurs des portes $f_t = \sigma(z_f)$, $i_t = \sigma(z_i)$, $g_t = \tanh(z_g)$ et $o_t = \sigma(z_o)$.
- (b) Calculer le nouvel état de cellule $C_t = f_t \times C_{t-1} + i_t \times g_t$.
- (c) Calculer la sortie cachée $h_t = o_t \times \tanh(C_t)$. La porte d'oubli, ici proche de 0,82, laisse-t-elle passer la majorité ou la minorité de la mémoire précédente ?

2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Un RNN aurait-il mieux valu pour le réseau du chapitre 1 ?

Le réseau officiel du chapitre 1 reçoit les 20 derniers rendements comme un vecteur d'entrée unique, traité par une couche dense. On envisage une alternative : un RNN scalaire de largeur $H = 16$ (la largeur de la seconde couche cachée du chapitre 1) qui parcourrait ces 20 rendements **pas à pas**.

- (a) Le chapitre 2 avait chiffré le facteur d'atténuation au mieux du gradient après 20 couches sigmoïdes : $9,1 \times 10^{-13}$ (table du chapitre 2, reprise au chapitre 4). Pourquoi ce chiffre est-il directement pertinent pour un RNN simple qui déroule 20 pas de temps ?
- (b) Quel remède, introduit dans ce chapitre et déjà annoncé comme « la même idée que les connexions résiduelles du chapitre 7 », permettrait d'éviter cette atténuation en transportant l'état par des opérations essentiellement additives ?
- (c) Calculer le nombre de paramètres d'un RNN scalaire de largeur $H = 16$ (matrice W_h de taille $H \times H$, vecteur W_x de taille $H \times 1$, biais de taille H), puis le rapport entre les 1 217 paramètres du réseau dense du chapitre 1 et ce nombre. Ce gain, dû au partage des poids entre pas de temps, répond-il à la même logique que le partage des poids en convolution (chapitre 7) ? Sachant que le RNN simple ne retient qu'une dizaine de pas alors qu'il en faudrait 20, ce gain en paramètres suffit-il à en faire un bon choix architectural ici ?

3 Applications en sciences économiques

Exercice 5 — Les portes d'un LSTM pour un historique de paiement

Un modèle de scoring séquentiel traite l'historique mensuel de paiement d'un emprunteur. À un mois donné, les pré-activations des portes valent : oubli $z_f = 0,8$, entrée $z_i = 1,2$, candidat $z_g = -0,3$, sortie $z_o = 0,6$, avec $C_{t-1} = 1,5$.

- (a) Calculer les quatre valeurs de portes f_t , i_t , g_t et o_t .
- (b) Calculer C_t et h_t .
- (c) La porte d'entrée $i_t \approx 0,77$ est plus ouverte que la porte de sortie $o_t \approx 0,65$. Que signifie, en termes de gestion du risque, une porte d'entrée largement ouverte combinée à un candidat g_t négatif (un mois de paiement dégradé), pour l'évolution de la mémoire du modèle ?

Exercice 6 — RNN linéaire et processus AR(1) : la même trajectoire


Un institut compare un processus AR(1), $y_t = \phi y_{t-1} + \varepsilon_t$ avec $\phi = 0,7$ et $y_0 = 100$, à un RNN scalaire à activation **identité** (sans non-linéarité), $h_t = \phi h_{t-1} + \varepsilon_t$, avec les mêmes chocs $\varepsilon = (0; 2; -1; 3; -2)$ et $h_0 = 100$.

- (a) Calculer les quatre premières valeurs de la trajectoire AR(1) (y_1 à y_4).
- (b) Calculer les quatre premières valeurs de la trajectoire du RNN linéaire (h_1 à h_4).
- (c) Les deux trajectoires sont-elles identiques ? Cela confirme-t-il la lecture du chapitre selon laquelle un RNN à activation identité et sans terme d'entrée séparé W_x distinct de 1 se réduit exactement à un processus AR(1), la non-linéarité g étant ce qui distingue véritablement les deux modèles en général ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $z_1 = 0,8 \times 0 + 0,5 \times 1 + 0,1 = 0,6$. $h_1 = \tanh(0,6) \approx 0,5370$.
(b) $z_2 = 0,8 \times 0,5370 + 0,5 \times 2 + 0,1 \approx 0,4296 + 1,0 + 0,1 = 1,5296$. $h_2 = \tanh(1,5296) \approx 0,9104$.
(c) $z_3 = 0,8 \times 0,9104 + 0,5 \times (-1) + 0,1 \approx 0,7283 - 0,5 + 0,1 = 0,3283$. $h_3 = \tanh(0,3283) \approx 0,3170$. Oui : à chaque étape, h_t ne dépend que de h_{t-1} (l'état résumant tout le passé) et de x_t (l'entrée courante), exactement comme y_t dans un AR(1) ne dépend que de y_{t-1} et du choc courant ε_t – la seule différence étant la non-linéarité $\tanh$ et la dimension éventuellement vectorielle de h_t .




Correction — Exercice 2

- (a) $T = 10 : 0,9^{10} \approx 3,487 \times 10^{-1}$. $T = 50 : 0,9^{50} \approx 5,154 \times 10^{-3}$. $T = 100 : 0,9^{100} \approx 2,656 \times 10^{-5}$.
(b) Une séquence de 100 séances déroulée pour la rétropropagation dans le temps équivaut à un réseau de **100** couches effectives.
(c) Le facteur pour $T = 10$ ($\approx 0,349$) reste d'un ordre de grandeur raisonnable – le gradient est réduit de moins des deux tiers, pas anéanti : c'est cohérent avec le fait qu'un RNN simple retient encore de l'information sur une dizaine de pas. En revanche, le facteur pour $T = 100$ ($\approx 2,7 \times 10^{-5}$) est extrêmement faible : le gradient qui atteint les tout premiers pas est pratiquement nul, confirmant que le RNN simple ne peut pas apprendre de dépendances à si longue portée.



Correction — Exercice 3

- (a) $f_t = \sigma(1,5) \approx 0,8176$. $i_t = \sigma(-0,5) \approx 0,3775$. $g_t = \tanh(0,8) \approx 0,6640$. $o_t = \sigma(1,0) \approx 0,7311$.
(b) $C_t = 0,8176 \times 2,0 + 0,3775 \times 0,6640 \approx 1,6352 + 0,2507 = 1,8858$.
(c) $h_t = 0,7311 \times \tanh(1,8858) \approx 0,7311 \times 0,9548 \approx 0,6982$. La porte d'oubli $f_t \approx 0,8176$ est proche de 1 : elle laisse passer la **majorité** de la mémoire précédente (environ 82 %), n'en effaçant qu'une petite part.




2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) Un RNN simple qui déroule 20 pas de temps pour la rétropropagation dans le temps constitue, exactement comme une couche sigmoïde profonde, une chaîne de 20 multiplications de facteurs locaux : le chiffage du chapitre 2 ($9,1 \times 10^{-13}$ après 20 couches sigmoïdes) s'applique donc directement, à ceci près que ces 20 « couches » sont ici les 20 pas de temps déroulés plutôt que 20 couches empilées dans l'espace – c'est précisément la lecture du chapitre 4 « appliquée au temps ».

(b) Le remède est le **LSTM** (ou le **GRU**) : son état de cellule transporté par des opérations essentiellement **additives** (via la porte d'oubli proche de 1) offre au gradient un chemin sans facteur multiplicatif à chaque pas, exactement comme une connexion résiduelle $y = F(x) + x$ du chapitre 7 offre un chemin direct à travers les couches.

(c) Paramètres du RNN = $H \times H + H \times 1 + H = 16 \times 16 + 16 + 16 = 256 + 32 = 288$. Rapport = $1\,217/288 \approx 4,23$. Oui, ce gain répond à la même logique que le partage des poids en convolution : les **mêmes** poids W_h, W_x, b servent à **chaque** pas de temps, au lieu d'avoir des poids séparés pour chacune des 20 positions temporelles – exactement comme un filtre convolutif partage ses poids à travers toutes les positions spatiales. Ce gain, cependant, ne suffit **pas** à faire du RNN simple un bon choix ici : le problème n'est pas le nombre de paramètres mais la portée de la mémoire, et un RNN simple qui ne retient qu'une dizaine de pas serait incapable d'exploiter les 20 rendements nécessaires – il faudrait au minimum passer à un LSTM ou un GRU pour espérer couvrir cette portée.



3 Applications en sciences économiques

Correction — Exercice 5

(a) $f_t = \sigma(0,8) \approx 0,6900$. $i_t = \sigma(1,2) \approx 0,7685$. $g_t = \tanh(-0,3) \approx -0,2913$. $o_t = \sigma(0,6) \approx 0,6457$.

(b) $C_t = 0,6900 \times 1,5 + 0,7685 \times (-0,2913) \approx 1,0350 - 0,2239 = 0,8111$. $h_t = 0,6457 \times \tanh(0,8111) \approx 0,6457 \times 0,6706 \approx 0,4327$.

(c) Une porte d'entrée largement ouverte ($i_t \approx 0,77$) combinée à un candidat négatif ($g_t \approx -0,29$) signifie que le modèle **intègre fortement** ce signal de dégradation dans sa mémoire : le mois de paiement dégradé n'est pas ignoré, il pèse significativement sur l'état de cellule. C'est

un comportement souhaitable pour un modèle de risque : une porte d'entrée qui laisserait passer l'information seulement quand elle est **significative** (ici, un événement de paiement inhabituel) est exactement ce qui distingue un LSTM d'un simple RNN qui mélangerait uniformément toute l'information, bonne ou mauvaise, à chaque pas.

Correction — Exercice 6

(a) $y_1 = 0,7 \times 100 + 2 = 72,0$. $y_2 = 0,7 \times 72 + (-1) = 49,4$. $y_3 = 0,7 \times 49,4 + 3 = 37,58$. $y_4 = 0,7 \times 37,58 + (-2) = 24,306$.

(b) $h_1 = 0,7 \times 100 + 2 = 72,0$. $h_2 = 0,7 \times 72 + (-1) = 49,4$. $h_3 = 0,7 \times 49,4 + 3 = 37,58$. $h_4 = 0,7 \times 37,58 + (-2) = 24,306$.

(c) Les deux trajectoires sont **rigoureusement identiques**, valeur par valeur. Cela confirme bien la lecture du chapitre : un RNN dont l'activation g est l'identité (au lieu d'un tanh ou d'une sigmoïde) et dont le poids d'entrée joue le même rôle que le choc ε_t d'un AR(1) se réduit exactement à ce processus autorégressif. C'est la **non-linéarité** g – absente ici – qui, en pratique, distingue véritablement un RNN d'un simple modèle autorégressif linéaire, en lui permettant de capter des dynamiques que l'AR(1) ne peut pas représenter.

