

Chapitre 8

Les réseaux récurrents : RNN, LSTM, GRU

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage profond

1 Exercices du chapitre

Exercice 1 — Dérouler un RNN simple

Un RNN scalaire ($h_t \in \mathbb{R}$) obéit à $h_t = \tanh(W_h h_{t-1} + W_x x_t + b)$, avec $W_h = 0,8$, $W_x = 0,5$, $b = 0,1$, et $h_0 = 0$. La séquence d'entrée est $x = (1; 2; -1)$.

- (a) Calculer $z_1 = W_h h_0 + W_x x_1 + b$, puis $h_1 = \tanh(z_1)$.
- (b) Calculer z_2 et h_2 , en utilisant h_1 obtenu en (a).
- (c) Calculer z_3 et h_3 . Ce calcul est-il cohérent avec la lecture du chapitre selon laquelle un RNN est un « AR non linéaire à état caché » : chaque h_t dépend-il bien uniquement de h_{t-1} et de x_t , comme le ferait $y_t = \phi y_{t-1} + \varepsilon_t$?

Exercice 2 — Atténuation du gradient dans la rétropropagation dans le temps

Le facteur local au mieux, à chaque pas de temps remonté, vaut 0,9.

- (a) Calculer le facteur cumulé après $T = 10$ pas, $T = 50$ pas et $T = 100$ pas.
- (b) Une séquence financière de 100 séances correspond, une fois dépliée pour la rétropropagation dans le temps, à un réseau de combien de couches effectives ?
- (c) Le chapitre indique qu'un RNN simple retient efficacement « une dizaine de pas, guère plus ». Le facteur obtenu pour $T = 10$ en (a) est-il déjà préoccupant ? Et celui pour $T = 100$?

Exercice 3 — Les trois portes d'un LSTM

À un instant t , les pré-activations des portes d'un LSTM valent : oubli $z_f = 1,5$, entrée $z_i = -0,5$, candidat $z_g = 0,8$ (activation $\tanh$), sortie $z_o = 1,0$. L'état de cellule précédent vaut $C_{t-1} = 2,0$.

- (a) Calculer les valeurs des portes $f_t = \sigma(z_f)$, $i_t = \sigma(z_i)$, $g_t = \tanh(z_g)$ et $o_t = \sigma(z_o)$.
- (b) Calculer le nouvel état de cellule $C_t = f_t \times C_{t-1} + i_t \times g_t$.
- (c) Calculer la sortie cachée $h_t = o_t \times \tanh(C_t)$. La porte d'oubli, ici proche de 0,82, laisse-t-elle passer la majorité ou la minorité de la mémoire précédente ?

2 Exercices cumulatifs (chapitre 8, chapitre 7, chapitre 6, chapitre 5, chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Un RNN aurait-il mieux valu pour le réseau du chapitre 1 ?

Le réseau officiel du chapitre 1 reçoit les 20 derniers rendements comme un vecteur d'entrée unique, traité par une couche dense. On envisage une alternative : un RNN scalaire de largeur $H = 16$ (la largeur de la seconde couche cachée du chapitre 1) qui parcourrait ces 20 rendements **pas à pas**.

- (a) Le chapitre 2 avait chiffré le facteur d'atténuation au mieux du gradient après 20 couches sigmoïdes : $9,1 \times 10^{-13}$ (table du chapitre 2, reprise au chapitre 4). Pourquoi ce chiffre est-il directement pertinent pour un RNN simple qui déroule 20 pas de temps ?
- (b) Quel remède, introduit dans ce chapitre et déjà annoncé comme « la même idée que les connexions résiduelles du chapitre 7 », permettrait d'éviter cette atténuation en transportant l'état par des opérations essentiellement additives ?
- (c) Calculer le nombre de paramètres d'un RNN scalaire de largeur $H = 16$ (matrice W_h de taille $H \times H$, vecteur W_x de taille $H \times 1$, biais de taille H), puis le rapport entre les 1 217 paramètres du réseau dense du chapitre 1 et ce nombre. Ce gain, dû au partage des poids entre pas de temps, répond-il à la même logique que le partage des poids en convolution (chapitre 7) ? Sachant que le RNN simple ne retient qu'une dizaine de pas alors qu'il en faudrait 20, ce gain en paramètres suffit-il à en faire un bon choix architectural ici ?

3 Applications en sciences économiques

Exercice 5 — Les portes d'un LSTM pour un historique de paiement

Un modèle de scoring séquentiel traite l'historique mensuel de paiement d'un emprunteur. À un mois donné, les pré-activations des portes valent : oubli $z_f = 0,8$, entrée $z_i = 1,2$, candidat $z_g = -0,3$, sortie $z_o = 0,6$, avec $C_{t-1} = 1,5$.

- (a) Calculer les quatre valeurs de portes f_t , i_t , g_t et o_t .
- (b) Calculer C_t et h_t .
- (c) La porte d'entrée $i_t \approx 0,77$ est plus ouverte que la porte de sortie $o_t \approx 0,65$. Que signifie, en termes de gestion du risque, une porte d'entrée largement ouverte combinée à un candidat g_t négatif (un mois de paiement dégradé), pour l'évolution de la mémoire du modèle ?

Exercice 6 — RNN linéaire et processus AR(1) : la même trajectoire

Un institut compare un processus AR(1), $y_t = \phi y_{t-1} + \varepsilon_t$ avec $\phi = 0,7$ et $y_0 = 100$, à un RNN scalaire à activation **identité** (sans non-linéarité), $h_t = \phi h_{t-1} + \varepsilon_t$, avec les mêmes chocs $\varepsilon = (0; 2; -1; 3; -2)$ et $h_0 = 100$.

- (a) Calculer les quatre premières valeurs de la trajectoire AR(1) (y_1 à y_4).
- (b) Calculer les quatre premières valeurs de la trajectoire du RNN linéaire (h_1 à h_4).
- (c) Les deux trajectoires sont-elles identiques ? Cela confirme-t-il la lecture du chapitre selon laquelle un RNN à activation identité et sans terme d'entrée séparé W_x distinct de 1 se réduit exactement à un processus AR(1), la non-linéarité g étant ce qui distingue véritablement les deux modèles en général ?