

Apprentissage profond

Chapitre 4 : La rétropropagation

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage profond

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Passe avant et passe arrière sur un réseau à deux poids

Un réseau à un seul chemin enchaîne : entrée $x = 2$, poids $w_1 = 0,5$ vers un neurone caché sigmoïde ($z_1 = w_1 x$, $a_1 = \sigma(z_1)$), puis poids $w_2 = -0,4$ vers un neurone de sortie sigmoïde ($z_2 = w_2 a_1$, $\hat{y} = \sigma(z_2)$). La cible est $y = 1$ et la perte est $L = \frac{1}{2}(y - \hat{y})^2$.

- (a) Passe avant : calculer z_1 , a_1 , z_2 et $\hat{y}$.
- (b) Passe arrière : calculer $\partial L / \partial \hat{y} = \hat{y} - y$, puis $\delta_2 = (\partial L / \partial \hat{y}) \times \sigma'(z_2)$, puis $\partial L / \partial w_2 = \delta_2 \times a_1$.
- (c) Poursuivre la remontée : calculer $\delta_1 = w_2 \times \delta_2 \times \sigma'(z_1)$, puis $\partial L / \partial w_1 = \delta_1 \times x$.

Exercice 2 — La règle de la chaîne, à trois étages

On pose $u = x^2$, $v = 3u + 1$, $y = v^3$, et l'on souhaite dy/dx en $x = 2$.

- (a) Calculer u , v et y en $x = 2$.
- (b) Calculer dy/dv , dv/du et du/dx en ce point, puis en déduire $dy/dx = (dy/dv) \times (dv/du) \times (du/dx)$.
- (c) Vérifier ce résultat en écrivant y directement en fonction de x ($y = (3x^2 + 1)^3$) et en calculant dy/dx par la formule habituelle de dérivation d'une puissance composée.

Exercice 3 — Un produit de facteurs qui s'annule malgré des termes supérieurs à un

La remontée du gradient sur 5 couches produit les facteurs locaux successifs 0,2 ; 1,5 ; 0,1 ; 2,0 ; 0,05.

- (a) Calculer le produit de ces cinq facteurs.
- (b) Deux de ces facteurs sont supérieurs à 1. Le produit final évanouit-il, explose-t-il, ou reste-t-il proche de 1 ?
- (c) Que faut-il en conclure sur la nécessité d'examiner **chaque** facteur d'une chaîne, plutôt que sa seule moyenne ou sa seule tendance générale ?

2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Rétropropager à travers le neurone de l'introduction

Le neurone de l'introduction ($w_1 = 0,5$, $w_2 = -0,3$, $b = 0,2$, $x_1 = 4$, $x_2 = 1$) calculait $z = 1,9$ et $a = \sigma(1,9) \approx 0,8699$. On ajoute maintenant à ce neurone une couche de sortie : a devient l'activation cachée a_1 , transmise avec un poids $w_{\text{sortie}} = 0,6$ et un biais $b_{\text{sortie}} = -0,1$ vers un neurone de sortie sigmoïde, pour une cible $y = 1$ (perte d'entropie croisée du chapitre 2).

- (a) Calculer $z_{\text{sortie}} = w_{\text{sortie}} \times a_1 + b_{\text{sortie}}$, puis $\hat{y} = \sigma(z_{\text{sortie}})$.
- (b) Pour une sortie sigmoïde combinée à une perte d'entropie croisée, on peut montrer que $\partial L / \partial z_{\text{sortie}} = \hat{y} - y$ directement (une simplification classique). En déduire δ_{sortie} , puis $\partial L / \partial w_{\text{sortie}} = \delta_{\text{sortie}} \times a_1$.
- (c) Calculer $\delta_{\text{caché}} = w_{\text{sortie}} \times \delta_{\text{sortie}} \times \sigma'(z)$ (avec $z = 1,9$, le z du neurone de l'introduction), puis $\partial L / \partial w_1 = \delta_{\text{caché}} \times x_1$. Enfin, en appliquant la règle de mise à jour du chapitre 3 avec $\eta = 0,05$, calculer la nouvelle valeur de w_{sortie} après un pas de descente de gradient.

3 Applications en sciences économiques

Exercice 5 — Rétropropager dans un scoring de crédit à deux couches

Un modèle de scoring associe à un dossier de crédit une variable d'entrée normalisée $x = 3$, un poids caché $w_1 = 0,3$ et un poids de sortie $w_2 = 0,7$, avec activations sigmoïdes aux deux couches ($z_1 = w_1 x$, $a_1 = \sigma(z_1)$, $z_2 = w_2 a_1$, $\hat{y} = \sigma(z_2)$). Le dossier n'a en réalité **pas** fait défaut ($y = 0$).

- (a) Calculer z_1 , a_1 , z_2 et $\hat{y}$.
- (b) Pour cette combinaison sigmoïde + entropie croisée, $\partial L / \partial z_2 = \hat{y} - y$. Calculer δ_2 , puis $\partial L / \partial w_2 = \delta_2 \times a_1$.
- (c) Calculer $\delta_1 = w_2 \times \delta_2 \times \sigma'(z_1)$, puis $\partial L / \partial w_1 = \delta_1 \times x$. Le signe de ces deux gradients est-il cohérent avec le fait que le modèle a surestimé le risque de ce dossier ($\hat{y} > y$) ?

Exercice 6 — Diagnostiquer un gradient qui explose dans un modèle de prévision


Un réseau récurrent de prévision macroéconomique (chapitre 8) remonte le gradient sur 8 pas de temps, avec les facteurs locaux successifs suivants : 1,4 ; 1,3 ; 1,5 ; 1,2 ; 1,4 ; 1,3 ; 1,5 ; 1,2.

- (a) Calculer le produit de ces huit facteurs.
- (b) Ce produit signale-t-il un gradient qui s'évanouit ou un gradient qui explose ?
- (c) Parmi les remèdes évoqués dans le chapitre pour ce problème, lequel s'applique directement à cette situation, et en quoi consiste-t-il concrètement ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) $z_1 = 0,5 \times 2 = 1$. $a_1 = \sigma(1) \approx 0,7311$. $z_2 = -0,4 \times 0,7311 \approx -0,2924$. $\hat{y} = \sigma(-0,2924) \approx 0,4274$.
 (b) $\partial L / \partial \hat{y} = \hat{y} - y = 0,4274 - 1 = -0,5726$. $\sigma'(z_2) = \hat{y}(1 - \hat{y}) \approx 0,4274 \times 0,5726 \approx 0,2447$. $\delta_2 = -0,5726 \times 0,2447 \approx -0,1401$. $\partial L / \partial w_2 = \delta_2 \times a_1 \approx -0,1401 \times 0,7311 \approx -0,1024$.
 (c) $\sigma'(z_1) = a_1(1 - a_1) \approx 0,7311 \times 0,2689 \approx 0,1966$. $\delta_1 = w_2 \times \delta_2 \times \sigma'(z_1) = (-0,4) \times (-0,1401) \times 0,1966 \approx 0,01102$. $\partial L / \partial w_1 = \delta_1 \times x \approx 0,01102 \times 2 \approx 0,02204$.



Correction — Exercice 2

- (a) $u = 2^2 = 4$. $v = 3 \times 4 + 1 = 13$. $y = 13^3 = 2197$.
 (b) $dy/dv = 3v^2 = 3 \times 169 = 507$. $dv/du = 3$. $du/dx = 2x = 4$. $dy/dx = 507 \times 3 \times 4 = 6084$.
 (c) $y = (3x^2 + 1)^3$, donc $dy/dx = 3(3x^2 + 1)^2 \times 6x = 18x(3x^2 + 1)^2 = 18 \times 2 \times 13^2 = 18 \times 2 \times 169 = 6084$.
 Les deux méthodes coïncident exactement.



Correction — Exercice 3

- (a) Produit = $0,2 \times 1,5 \times 0,1 \times 2,0 \times 0,05 = 0,003$.
 (b) Malgré deux facteurs supérieurs à 1 (1,5 et 2,0), le produit final **évanouit** : il vaut 0,003, très proche de 0.
 (c) Il faut examiner l'ensemble du produit, et non se fier à une impression de moyenne ou de tendance : quelques facteurs franchement inférieurs à 1 (ici 0,2, 0,1 et 0,05) suffisent à dominer le produit final, même en présence de facteurs amplificateurs. Un raisonnement qui se contenterait de compter « autant de facteurs > 1 que de facteurs < 1 » serait trompeur.




2 Exercices cumulatifs (chapitre 4, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

- (a) $z_{\text{sortie}} = 0,6 \times 0,8699 - 0,1 \approx 0,4219$. $\hat{y} = \sigma(0,4219) \approx 0,6039$.
 (b) $\delta_{\text{sortie}} = \hat{y} - y = 0,6039 - 1 = -0,3961$. $\partial L / \partial w_{\text{sortie}} = \delta_{\text{sortie}} \times a_1 = -0,3961 \times 0,8699 \approx -0,3445$.
 (c) $\sigma'(z) = a_1(1 - a_1) = 0,8699 \times 0,1301 \approx 0,1132$ (avec $z = 1,9$, le z de l'introduction). $\delta_{\text{caché}} = w_{\text{sortie}} \times \delta_{\text{sortie}} \times \sigma'(z) = 0,6 \times (-0,3961) \times 0,1132 \approx -0,0269$. $\partial L / \partial w_1 = \delta_{\text{caché}} \times x_1 = -0,0269 \times 4 \approx -0,1076$. Mise à jour du chapitre 3 : $w_{\text{sortie}} \leftarrow w_{\text{sortie}} - \eta \times \partial L / \partial w_{\text{sortie}} = 0,6 - 0,05 \times (-0,3445) = 0,6 + 0,01723 \approx 0,6172$.
 Le poids **augmente** légèrement : c'est cohérent, puisque le réseau sous-estimait $\hat{y}$ par rapport à la cible

$y = 1$ ($\hat{y} = 0,6039 < 1$), et qu'augmenter w_{sortie} pousse $\hat{y}$ vers le haut.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $z_1 = 0,3 \times 3 = 0,9$. $a_1 = \sigma(0,9) \approx 0,7109$. $z_2 = 0,7 \times 0,7109 \approx 0,4977$. $\hat{y} = \sigma(0,4977) \approx 0,6219$.
 (b) $\delta_2 = \hat{y} - y = 0,6219 - 0 = 0,6219$. $\partial L / \partial w_2 = \delta_2 \times a_1 = 0,6219 \times 0,7109 \approx 0,4422$.
 (c) $\sigma'(z_1) = a_1(1 - a_1) = 0,7109 \times 0,2891 \approx 0,2056$. $\delta_1 = w_2 \times \delta_2 \times \sigma'(z_1) = 0,7 \times 0,6219 \times 0,2056 \approx 0,0895$.
 $\partial L / \partial w_1 = \delta_1 \times x = 0,0895 \times 3 \approx 0,2684$. Les deux gradients sont **positifs**, ce qui est cohérent : le modèle a prédit $\hat{y} \approx 0,62$ pour un dossier qui n'a pas fait défaut ($y = 0$), donc il a **surestimé** le risque. Un gradient positif signifie que la descente de gradient (chapitre 3) va **diminuer** w_1 et w_2 , ce qui réduira $\hat{y}$ lors de la prochaine passe – exactement la correction souhaitée.

Correction — Exercice 6

- (a) Produit = $1,4 \times 1,3 \times 1,5 \times 1,2 \times 1,4 \times 1,3 \times 1,5 \times 1,2 \approx 10,73$.
 (b) Ce produit, très supérieur à 1, signale un gradient qui **explose**, et non qui s'évanouit.
 (c) Le remède directement applicable est l'**écrêtage du gradient** (gradient clipping) : il consiste à plafonner la norme du gradient avant la mise à jour des poids, de sorte qu'un gradient anormalement grand – comme celui produit ici par ce produit de facteurs supérieurs à 1 – ne provoque pas une mise à jour démesurée susceptible d'envoyer les poids à l'infini ou de rendre la perte indéfinie.

