

Apprentissage profond

Chapitre 3 : La descente de gradient et ses variantes

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger · 25 septembre 2026

Plan du chapitre

Le principe

Le taux d'apprentissage

Les trois régimes de descente

Les optimiseurs

Ce qu'il faut retenir

Le principe

Descendre dans le sens de la pente

La règle de mise à jour

$$w \leftarrow w - \eta \frac{\partial L}{\partial w}$$

Le gradient indique la direction de plus forte **montée** ; on va donc dans le sens opposé. η est le **taux d'apprentissage**.

C'est le chapitre 6 de Mathématiques pour la gestion

Chercher un minimum en annulant les dérivées partielles est exactement la condition du premier ordre à plusieurs variables.

La différence est qu'ici le système ne se résout pas : il y a des millions de paramètres, et l'on **descend pas à pas** au lieu de résoudre.

Le taux d'apprentissage

Le paramètre le plus important du cours

Une descente entièrement calculable

Minimisons $L(w) = w^2$, de dérivée $2w$, en partant de $w = 1$.

La règle donne $w \leftarrow w(1 - 2\eta)$: chaque pas multiplie w par un facteur fixe.

η	Facteur	Trajectoire
0,1	+0,8	$1 \rightarrow 0,8 \rightarrow 0,64 \rightarrow 0,512 \rightarrow 0,41$
1,1	-1,2	$1 \rightarrow -1,2 \rightarrow 1,44 \rightarrow -1,73 \rightarrow 2,07$

Le premier **converge** vers zéro. Le second **oscille en s'éloignant** : la descente diverge.

La condition de convergence, ici

Les trois régimes de descente

Combien d'observations par pas

Batch, stochastique, mini-batch

Régime	Observations par pas	Caractère
Batch	toutes	coûteux, trajectoire lisse
Stochastique	une seule	rapide, très bruité
Mini-batch	32 à 256	le compromis employé partout

Pourquoi le bruit est utile

On pourrait croire que la descente batch, plus précise, est préférable.

Le bruit du mini-batch aide en réalité à **sortir des minima locaux médiocres** et des plateaux. Il agit comme une régularisation légère.

De plus, un pas approximatif calculé cent fois vaut mieux qu'un pas exact calculé une fois : à temps égal, le mini-batch progresse davantage.

Définition

Une **époque** est un passage complet sur les données d'apprentissage.

Avec 1 000 observations et des lots de 32, une époque compte environ 32 mises à jour.

Les optimiseurs

Trois améliorations successives

Le momentum

On accumule une **inertie** : le pas courant garde une part du précédent.

Cela lisse les oscillations dans les directions instables et accélère dans les directions constantes — comme une bille qui prend de la vitesse dans une vallée.

Le taux adaptatif

RMSProp ajuste le taux **par paramètre**, en divisant par une moyenne des gradients récents.

Les paramètres à gradients forts avancent prudemment, ceux à gradients faibles plus franchement.

Adam

Adam combine les deux : inertie et taux adaptatif par paramètre.

C'est l'optimiseur par défaut, robuste aux réglages approximatifs. On le lance typiquement avec $\eta = 10^{-3}$

Application en gestion

Commencer par **Adam**. Il fonctionne presque toujours correctement du premier coup.

La descente avec momentum, mieux réglée, atteint parfois une meilleure solution finale sur les grands modèles de vision — c'est une optimisation de dernier ressort, pas un point de départ.

L'ordonnement du taux

Faire décroître le taux

Un taux élevé au début explore ; un taux faible à la fin affine.

Stratégie	Principe
Par paliers	diviser par dix à intervalles fixés
Décroissance cosinus	descente douce et continue
Sur plateau	réduire quand la validation stagne

Ce que le chapitre a établi

Le taux d'apprentissage est le paramètre auquel un réseau est **le plus sensible**.
Architecture, activation et optimiseur comptent moins que lui.

Devant un réseau qui n'apprend pas, c'est la première chose à regarder — et souvent la seule à corriger.

Ce qu'il faut retenir

Cinq points

1. $w \leftarrow w - \eta \partial L / \partial w$: on descend dans le sens opposé au gradient.
2. Sur $L(w) = w^2$: $\eta = 0,1$ converge, $\eta = 1,1$ **diverge** — la condition est $0 < \eta < 1$.
3. Le **mini-batch** de 32 à 256 est le régime standard ; son bruit est utile.
4. **Adam** — momentum et taux adaptatif — est l'optimiseur par défaut, à 10^{-3} .
5. Le **taux d'apprentissage** est le paramètre le plus sensible de tous.

La suite

Il reste à savoir comment le gradient est calculé pour des millions de paramètres.
C'est la rétropropagation, au chapitre 4.