


Apprentissage profond

Chapitre 2 : Le perceptron multicouche



L'architecture

Compter les paramètres

Choisir une architecture

La sortie

Ce qu'il faut retenir

L'architecture

Comment les couches s'enchaînent

Perceptron multicouche

Un **perceptron multicouche** est une suite de couches **entièrement connectées** : chaque neurone d'une couche reçoit toutes les sorties de la précédente.

L'écriture matricielle

Pour la couche ℓ :

$$z^{(\ell)} = W^{(\ell)} a^{(\ell-1)} + b^{(\ell)} \qquad a^{(\ell)} = g(z^{(\ell)})$$

$W^{(\ell)}$ est une matrice, $b^{(\ell)}$ un vecteur, et g s'applique terme à terme.

C'est l'algèbre linéaire du niveau Licence

Le produit matrice-vecteur du chapitre 10 de *Mathématiques pour la gestion* est exactement l'opération élémentaire d'un réseau.

Un réseau profond n'est qu'une **composition** de ces produits, entrecoupée de non-linéarités. Sans elles, la composition de fonctions linéaires resterait linéaire — et toute la profondeur serait perdue.

Compter les paramètres

Un calcul à savoir faire

La formule par couche

Pour une couche de e entrées vers s sorties :

$$\text{paramètres} = \underbrace{e \times s}_{\text{poids}} + \underbrace{s}_{\text{biais}}$$

Un réseau pour notre série financière

Vingt indicateurs en entrée, deux couches cachées, une sortie :

Couche	Calcul	Paramètres
$20 \rightarrow 32$	$20 \times 32 + 32$	672
$32 \rightarrow 16$	$32 \times 16 + 16$	528
$16 \rightarrow 1$	$16 \times 1 + 1$	17
Total		1 217

Choisir une architecture

Profondeur et largeur

Deux leviers

La **largeur** est le nombre de neurones par couche. La **profondeur** est le nombre de couches.

À nombre de paramètres égal, la profondeur permet des représentations plus abstraites; la largeur, davantage de descripteurs au même niveau.

Ce qui se pratique

Pour des données tabulaires, deux à quatre couches suffisent presque toujours. Aller au-delà n'améliore rien et complique l'entraînement.

Les architectures très profondes ne se justifient que pour l'image, le texte et le son, où la hiérarchie des représentations a un sens naturel.

La forme en entonnoir — des couches de plus en plus étroites, comme **32** puis **16** ci-dessus — est un point de départ raisonnable, non une règle.

Une architecture ne se devine pas

Le nombre de couches et leur largeur sont des **hyperparamètres**, au même titre que λ dans ridge ou α dans l'élagage.

La sortie

Adapter la dernière couche à la tâche

Trois cas

Tâche	Neurones de sortie	Activation finale
Régression	1	aucune
Classification binaire	1	sigmoïde
Classification à K classes	K	softmax

La fonction softmax

$$\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$$

Elle transforme des scores quelconques en probabilités : toutes positives, de somme 1.

Trois régimes de marché

Scores en sortie : 2,0; 1,0; 0,1.

Ce qu'il faut retenir

Cinq points

1. Un perceptron multicouche enchaîne $z = Wa + b$ puis $a = g(z)$.
2. Une couche de e vers s coûte $e \times s + s$ paramètres.
3. Notre réseau 20-32-16-1 en compte 1 217 : bien plus qu'une régression, à comparer au nombre d'observations.
4. Deux à quatre couches suffisent sur données tabulaires; l'architecture est un **hyperparamètre**.
5. Sortie **libre** en régression, **sigmoïde** en binaire, **softmax** à K classes.

La suite

L'architecture est posée. Le chapitre 3 examine les deux choix qui la font fonctionner ou échouer : la fonction de perte et les activations.