


Apprentissage profond

Chapitre 3 : Fonctions de perte et d'activation



La fonction de perte

Les activations

Ce qu'il faut retenir

La fonction de perte

Ce que le réseau cherche à minimiser

Les pertes usuelles

Tâche	Perte	Formule
Régression	erreur quadratique	$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$
Régression robuste	erreur absolue	$\frac{1}{n} \sum y_i - \hat{y}_i $
Classification binaire	entropie croisée	$-\frac{1}{n} \sum [y_i \ln \hat{p}_i + (1 - y_i) \ln(1 - \hat{p}_i)]$

L'entropie croisée n'est pas une nouveauté

Minimiser l'entropie croisée revient exactement à **maximiser la vraisemblance** du modèle logistique.

C'est le maximum de vraisemblance du chapitre 8 de *Statistique inférentielle*, sous un autre nom. Le vocabulaire change; le critère est identique.

Pourquoi l'entropie croisée plutôt que l'erreur quadratique

En classification, l'erreur quadratique produit des gradients qui **s'annulent** quand le réseau se trompe avec assurance — précisément quand il faudrait corriger le plus fort.

L'entropie croisée, au contraire, pénalise très lourdement une prédiction confiante et fautive :

Les activations

La sigmoïde et son défaut

La sigmoïde

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

Elle ramène toute valeur dans $]0, 1[$. Sa dérivée vaut $\sigma(z) (1 - \sigma(z))$.

Le problème, chiffré

La dérivée de la sigmoïde est **maximale en $z = 0$** , où elle vaut **0,25**. Elle est plus faible partout ailleurs.

Or la rétropropagation **multiplie** ces dérivées couche après couche :

Couches	Facteur au mieux
1	0,25
5	$9,8 \times 10^{-4}$
10	$9,5 \times 10^{-7}$
20	$9,1 \times 10^{-13}$

ReLU, et pourquoi elle a tout changé

ReLU

$$\text{ReLU}(z) = \max(0, z)$$

Sa dérivée vaut 1 pour $z > 0$ et 0 sinon.

La dérivée de 1 est décisive

Multiplier des 1 ne diminue rien. Le gradient traverse donc les couches sans s'atténuer, et l'entraînement de réseaux profonds devient possible.

À cela s'ajoutent deux avantages : le calcul est trivial, et la **parcimonie** — les neurones à sortie nulle ne participent pas, ce qui allège le réseau.

Le passage de la sigmoïde à ReLU est l'une des raisons principales du succès de l'apprentissage **profond**, davantage qu'une astuce d'implémentation.

Son défaut, et ses variantes

Un neurone dont l'entrée reste négative a un gradient nul en permanence : il est **mort**, définitivement.

Ce qu'il faut retenir

Cinq points

1. La **perte** encode l'objectif : quadratique, absolue, ou entropie croisée.
2. L'**entropie croisée** est le maximum de vraisemblance logistique, sous un autre nom.
3. La dérivée de la sigmoïde plafonne à **0,25** : après dix couches, le gradient est divisé par un million.
4. **ReLU** a une dérivée de **1** : le gradient traverse sans s'atténuer.
5. ReLU dans les couches cachées; sigmoïde ou softmax **uniquement en sortie**.

La suite

Perte et activations sont choisies. Le chapitre 4 aborde l'algorithme qui minimise effectivement cette perte.