

Chapitre 7

Les arbres de décision

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre


Correction — Exercice 1

- (a) $\text{Gini}(0,30) = 1 - (0,30^2 + 0,70^2) = 1 - (0,09 + 0,49) = \mathbf{0,42}$.
(b) $\text{Gini}(0,08) = 1 - (0,08^2 + 0,92^2) = 1 - (0,0064 + 0,8464) = \mathbf{0,1472}$.
(c) Le Gini est maximal pour $p = \mathbf{0,50}$ (classes parfaitement équilibrées), où $\text{Gini} = 1 - (0,5^2 + 0,5^2) = \mathbf{0,50}$.




Correction — Exercice 2

- (a) $\text{Gini}_{\text{parent}} = 1 - (0,30^2 + 0,70^2) = \mathbf{0,42}$.
(b) $\text{Gini}_{\text{gauche}} = 1 - (0,10^2 + 0,90^2) = 0,18$. $\text{Gini}_{\text{droite}} = 1 - (0,60^2 + 0,40^2) = 0,48$. Gini pondéré = $(120 \times 0,18 + 80 \times 0,48) / 200 = (21,6 + 38,4) / 200 = 60 / 200 = \mathbf{0,30}$.
(c) Réduction = $0,42 - 0,30 = \mathbf{0,12}$. Oui : $0,12 > 0,08$, donc ce premier découpage réduit davantage l'impureté que le second candidat – l'algorithme glouton, qui retient toujours le découpage produisant la plus forte réduction *immédiate*, confirmerait bien ce choix.



Correction — Exercice 3


- (a) 20 feuilles : $0,05 + 0,02 \times 20 = 0,05 + 0,40 = \mathbf{0,45}$. 10 feuilles : $0,08 + 0,02 \times 10 = 0,08 + 0,20 = \mathbf{0,28}$. 5 feuilles : $0,13 + 0,02 \times 5 = 0,13 + 0,10 = \mathbf{0,23}$.
(b) Le critère sélectionne l'arbre à 5 feuilles, qui minimise le critère coût-complexité (0,23).
(c) Oui : avec $\alpha = 0,001$, la pénalité par feuille devient bien plus faible ($0,001 \times 20 = 0,02$ contre $0,001 \times 5 = 0,005$, un écart de seulement 0,015), alors que l'écart d'erreur entre les arbres ($0,13 - 0,05 = 0,08$) reste inchangé. Le critère devient alors dominé par le terme d'erreur plutôt que par le nombre de feuilles, ce qui favorise l'arbre le plus grand (20 feuilles, erreur la plus faible) – exactement comme un λ trop faible au chapitre 3 laissait le modèle non régularisé prendre le dessus.



2 Exercices cumulatifs (chapitre 7 et introduction)

Correction — Exercice 4


- (a) $\text{Gini}_{62\%} = 1 - (0,62^2 + 0,38^2) = 1 - (0,3844 + 0,1444) = \mathbf{0,4712}$. $\text{Gini}_{18\%} = 1 - (0,18^2 + 0,82^2) = 1 - (0,0324 + 0,6724) = \mathbf{0,2952}$.
- (b) Taux de défaut du parent $= (80 \times 0,62 + 220 \times 0,18) / 300 = (49,6 + 39,6) / 300 = 89,2 / 300 \approx \mathbf{0,2973}$.
Gini du parent $= 1 - (0,2973^2 + 0,7027^2) \approx \mathbf{0,4179}$.
- (c) Gini pondéré des deux feuilles $= (80 \times 0,4712 + 220 \times 0,2952) / 300 \approx \mathbf{0,3421}$. Réduction d'impureté $= 0,4179 - 0,3421 \approx \mathbf{0,0757}$. Ce nœud parent (« Endettement $> 0,45$ », Gini $\approx 0,418$) est nettement **moins pur** que la racine de l'arbre sur l'ensemble du portefeuille (Gini = 0,180) : c'est parfaitement cohérent, puisque ce nœud ne contient que les dossiers déjà filtrés par un fort endettement, une sous-population bien plus risquée (taux de défaut $\approx 29,7\%$) que le portefeuille entier (10 %). On y retrouve, à cette échelle réduite, exactement la logique du chapitre 1 : un arbre poussé jusqu'à la pureté totale sur ces 300 dossiers atteindrait une erreur d'apprentissage nulle, mais ce serait le sur-ajustement le plus pur – d'où la nécessité de l'élagage par validation croisée.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) $\text{Gini}_{\text{parent}} = 1 - (0,40^2 + 0,60^2) = 1 - (0,16 + 0,36) = \mathbf{0,48}$.
- (b) $\text{Gini}_{\text{avec activité}} = 1 - (0,15^2 + 0,85^2) = \mathbf{0,2550}$. $\text{Gini}_{\text{sans activité}} = 1 - (0,75^2 + 0,25^2) = \mathbf{0,3750}$. Gini pondéré $= (90 \times 0,2550 + 60 \times 0,3750) / 150 = (22,95 + 22,5) / 150 \approx \mathbf{0,3030}$.
- (c) Oui, ce découpage réduit fortement l'impureté (0,48 $\rightarrow$ 0,303, soit une réduction de 0,177). Un chargé de crédit préférerait un arbre à une régression logistique pour **expliquer** sa décision, car le premier se lit directement comme une règle (« pas d'activité secondaire $\Rightarrow$ risque de défaut de 75 % »), sans nécessiter de convertir un coefficient en facteur multiplicatif sur une cote (chapitre 5) : c'est précisément l'avantage d'interprétabilité mis en avant dans le chapitre, décisif face à un client refusé ou à un régulateur qui exige une justification lisible.



Correction — Exercice 6

(a) Arbre complet (500 feuilles, erreur 0) : $0 + 0,005 \times 500 = 2,5$. 200 feuilles : $0,04 + 0,005 \times 200 = 0,04 + 1,0 = 1,04$. 50 feuilles : $0,09 + 0,005 \times 50 = 0,09 + 0,25 = 0,34$. 15 feuilles : $0,15 + 0,005 \times 15 = 0,15 + 0,075 = 0,225$.

(b) Le critère sélectionne l'arbre à 15 feuilles (0,225, le plus faible des quatre).

(c) Non : malgré son erreur d'apprentissage nulle, l'arbre complet obtient de très loin le pire critère (2,5), précisément parce qu'une feuille par observation (ou presque) mémorise le bruit de l'échantillon d'apprentissage sans rien généraliser – c'est le sur-ajustement du chapitre 1 « dans sa forme la plus pure », comme le rappelle le chapitre. L'élagage par coût-complexité, avec α choisi par validation croisée, existe précisément pour éviter de déployer un tel arbre en production.