

Apprentissage statistique

Chapitre 7 : Les arbres de décision

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer l'indice de Gini pour différentes compositions

On utilise $Gini = 1 - \sum_k p_k^2$ pour un nœud à deux classes.

- (a) Calculer le Gini d'un nœud contenant 30 % de défauts.
- (b) Calculer le Gini d'un nœud contenant 8 % de défauts.
- (c) Pour quelle proportion de défauts le Gini est-il maximal, et quelle est alors sa valeur ?

Exercice 2 — Évaluer la réduction d'impureté d'un découpage

Un nœud parent de 200 dossiers contient 30 % de défauts. Un découpage le sépare en une branche gauche de 120 dossiers (10 % de défauts) et une branche droite de 80 dossiers (60 % de défauts).

- (a) Calculer le Gini du nœud parent.
- (b) Calculer le Gini pondéré après découpage (moyenne des Gini des deux branches, pondérée par leurs effectifs).
- (c) Calculer la réduction d'impureté obtenue par ce découpage. Un second découpage candidat, non retenu, aurait produit une réduction de 0,08 : l'algorithme glouton du chapitre confirme-t-il le choix du premier découpage ?

Exercice 3 — Choisir un arbre élagué par le critère coût-complexité

Trois arbres candidats, obtenus par élagage successif d'un même arbre complet, ont les caractéristiques suivantes : 20 feuilles avec une erreur de 0,05 ; 10 feuilles avec une erreur de 0,08 ; 5 feuilles avec une erreur de 0,13. On utilise le critère erreur + $\alpha \times$ nombre de feuilles, avec $\alpha = 0,02$.

- (a) Calculer le critère coût-complexité pour chacun des trois arbres.
- (b) Quel arbre le critère sélectionne-t-il ?
- (c) Si α était beaucoup plus petit (par exemple 0,001), un arbre plus grand serait-il davantage favorisé ? Justifier à partir de la formule du critère.

2 Exercices cumulatifs (chapitre 7 et introduction)

Exercice 4 — Vérifier la réduction d'impureté sur la branche « Endettement > 0,45 » du cours (introduction)

On reprend l'arbre officiel du chapitre sur le portefeuille de **mille dossiers de crédit** de l'introduction. La branche « Endettement > 0,45 » regroupe 300 dossiers, qui se répartissent en 80 dossiers « Ancienneté < 2 ans » (risque de défaut 62 %, valeur du chapitre) et 220 dossiers « Ancienneté $\geq$ 2 ans » (risque de défaut 18 %, valeur du chapitre).

- (a) Calculer le Gini de chacune des deux feuilles, à partir des risques de 62 % et 18 % donnés par le chapitre.
- (b) Calculer le taux de défaut du nœud parent « Endettement > 0,45 » (moyenne pondérée des deux feuilles), puis son Gini.
- (c) Calculer la réduction d'impureté obtenue par ce découpage. Ce nœud parent est-il plus ou moins pur que la racine de l'arbre sur l'ensemble du portefeuille (Gini = 0,180, chapitre) ? Cette différence est-elle cohérente avec le fait que ce nœud ne rassemble que les dossiers déjà filtrés par un fort endettement ?

3 Applications en sciences économiques

Exercice 5 — Construire un arbre de décision pour l'octroi de microcrédit

Une institution de microfinance étudie un nœud de 150 dossiers, contenant 40 % de défauts. Un découpage sur la variable «possède une activité secondaire» sépare ce nœud en 90 dossiers avec activité secondaire (15 % de défauts) et 60 dossiers sans activité secondaire (75 % de défauts).

- (a) Calculer le Gini du nœud parent.
- (b) Calculer le Gini pondéré après découpage.
- (c) Ce découpage réduit-il l'impureté? Pourquoi un chargé de crédit préférerait-il, à qualité de prévision égale, ce type de modèle à une régression logistique pour expliquer sa décision à un client refusé?

Exercice 6 — Élaguer un arbre de scoring pour limiter le sur-ajustement


Une fintech a fait pousser un arbre complet pour son modèle de scoring, avec une erreur d'apprentissage nulle et 500 feuilles. Trois versions élaguées sont comparées avec $\alpha = 0,005$: 200 feuilles (erreur 0,04), 50 feuilles (erreur 0,09), 15 feuilles (erreur 0,15).

- (a) Calculer le critère coût-complexité pour l'arbre complet (500 feuilles, erreur 0), puis pour les trois versions élaguées.
- (b) Quel arbre le critère sélectionne-t-il?
- (c) L'arbre complet, à erreur d'apprentissage nulle, aurait-il été un bon choix en production? Relier la réponse au sur-ajustement décrit dans le chapitre.

1 Exercices du chapitre


Correction — Exercice 1

- (a) $\text{Gini}(0,30) = 1 - (0,30^2 + 0,70^2) = 1 - (0,09 + 0,49) = \mathbf{0,42}$.
(b) $\text{Gini}(0,08) = 1 - (0,08^2 + 0,92^2) = 1 - (0,0064 + 0,8464) = \mathbf{0,1472}$.
(c) Le Gini est maximal pour $p = \mathbf{0,50}$ (classes parfaitement équilibrées), où $\text{Gini} = 1 - (0,5^2 + 0,5^2) = \mathbf{0,50}$.




Correction — Exercice 2

- (a) $\text{Gini}_{\text{parent}} = 1 - (0,30^2 + 0,70^2) = \mathbf{0,42}$.
(b) $\text{Gini}_{\text{gauche}} = 1 - (0,10^2 + 0,90^2) = 0,18$. $\text{Gini}_{\text{droite}} = 1 - (0,60^2 + 0,40^2) = 0,48$. Gini pondéré = $(120 \times 0,18 + 80 \times 0,48) / 200 = (21,6 + 38,4) / 200 = 60 / 200 = \mathbf{0,30}$.
(c) Réduction = $0,42 - 0,30 = \mathbf{0,12}$. Oui : $0,12 > 0,08$, donc ce premier découpage réduit davantage l'impureté que le second candidat – l'algorithme glouton, qui retient toujours le découpage produisant la plus forte réduction *immédiate*, confirmerait bien ce choix.



Correction — Exercice 3

- (a) 20 feuilles : $0,05 + 0,02 \times 20 = 0,05 + 0,40 = \mathbf{0,45}$. 10 feuilles : $0,08 + 0,02 \times 10 = 0,08 + 0,20 = \mathbf{0,28}$. 5 feuilles : $0,13 + 0,02 \times 5 = 0,13 + 0,10 = \mathbf{0,23}$.
(b) Le critère sélectionne l'arbre à 5 feuilles, qui minimise le critère coût-complexité (0,23).
(c) Oui : avec $\alpha = 0,001$, la pénalité par feuille devient bien plus faible ($0,001 \times 20 = 0,02$ contre $0,001 \times 5 = 0,005$, un écart de seulement 0,015), alors que l'écart d'erreur entre les arbres ($0,13 - 0,05 = 0,08$) reste inchangé. Le critère devient alors dominé par le terme d'erreur plutôt que par le nombre de feuilles, ce qui favorise l'arbre le plus grand (20 feuilles, erreur la plus faible) – exactement comme un λ trop faible au chapitre 3 laissait le modèle non régularisé prendre le dessus.




2 Exercices cumulatifs (chapitre 7 et introduction)

Correction — Exercice 4

(a) $\text{Gini}_{62\%} = 1 - (0,62^2 + 0,38^2) = 1 - (0,3844 + 0,1444) = \mathbf{0,4712}$. $\text{Gini}_{18\%} = 1 - (0,18^2 + 0,82^2) = 1 - (0,0324 + 0,6724) = \mathbf{0,2952}$.

(b) Taux de défaut du parent = $(80 \times 0,62 + 220 \times 0,18) / 300 = (49,6 + 39,6) / 300 = 89,2 / 300 \approx \mathbf{0,2973}$.
Gini du parent = $1 - (0,2973^2 + 0,7027^2) \approx \mathbf{0,4179}$.

(c) Gini pondéré des deux feuilles = $(80 \times 0,4712 + 220 \times 0,2952) / 300 \approx \mathbf{0,3421}$. Réduction d'impureté = $0,4179 - 0,3421 \approx \mathbf{0,0757}$. Ce nœud parent (« Endettement > 0,45 », Gini $\approx 0,418$) est nettement **moins pur** que la racine de l'arbre sur l'ensemble du portefeuille (Gini = 0,180) : c'est parfaitement cohérent, puisque ce nœud ne contient que les dossiers déjà filtrés par un fort endettement, une sous-population bien plus risquée (taux de défaut $\approx 29,7\%$) que le portefeuille entier (10 %). On y retrouve, à cette échelle réduite, exactement la logique du chapitre 1 : un arbre poussé jusqu'à la pureté totale sur ces 300 dossiers atteindrait une erreur d'apprentissage nulle, mais ce serait le sur-ajustement le plus pur – d'où la nécessité de l'élagage par validation croisée.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $\text{Gini}_{\text{parent}} = 1 - (0,40^2 + 0,60^2) = 1 - (0,16 + 0,36) = \mathbf{0,48}$.

(b) $\text{Gini}_{\text{avec activité}} = 1 - (0,15^2 + 0,85^2) = \mathbf{0,2550}$. $\text{Gini}_{\text{sans activité}} = 1 - (0,75^2 + 0,25^2) = \mathbf{0,3750}$. Gini pondéré = $(90 \times 0,2550 + 60 \times 0,3750) / 150 = (22,95 + 22,5) / 150 \approx \mathbf{0,3030}$.

(c) Oui, ce découpage réduit fortement l'impureté ($0,48 \rightarrow 0,303$, soit une réduction de 0,177). Un chargé de crédit préférerait un arbre à une régression logistique pour **expliquer** sa décision, car le premier se lit directement comme une règle (« pas d'activité secondaire $\Rightarrow$ risque de défaut de 75 % »), sans nécessiter de convertir un coefficient en facteur multiplicatif sur une cote (chapitre 5) : c'est précisément l'avantage d'interprétabilité mis en avant dans le chapitre, décisif face à un client refusé ou à un régulateur qui exige une justification lisible.



Correction — Exercice 6

(a) Arbre complet (500 feuilles, erreur 0) : $0 + 0,005 \times 500 = 2,5$. 200 feuilles : $0,04 + 0,005 \times 200 = 0,04 + 1,0 = 1,04$. 50 feuilles : $0,09 + 0,005 \times 50 = 0,09 + 0,25 = 0,34$. 15 feuilles : $0,15 + 0,005 \times 15 = 0,15 + 0,075 = 0,225$.

(b) Le critère sélectionne l'arbre à 15 feuilles (0,225, le plus faible des quatre).

(c) Non : malgré son erreur d'apprentissage nulle, l'arbre complet obtient de très loin le pire critère (2,5), précisément parce qu'une feuille par observation (ou presque) mémorise le bruit de l'échantillon d'apprentissage sans rien généraliser – c'est le sur-ajustement du chapitre 1 « dans sa forme la plus pure », comme le rappelle le chapitre. L'élagage par coût-complexité, avec α choisi par validation croisée, existe précisément pour éviter de déployer un tel arbre en production.