

Chapitre 7

Les arbres de décision

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Calculer l'indice de Gini pour différentes compositions

On utilise $Gini = 1 - \sum_k p_k^2$ pour un nœud à deux classes.

- (a) Calculer le Gini d'un nœud contenant 30 % de défauts.
- (b) Calculer le Gini d'un nœud contenant 8 % de défauts.
- (c) Pour quelle proportion de défauts le Gini est-il maximal, et quelle est alors sa valeur ?

Exercice 2 — Évaluer la réduction d'impureté d'un découpage

Un nœud parent de 200 dossiers contient 30 % de défauts. Un découpage le sépare en une branche gauche de 120 dossiers (10 % de défauts) et une branche droite de 80 dossiers (60 % de défauts).

- (a) Calculer le Gini du nœud parent.
- (b) Calculer le Gini pondéré après découpage (moyenne des Gini des deux branches, pondérée par leurs effectifs).
- (c) Calculer la réduction d'impureté obtenue par ce découpage. Un second découpage candidat, non retenu, aurait produit une réduction de 0,08 : l'algorithme glouton du chapitre confirme-t-il le choix du premier découpage ?

Exercice 3 — Choisir un arbre élagué par le critère coût-complexité

Trois arbres candidats, obtenus par élagage successif d'un même arbre complet, ont les caractéristiques suivantes : 20 feuilles avec une erreur de 0,05 ; 10 feuilles avec une erreur de 0,08 ; 5 feuilles avec une erreur de 0,13. On utilise le critère $\text{erreur} + \alpha \times \text{nombre de feuilles}$, avec $\alpha = 0,02$.

- (a) Calculer le critère coût-complexité pour chacun des trois arbres.
- (b) Quel arbre le critère sélectionne-t-il ?
- (c) Si α était beaucoup plus petit (par exemple 0,001), un arbre plus grand serait-il davantage favorisé ? Justifier à partir de la formule du critère.

2 Exercices cumulatifs (chapitre 7 et introduction)

Exercice 4 — Vérifier la réduction d'impureté sur la branche « Endettement > 0,45 » du cours (introduction)

On reprend l'arbre officiel du chapitre sur le portefeuille de **mille dossiers de crédit** de l'introduction. La branche « Endettement > 0,45 » regroupe 300 dossiers, qui se répartissent en 80 dossiers « Ancienneté < 2 ans » (risque de défaut 62 %, valeur du chapitre) et 220 dossiers « Ancienneté $\geq$ 2 ans » (risque de défaut 18 %, valeur du chapitre).

- (a) Calculer le Gini de chacune des deux feuilles, à partir des risques de 62 % et 18 % donnés par le chapitre.
- (b) Calculer le taux de défaut du nœud parent « Endettement > 0,45 » (moyenne pondérée des deux feuilles), puis son Gini.
- (c) Calculer la réduction d'impureté obtenue par ce découpage. Ce nœud parent est-il plus ou moins pur que la racine de l'arbre sur l'ensemble du portefeuille (Gini = 0,180, chapitre) ? Cette différence est-elle cohérente avec le fait que ce nœud ne rassemble que les dossiers déjà filtrés par un fort endettement ?

3 Applications en sciences économiques

Exercice 5 — Construire un arbre de décision pour l'octroi de microcrédit

Une institution de microfinance étudie un nœud de 150 dossiers, contenant 40 % de défauts. Un découpage sur la variable «possède une activité secondaire» sépare ce nœud en 90 dossiers avec activité secondaire (15 % de défauts) et 60 dossiers sans activité secondaire (75 % de défauts).

- (a) Calculer le Gini du nœud parent.
- (b) Calculer le Gini pondéré après découpage.
- (c) Ce découpage réduit-il l'impureté? Pourquoi un chargé de crédit préférerait-il, à qualité de prévision égale, ce type de modèle à une régression logistique pour expliquer sa décision à un client refusé?

Exercice 6 — Élaguer un arbre de scoring pour limiter le sur-ajustement

Une fintech a fait pousser un arbre complet pour son modèle de scoring, avec une erreur d'apprentissage nulle et 500 feuilles. Trois versions élaguées sont comparées avec $\alpha = 0,005$: 200 feuilles (erreur 0,04), 50 feuilles (erreur 0,09), 15 feuilles (erreur 0,15).

- (a) Calculer le critère coût-complexité pour l'arbre complet (500 feuilles, erreur 0), puis pour les trois versions élaguées.
- (b) Quel arbre le critère sélectionne-t-il?
- (c) L'arbre complet, à erreur d'apprentissage nulle, aurait-il été un bon choix en production? Relier la réponse au sur-ajustement décrit dans le chapitre.