

Apprentissage statistique

Chapitre 1 : Le compromis biais-variance

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Comparer deux modèles par leur EQM décomposée

Un premier modèle affiche un biais² de 2,5, une variance de 1,5 et un bruit irréductible de 0,8. Un second modèle, plus flexible, affiche un biais² de 0,5, une variance de 4,0 et le même bruit irréductible de 0,8.

- (a) Calculer l'EQM de chacun des deux modèles.
- (b) Lequel des deux modèles faut-il préférer au sens de l'erreur quadratique moyenne ?
- (c) Le second modèle a pourtant un biais bien plus faible que le premier. Pourquoi cela ne suffit-il pas à le rendre préférable ?

Exercice 2 — Trouver la complexité optimale dans un nouveau tableau

Un analyste teste cinq niveaux de complexité pour un modèle, avec un bruit irréductible constant de 1,2 :

Complexité	Biais ²	Variance
2	6,0	0,4
4	3,0	0,9
6	1,5	1,8
8	0,8	3,5
12	0,3	7,0

- (a) Calculer l'EQM pour chacun des cinq niveaux de complexité.
- (b) Quelle complexité minimise l'EQM ?
- (c) Comment évolue le biais et comment évolue la variance à mesure que la complexité augmente ? Ce constat est-il cohérent avec le cours ?

Exercice 3 — Chiffrer la malédiction de la dimension

Pour couvrir une fraction p du volume d'un cube unité de dimension d autour d'un point, le côté nécessaire vaut $p^{1/d}$. On prend $p = 0,05$ (soit 5 % du volume).

- (a) Calculer le côté nécessaire pour $d = 1$.
- (b) Calculer le côté nécessaire pour $d = 3$, puis pour $d = 8$.
- (c) Un côté proche de 0,69 (comme en dimension 8) signifie-t-il encore un « voisinage local » au sens usuel du terme ? Commenter.

2 Exercices cumulatifs (chapitre 1 et introduction)

Exercice 4 — De l'erreur irréductible au diagnostic de sur-ajustement (introduction)

On reprend le portefeuille de l'introduction : **mille dossiers de crédit, dont cent défauts**. Les experts du risque estiment que le taux d'erreur irréductible de ce marché, dû à des défauts intrinsèquement imprévisibles, est de 4 %. Un premier modèle, très simple, atteint un taux d'erreur de test de 15 %. Un second modèle, plus flexible, atteint un taux d'erreur de test de 9 %, mais un taux d'erreur d'apprentissage de seulement 2 %.

- (a) Calculer la part réductible de l'erreur du modèle simple.
- (b) Calculer l'écart entre erreur de test et erreur d'apprentissage du second modèle. En reprenant la logique de diagnostic de l'exercice 3 de l'introduction, ce second modèle est-il plutôt en sur-ajustement ou en sous-ajustement ?

- (c) Avec ces seules informations, peut-on affirmer que le second modèle serait nécessairement préférable en production, malgré le signal de sur-ajustement identifié en (b) ? Justifier.

3 Applications en sciences économiques

Exercice 5 — Choisir la complexité d'un modèle de prévision de rendement

Un gérant d'actifs compare deux modèles de prévision du rendement mensuel d'un fonds sur 60 mois d'historique : un modèle simple à 3 variables macroéconomiques, et un modèle complexe à 25 variables avec interactions. Le modèle simple affiche une EQM de 0,70 en estimation et 0,85 hors échantillon. Le modèle complexe affiche une EQM de 0,10 en estimation et 1,42 hors échantillon.

- (a) Calculer l'écart entre EQM hors échantillon et EQM d'estimation pour chacun des deux modèles.
- (b) Lequel des deux modèles souffre du sur-ajustement le plus marqué ?
- (c) Le gérant ne dispose que de 60 observations mensuelles pour estimer les 25 variables du modèle complexe. Relier ce constat au levier « nombre de variables » et à la malédiction de la dimension évoqués dans le chapitre.

Exercice 6 — L'optimum se déplace avec la taille de l'échantillon


Une fintech de scoring de PME hésite entre un modèle linéaire à 6 variables ($\text{biais}^2 = 5,0$, $\text{variance} = 0,8$) et un modèle non linéaire à 60 variables ($\text{biais}^2 = 0,6$, $\text{variance} = 6,1$), avec un bruit irréductible commun de 1,5, sur un portefeuille de 400 PME.

- (a) Calculer l'EQM de chacun des deux modèles sur ce portefeuille de 400 PME.
- (b) Lequel des deux modèles la fintech doit-elle choisir à ce stade ?
- (c) La fintech multiplie son portefeuille par 10 (soit 4 000 PME), ce qui divise par 10 la variance du modèle non linéaire (le biais^2 et le bruit restant inchangés). Recalculer l'EQM du modèle non linéaire dans ce nouveau contexte, et indiquer si le classement des deux modèles s'en trouve modifié.

1 Exercices du chapitre


Correction — Exercice 1

- (a) Modèle 1 : $EQM_1 = 2,5 + 1,5 + 0,8 = 4,8$. Modèle 2 : $EQM_2 = 0,5 + 4,0 + 0,8 = 5,3$.
 (b) Le modèle 1 est préférable : son EQM (4,8) est inférieure à celle du modèle 2 (5,3).
 (c) Parce que l'EQM ne juge jamais le biais seul : le second modèle réduit fortement son biais² (0,5 contre 2,5) mais au prix d'une variance bien plus élevée (4,0 contre 1,5), et l'augmentation de variance (+2,5) dépasse la réduction de biais (−2,0). C'est la somme des deux qui compte, pas chaque terme isolément.




Correction — Exercice 2

- (a) $EQM(2) = 6,0 + 0,4 + 1,2 = 7,6$; $EQM(4) = 3,0 + 0,9 + 1,2 = 5,1$; $EQM(6) = 1,5 + 1,8 + 1,2 = 4,5$; $EQM(8) = 0,8 + 3,5 + 1,2 = 5,5$; $EQM(12) = 0,3 + 7,0 + 1,2 = 8,5$.
 (b) La complexité 6 minimise l'EQM, avec une valeur de 4,5.
 (c) Le biais² décroît sans cesse (6,0 → 0,3) tandis que la variance croît sans cesse (0,4 → 7,0) à mesure que la complexité augmente. C'est exactement le mécanisme du cours : les deux termes évoluent en sens opposé, et leur somme passe par un minimum intérieur – ici en complexité 6 – plutôt que de décroître ou croître de façon monotone.



Correction — Exercice 3

- (a) $d = 1$: côté = $0,05^{1/1} = 0,0500$.
 (b) $d = 3$: côté = $0,05^{1/3} \approx 0,3684$. $d = 8$: côté = $0,05^{1/8} \approx 0,6877$.
 (c) Non : un côté de 0,69 couvre déjà près des **deux tiers** de l'étendue de chaque variable. Ce n'est plus un « voisinage » au sens intuitif – c'est presque tout l'espace. C'est exactement la malédiction de la dimension : en dimension 8, il n'existe quasiment plus de région qui soit à la fois petite en volume et locale sur chaque variable prise séparément.




2 Exercices cumulatifs (chapitre 1 et introduction)

Correction — Exercice 4

(a) Part réductible = 15 % – 4 % = **11 points**.

(b) Écart test – apprentissage = 9 % – 2 % = **7 points**. En reprenant le critère de l'exercice 3 de l'introduction (c'est l'écart entre les deux erreurs qui diagnostique, pas leur niveau), une erreur d'apprentissage très faible (2 %) combinée à un écart significatif (7 points) signale bien un **sur-ajustement** – le modèle a probablement capté une partie du bruit propre à l'échantillon d'apprentissage.

(c) Non, pas nécessairement : malgré le signal de sur-ajustement, le second modèle reste le meilleur au sens de l'erreur de **test** (9 % < 15 %), qui est le seul critère pertinent pour juger de la performance en production – l'introduction insiste précisément sur le fait qu'on n'évalue jamais sur l'erreur d'apprentissage. Le signal de sur-ajustement invite en revanche à **surveiller** ce second modèle et, si possible, à le régulariser encore pour tenter de réduire l'écart sans perdre sa performance de test.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Modèle simple : $0,85 - 0,70 = \mathbf{0,15}$. Modèle complexe : $1,42 - 0,10 = \mathbf{1,32}$.

(b) Le modèle **complexe** souffre d'un sur-ajustement bien plus marqué : son écart (1,32) est presque neuf fois supérieur à celui du modèle simple (0,15), avec une EQM d'estimation presque nulle (0,10) mais une EQM hors échantillon qui explose (1,42).

(c) Avec 25 variables (et davantage d'interactions) estimées sur seulement 60 observations mensuelles, le rapport observations/paramètres est extrêmement défavorable – c'est exactement le levier « nombre de variables » du chapitre : chaque variable ajoutée augmente la flexibilité, donc la variance, et en grande dimension relative à n ce terme devient dominant. C'est la malédiction de la dimension qui frappe ici directement la qualité de la prévision hors échantillon.



Correction — Exercice 6

- (a) Modèle linéaire : $EQM = 5,0 + 0,8 + 1,5 = 7,3$. Modèle non linéaire : $EQM = 0,6 + 6,1 + 1,5 = 8,2$.
- (b) À $n = 400$, la fintech doit choisir le modèle **linéaire** : son EQM (7,3) est inférieure à celle du modèle non linéaire (8,2), malgré un biais bien plus élevé.
- (c) Nouvelle variance du modèle non linéaire = $6,1/10 = 0,61$, d'où $EQM = 0,6 + 0,61 + 1,5 = 2,71$. Le classement **s'inverse** : le modèle non linéaire (2,71) devient nettement préférable au modèle linéaire, dont l'EQM reste inchangée à 7,3 (son biais ne dépend pas de la taille de l'échantillon). C'est exactement le mécanisme du levier « taille de l'échantillon » du chapitre : plus n est grand, plus la variance diminue à complexité donnée, et l'optimum se déplace vers plus de complexité.

