

Apprentissage statistique

Chapitre 9 : Le boosting de gradient

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Le lien entre taux d'apprentissage et nombre d'arbres

Une configuration initiale de boosting utilise $\eta_0 = 0,1$ et $B_0 = 200$ arbres. On admet que le produit $\eta \times B$ doit rester approximativement constant pour « parcourir la même distance ».

- (a) Si l'on divise η par 5 (soit $\eta_1 = 0,02$), quel nombre d'arbres B_1 faut-il pour conserver le même produit $\eta \times B$?
- (b) Le budget de calcul plafonne à $B = 4\,000$ arbres. Quel serait alors le η correspondant, pour conserver ce même produit ?
- (c) Pourquoi un η faible associé à un B élevé donne-t-il en général de meilleurs résultats qu'un η élevé avec un B faible, au prix d'un temps de calcul plus long ?

Exercice 2 — Repérer le point d'arrêt précoce

Un boosting est évalué sur un ensemble de validation à différentes étapes : à $B = 100$ arbres, erreur 0,22 ; à $B = 300$, erreur 0,15 ; à $B = 500$, erreur 0,11 ; à $B = 700$, erreur 0,13 ; à $B = 900$, erreur 0,19.

- (a) À quel nombre d'arbres l'erreur de validation est-elle minimale ? C'est le point d'arrêt précoce recommandé.
- (b) Que se passe-t-il entre $B = 500$ et $B = 900$? Comment nomme-t-on ce phénomène ?
- (c) Une forêt aléatoire évaluée aux mêmes valeurs de B afficherait-elle la même remontée de l'erreur au-delà de 500 arbres ? Justifier par la différence de mécanisme entre les deux méthodes.

Exercice 3 — Calculer le sous-échantillonnage des lignes et des colonnes

Un modèle de boosting de gradient (type XGBoost) est entraîné sur $n = 2\,000$ observations et $p = 40$ variables, avec un sous-échantillonnage de 70 % des lignes et 60 % des colonnes à chaque arbre.

- (a) Calculer le nombre de lignes considérées pour la construction de chaque arbre.
- (b) Calculer le nombre de colonnes (variables) considérées pour la construction de chaque arbre.
- (c) En quoi ce sous-échantillonnage des lignes et des colonnes reprend-il, respectivement, les mécanismes du bootstrap et du tirage de m variables du chapitre 8 ?

2 Exercices cumulatifs (chapitre 9, chapitre 8 et chapitre 1)

Exercice 4 — Comparer arbre, forêt et boosting sur l'échelle biais-variance du chapitre 1 (chapitre 8)

On reprend le tableau officiel du chapitre 1 (biais², variance et EQM selon la complexité, bruit = 1 dans chaque cas), dont le minimum était une EQM de 4,0 à la complexité 5. Une forêt aléatoire (chapitre 8, $B = 300$, $m \approx 4$) atteint sur ce même portefeuille un biais² de 0,4 et une variance de 1,8. Un boosting de gradient, avec arrêt précoce à $B = 600$ arbres courts, atteint un biais² de 0,3 et une variance de 1,0.

- (a) Calculer l'EQM de la forêt aléatoire.
- (b) Calculer l'EQM du boosting.
- (c) Classer les trois approches – meilleur modèle du tableau du chapitre 1, forêt aléatoire, boosting – par EQM croissante. Ce classement est-il cohérent avec l'idée que le cours « échange systématiquement de la lisibilité contre de la précision » ?

3 Applications en sciences économiques

Exercice 5 — L'arbitrage réglementaire entre performance et explicabilité

Une banque compare un modèle de boosting de gradient ($AUC = 0,93$) à une régression logistique ($AUC = 0,85$) pour son scoring de crédit.

- (a) Calculer l'écart d'AUC entre les deux modèles.
- (b) Malgré cet écart substantiel en faveur du boosting, pourquoi la banque pourrait-elle être contrainte, par la réglementation, d'utiliser la régression logistique pour motiver un refus de crédit auprès d'un client ?
- (c) Le chapitre annonce qu'une partie de la lisibilité perdue peut être « récupérée » sans revenir à un modèle simple. Pourquoi cette piste intéresse-t-elle particulièrement un secteur, comme le crédit, où l'explicabilité est une contrainte réglementaire et non un simple confort ?

Exercice 6 — Arbitrer entre performance et budget de calcul


Un assureur teste trois configurations de boosting pour détecter la fraude aux sinistres, sous un budget de calcul de 120 minutes : ($\eta = 0,1$; $B = 200$), temps 15 min, AUC 0,870 ; ($\eta = 0,05$; $B = 500$), temps 38 min, AUC 0,891 ; ($\eta = 0,01$; $B = 3\,000$), temps 210 min, AUC 0,905.

- (a) Quelles configurations respectent le budget de 120 minutes ?
- (b) Parmi les configurations respectant ce budget, laquelle maximise l'AUC ?
- (c) Calculer le gain d'AUC apporté par la configuration la plus lente par rapport à celle retenue en (b). Ce gain justifie-t-il, à votre avis, de dépasser le budget de calcul de près de 90 minutes ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) Produit initial = $0,1 \times 200 = 20$. Avec $\eta_1 = 0,02$: $B_1 = 20/0,02 = 1\,000$ arbres.
- (b) Avec $B = 4\,000$: $\eta = 20/4\,000 = 0,005$.
- (c) Un η faible signifie que chaque arbre n'ajoute qu'une correction **modeste** au modèle : la trajectoire de descente est plus prudente et suit de plus près la véritable direction de réduction de l'erreur, plutôt que de faire de grands pas qui risquent de dépasser l'optimum ou de sur-réagir au bruit d'un arbre particulier. Compenser ce pas plus petit par davantage d'arbres permet d'atteindre une meilleure solution finale, au prix évident d'un temps de calcul proportionnellement plus long.



Correction — Exercice 2


- (a) L'erreur de validation est minimale à $B = 500$ arbres (erreur 0,11) : c'est le point d'arrêt précoce recommandé.
- (b) Entre $B = 500$ et $B = 900$, l'erreur de validation **remonte** ($0,11 \rightarrow 0,13 \rightarrow 0,19$) alors que le modèle continue de s'entraîner : c'est le **sur-ajustement**, le boosting continuant à ajuster des arbres sur des résidus qui ne contiennent plus que du bruit.
- (c) Non : une forêt aléatoire évaluée aux mêmes valeurs de B verrait son erreur **se stabiliser** sans jamais remonter, car chaque arbre supplémentaire de la forêt est construit **indépendamment** des autres (sur un nouvel échantillon bootstrap) et se contente d'être moyenné – ajouter un arbre de plus ne fait que rapprocher l'estimation de sa moyenne théorique, sans jamais réintroduire de bruit appris. Le boosting, à l'inverse, ajuste chaque arbre **sur les résidus** du modèle courant : au-delà d'un certain point, ces résidus ne contiennent plus que du bruit, que le modèle se met à mémoriser.



Correction — Exercice 3

- (a) Lignes par arbre = $0,70 \times 2\,000 = 1\,400$.
- (b) Colonnes par arbre = $0,60 \times 40 = 24$.
- (c) Le sous-échantillonnage des **lignes** reprend exactement le principe du **bootstrap** du chapitre 8 : chaque arbre ne voit qu'un sous-ensemble des observations, ce qui introduit de la diversité entre arbres successifs. Le sous-échantillonnage des **colonnes** reprend le tirage de m variables du chapitre 8 : à chaque arbre (ici, plutôt qu'à chaque nœud comme dans la forêt), seul un sous-ensemble des p

variables est disponible, ce qui limite la domination systématique d'une variable et régularise le modèle – même logique de décorrélation, transposée du contexte parallèle (forêt) au contexte séquentiel (boosting).




2 Exercices cumulatifs (chapitre 9, chapitre 8 et chapitre 1)

Correction — Exercice 4

(a) EQM de la forêt = $0,4 + 1,8 + 1 = 3,2$.

(b) EQM du boosting = $0,3 + 1,0 + 1 = 2,3$.

(c) Classement par EQM croissante : **boosting** (2,3) < **forêt aléatoire** (3,2) < **meilleur modèle du chapitre 1** (4,0, à la complexité 5). Ce classement est parfaitement cohérent avec la trajectoire annoncée par le chapitre : à mesure qu'on abandonne un modèle unique et interprétable (chapitre 1) pour une forêt (interprétabilité faible), puis pour un boosting (interprétabilité très faible), la performance – ici mesurée par l'EQM – s'améliore régulièrement. Le cours échange donc bien, étape par étape, de la lisibilité contre de la précision.




3 Applications en sciences économiques

Correction — Exercice 5

(a) Écart d'AUC = $0,93 - 0,85 = 0,08$.

(b) Une décision de refus de crédit doit souvent être **motivée** auprès du client et du régulateur : un modèle de boosting à des centaines d'arbres ne se lit pas et ne permet pas d'expliquer simplement pourquoi tel dossier a été refusé, alors qu'une régression logistique fournit des coefficients directement interprétables (chapitre 5). Cette contrainte est **réglementaire**, non technique : la performance supérieure du boosting ne suffit pas à la lever.

(c) Un secteur comme le crédit ne peut pas se contenter d'arbitrer entre performance et explicabilité en choisissant simplement le modèle le plus simple : cela sacrifierait 0,08 point d'AUC, potentiellement significatif en termes de pertes évitées sur un grand portefeuille. Une méthode qui permettrait de **récupérer** une part de l'explicabilité tout en conservant (au moins partiellement) la performance du boosting offrirait un compromis bien plus favorable que le choix binaire entre les deux modèles extrêmes.



Correction — Exercice 6

- (a) Seules les configurations ($\eta = 0,1$; $B = 200$), temps 15 min, et ($\eta = 0,05$; $B = 500$), temps 38 min, respectent le budget de 120 minutes. La configuration ($\eta = 0,01$; $B = 3\,000$), à 210 minutes, le dépasse largement.
- (b) Parmi les deux configurations respectant le budget, celle qui maximise l'AUC est ($\eta = 0,05$; $B = 500$), avec une AUC de **0,891** contre 0,870 pour l'autre.
- (c) Gain d'AUC = $0,905 - 0,891 = \mathbf{0,014}$. Ce gain est modeste au regard du dépassement de budget (environ 90 minutes supplémentaires, soit près du **triple** du temps déjà consacré) : selon le contexte opérationnel de l'assureur (fréquence de réentraînement, urgence de la détection), un gain d'à peine 1,4 point d'AUC ne justifie probablement pas un tel surcoût, sauf si l'entraînement n'est réalisé qu'occasionnellement et que chaque point d'AUC a une valeur économique élevée en pertes de fraude évitées.