

Chapitre 9

Le boosting de gradient

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Le lien entre taux d'apprentissage et nombre d'arbres

Une configuration initiale de boosting utilise $\eta_0 = 0,1$ et $B_0 = 200$ arbres. On admet que le produit $\eta \times B$ doit rester approximativement constant pour « parcourir la même distance ».

- (a) Si l'on divise η par 5 (soit $\eta_1 = 0,02$), quel nombre d'arbres B_1 faut-il pour conserver le même produit $\eta \times B$?
- (b) Le budget de calcul plafonne à $B = 4000$ arbres. Quel serait alors le η correspondant, pour conserver ce même produit ?
- (c) Pourquoi un η faible associé à un B élevé donne-t-il en général de meilleurs résultats qu'un η élevé avec un B faible, au prix d'un temps de calcul plus long ?

Exercice 2 — Repérer le point d'arrêt précoce

Un boosting est évalué sur un ensemble de validation à différentes étapes : à $B = 100$ arbres, erreur 0,22 ; à $B = 300$, erreur 0,15 ; à $B = 500$, erreur 0,11 ; à $B = 700$, erreur 0,13 ; à $B = 900$, erreur 0,19.

- (a) À quel nombre d'arbres l'erreur de validation est-elle minimale ? C'est le point d'arrêt précoce recommandé.
- (b) Que se passe-t-il entre $B = 500$ et $B = 900$? Comment nomme-t-on ce phénomène ?
- (c) Une forêt aléatoire évaluée aux mêmes valeurs de B afficherait-elle la même remontée de l'erreur au-delà de 500 arbres ? Justifier par la différence de mécanisme entre les deux méthodes.

Exercice 3 — Calculer le sous-échantillonnage des lignes et des colonnes

Un modèle de boosting de gradient (type XGBoost) est entraîné sur $n = 2000$ observations et $p = 40$ variables, avec un sous-échantillonnage de 70 % des lignes et 60 % des colonnes à chaque arbre.

- (a) Calculer le nombre de lignes considérées pour la construction de chaque arbre.
- (b) Calculer le nombre de colonnes (variables) considérées pour la construction de chaque arbre.
- (c) En quoi ce sous-échantillonnage des lignes et des colonnes reprend-il, respectivement, les mécanismes du bootstrap et du tirage de m variables du chapitre 8 ?

2 Exercices cumulatifs (chapitre 9, chapitre 8 et chapitre 1)

Exercice 4 — Comparer arbre, forêt et boosting sur l'échelle biais-variance du chapitre 1 (chapitre 8)

On reprend le tableau officiel du chapitre 1 (biais², variance et EQM selon la complexité, bruit = 1 dans chaque cas), dont le minimum était une EQM de 4,0 à la complexité 5. Une forêt aléatoire (chapitre 8, $B = 300$, $m \approx 4$) atteint sur ce même portefeuille un biais² de 0,4 et une variance de 1,8. Un boosting de gradient, avec arrêt précoce à $B = 600$ arbres courts, atteint un biais² de 0,3 et une variance de 1,0.

- (a) Calculer l'EQM de la forêt aléatoire.
- (b) Calculer l'EQM du boosting.
- (c) Classer les trois approches – meilleur modèle du tableau du chapitre 1, forêt aléatoire, boosting – par EQM croissante. Ce classement est-il cohérent avec l'idée que le cours « échange systématiquement de la lisibilité contre de la précision » ?

3 Applications en sciences économiques

Exercice 5 — L'arbitrage réglementaire entre performance et explicabilité

Une banque compare un modèle de boosting de gradient ($AUC = 0,93$) à une régression logistique ($AUC = 0,85$) pour son scoring de crédit.

- (a) Calculer l'écart d'AUC entre les deux modèles.
- (b) Malgré cet écart substantiel en faveur du boosting, pourquoi la banque pourrait-elle être contrainte, par la réglementation, d'utiliser la régression logistique pour motiver un refus de crédit auprès d'un client ?
- (c) Le chapitre annonce qu'une partie de la lisibilité perdue peut être « récupérée » sans revenir à un modèle simple. Pourquoi cette piste intéresse-t-elle particulièrement un secteur, comme le crédit, où l'explicabilité est une contrainte réglementaire et non un simple confort ?

Exercice 6 — Arbitrer entre performance et budget de calcul

Un assureur teste trois configurations de boosting pour détecter la fraude aux sinistres, sous un budget de calcul de 120 minutes : ($\eta = 0,1$; $B = 200$), temps 15 min, AUC 0,870 ; ($\eta = 0,05$; $B = 500$), temps 38 min, AUC 0,891 ; ($\eta = 0,01$; $B = 3\,000$), temps 210 min, AUC 0,905.

- (a) Quelles configurations respectent le budget de 120 minutes ?
- (b) Parmi les configurations respectant ce budget, laquelle maximise l'AUC ?
- (c) Calculer le gain d'AUC apporté par la configuration la plus lente par rapport à celle retenue en (b). Ce gain justifie-t-il, à votre avis, de dépasser le budget de calcul de près de 90 minutes ?