

Chapitre 5

La classification : logistique et analyse discriminante

Corrigé

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique


1 Exercices du chapitre

Correction — Exercice 1

(a) $X = 60 : z = -4 + 0,05 \times 60 = -1, p = e^{-1}/(1 + e^{-1}) = \mathbf{0,2689}$. $X = 90 : z = -4 + 0,05 \times 90 = 0,5, p = e^{0,5}/(1 + e^{0,5}) = \mathbf{0,6225}$.

(b) Cote à $X = 60 : 0,2689/(1 - 0,2689) = \mathbf{0,3679}$. Facteur pour +10 unités : $e^{0,05 \times 10} = e^{0,5} = \mathbf{1,6487}$ – la cote est multipliée par environ 1,65.

(c) $e^{\hat{\beta}_1}$ porte sur la **cote**, jamais directement sur la probabilité : c'est le facteur multiplicatif de $p(X)/(1 - p(X))$ pour une hausse d'une unité de X , ce qui n'a pas d'effet constant sur $p(X)$ elle-même (l'effet sur p dépend du point de départ, comme le montre l'écart entre 0,2689 et 0,6225 en (a) pour un même écart de 30 unités de X).




Correction — Exercice 2

(a) $p = \text{cote}/(1 + \text{cote}) = 3/(1 + 3) = \mathbf{0,75}$.

(b) $\text{Cote} = p/(1 - p) = 0,20/0,80 = \mathbf{0,25}$.

(c) La relation $p = \text{cote}/(1 + \text{cote})$ est une bijection valable pour **toute** cote : une cote de 3 correspond *toujours* à une probabilité de 75 %, ce n'est pas une coïncidence propre à cet exercice – c'est la formule même qui relie les deux notions. Ce qui varie d'un exercice à l'autre, c'est la valeur de la cote elle-même (ici 3, contre 0,25 en (b)), pas la formule de passage entre cote et probabilité.




Correction — Exercice 3

(a) $p(p + 1)/2 = 5 \times 6/2 = \mathbf{15}$ paramètres pour l'ADL.

(b) ADQ : $3 \times 15 = \mathbf{45}$ paramètres de covariance au total.

(c) L'ADQ doit estimer **trois fois plus** de paramètres de covariance que l'ADL (45 contre 15), chacun sur les seules observations de sa propre classe (et non sur l'ensemble de l'échantillon comme l'ADL). C'est exactement le compromis biais-variance du chapitre 1 : l'ADQ réduit le biais en autorisant une frontière quadratique propre à chaque classe, mais augmente fortement la variance de l'estimation, car chaque matrice de covariance dispose de bien moins d'observations pour être estimée de façon stable.




2 Exercices cumulatifs (chapitre 5, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $X = 30 : z = -4 + 0,06 \times 30 = -2,2$, $p = e^{-2,2} / (1 + e^{-2,2}) = 0,0998$. $X = 60 : z = -4 + 0,06 \times 60 = -0,4$, $p = e^{-0,4} / (1 + e^{-0,4}) = 0,4013$.

(b) Avec 100 défauts au total répartis uniformément entre les 5 blocs (stratification), chaque bloc de validation contient $100/5 = 20$ défauts. À chaque itération, l'ensemble d'apprentissage (les 4 autres blocs) contient donc $100 - 20 = 80$ défauts.

(c) Le modèle **logistique** reste le plus raisonnable ici. Avec seulement 80 défauts disponibles pour l'apprentissage à chaque itération – et non 800, car ce sont les défauts, la classe rare, qui limitent réellement l'information disponible sur la frontière de décision –, une ADQ (qui exigerait déjà 45 paramètres de covariance rien que pour 5 variables et 3 classes, exercice 3) serait totalement hors de portée avec si peu d'observations dans la classe minoritaire : sa variance d'estimation exploserait, conformément au chapitre 1. La régression logistique, qui ne modélise pas la distribution complète de X dans chaque classe mais directement $P(Y | X)$ avec un nombre de paramètres bien plus restreint, reste le compromis biais-variance le plus adapté à ce volume de données.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $e^{0,5} \approx 1,6487$.

(b) Ce facteur porte sur la **cote** de résiliation, jamais sur sa probabilité : une réclamation supplémentaire multiplie par 1,6487 le rapport $p/(1 - p)$, ce qui se traduit par une hausse de p elle-même dont l'ampleur dépend du niveau de probabilité de départ.

(c) Nouvelle cote = $0,15 \times 1,6487 \approx 0,2473$. Probabilité correspondante = $0,2473 / (1 + 0,2473) \approx 0,1983$, soit une hausse d'environ 4,8 points de probabilité par rapport à la cote de base ($0,15/1,15 \approx 13,0\%$) pour cette seule réclamation supplémentaire.



Correction — Exercice 6

- (a) ADL : $8 \times 9/2 = 36$ paramètres de covariance. ADQ : $4 \times 36 = 144$ paramètres de covariance.
- (b) Observations moyennes par catégorie = $500/4 = 125$.
- (c) Avec 125 observations par catégorie face à 144 paramètres de covariance nécessaires *par classe* pour l'ADQ (soit davantage de paramètres que d'observations dans chaque catégorie prise isolément), l'ADQ serait manifestement sous-déterminée et sa variance d'estimation exploserait. L'assureur devrait donc privilégier l'ADL (seulement 36 paramètres, estimés sur l'ensemble des 500 sinistres), voire la régression logistique multinomiale, plutôt qu'une ADQ hors de portée avec ce volume de données.