

Apprentissage statistique

Chapitre 5 : La classification : logistique et analyse discriminante

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Calculer une probabilité et une cote logistiques

Un modèle logistique estime $p(X) = e^{\beta_0 + \beta_1 X} / (1 + e^{\beta_0 + \beta_1 X})$ avec $\hat{\beta}_0 = -4$ et $\hat{\beta}_1 = 0,05$ (X = revenu en milliers de dirhams).

- (a) Calculer $p(X)$ pour $X = 60$, puis pour $X = 90$.
- (b) Calculer la cote (odds) de défaut pour $X = 60$, puis le facteur multiplicatif de cette cote pour une hausse de 10 unités de X .
- (c) Interpréter $e^{\hat{\beta}_1}$: porte-t-il sur la probabilité de défaut ou sur sa cote ?

Exercice 2 — Passer d'une probabilité à une cote, et inversement

- (a) Une cote de défaut vaut 3 (trois contre un). Calculer la probabilité de défaut correspondante.
- (b) Une probabilité de défaut vaut 0,20. Calculer la cote correspondante.
- (c) Expliquer, à partir de ces deux calculs, pourquoi une cote de 3 ne signifie pas une probabilité de 75 % en général, mais le devient bien ici – quelle relation entre cote et probabilité rend ce résultat cohérent ?

Exercice 3 — Compter les paramètres de covariance en ADL et en ADQ

On considère un problème de classification à $K = 3$ classes, avec $p = 5$ variables explicatives.

- (a) Une matrice de covariance symétrique de taille $p \times p$ compte $p(p + 1)/2$ paramètres distincts. Calculer ce nombre pour $p = 5$: c'est le nombre de paramètres de covariance estimés par l'ADL (une seule matrice, commune aux 3 classes).
- (b) Calculer le nombre total de paramètres de covariance estimés par l'ADQ, qui estime une matrice propre à chacune des 3 classes.
- (c) Pourquoi l'ADQ, malgré sa frontière de décision plus flexible, exige-t-elle beaucoup plus de données que l'ADL pour être estimée de façon fiable ?

2 Exercices cumulatifs (chapitre 5, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Un modèle logistique sur le portefeuille de crédit (introduction, chapitre 2, chapitre 1)

Sur le portefeuille de **mille dossiers de crédit, dont cent défauts** (10 %) de l'introduction, un modèle logistique donne $\hat{\beta}_0 = -4$ et $\hat{\beta}_1 = 0,06$ pour le ratio d'endettement X .

- (a) Calculer $p(X)$ pour un ratio $X = 30$, puis pour $X = 60$.
- (b) En reprenant le découpage en validation croisée stratifiée à 5 blocs du chapitre 2 (bloc de 200 dossiers, apprentissage de 800), calculer le nombre de défauts attendu dans chaque bloc de validation, puis le nombre de défauts restant dans l'ensemble d'apprentissage à chaque itération.
- (c) Avec seulement 80 défauts disponibles à l'apprentissage à chaque itération de la validation croisée, et sachant (exercice 3) qu'une ADQ à 3 classes et 5 variables exigerait déjà 45 paramètres de covariance à elle seule, quel modèle de classification – logistique, ADL ou ADQ – serait le plus raisonnable ici ? Justifier en reliant biais, variance (chapitre 1) et disponibilité des données.

3 Applications en sciences économiques

Exercice 5 — Interpréter un coefficient logistique de résiliation

Un opérateur télécom modélise la résiliation d'abonnement (*churn*) par régression logistique. Le coefficient associé au nombre de réclamations déposées dans l'année vaut $\hat{\beta} = 0,5$.

- (a) Calculer $e^{\hat{\beta}}$.
- (b) Un client ayant déposé une réclamation de plus qu'un autre voit-il sa *probabilité* de résiliation multipliée par ce facteur, ou sa *cote* de résiliation? Justifier.
- (c) Un client de référence a une cote de résiliation de base de 0,15. Calculer sa nouvelle cote après une réclamation supplémentaire, puis la probabilité de résiliation correspondante.

Exercice 6 — Choisir entre ADL et ADQ pour un assureur

Un assureur souhaite classer chaque sinistre en $K = 4$ catégories de gravité, à partir de $p = 8$ variables (montant des dommages, type de véhicule, etc.), sur un portefeuille de 500 sinistres passés.

- (a) Calculer le nombre de paramètres de covariance requis par une ADL, puis par une ADQ.
- (b) En supposant les 500 sinistres répartis également entre les 4 catégories, calculer le nombre moyen d'observations disponibles par catégorie.
- (c) Au vu du rapport entre ce nombre d'observations par catégorie et le nombre de paramètres de covariance de l'ADQ calculé en (a), quelle méthode l'assureur devrait-il raisonnablement privilégier?


1 Exercices du chapitre

Correction — Exercice 1

(a) $X = 60 : z = -4 + 0,05 \times 60 = -1, p = e^{-1}/(1 + e^{-1}) = \mathbf{0,2689}$. $X = 90 : z = -4 + 0,05 \times 90 = 0,5$, $p = e^{0,5}/(1 + e^{0,5}) = \mathbf{0,6225}$.

(b) Cote à $X = 60 : 0,2689/(1 - 0,2689) = \mathbf{0,3679}$. Facteur pour +10 unités : $e^{0,05 \times 10} = e^{0,5} = \mathbf{1,6487}$ – la cote est multipliée par environ 1,65.

(c) $e^{\hat{\beta}_1}$ porte sur la **cote**, jamais directement sur la probabilité : c'est le facteur multiplicatif de $p(X)/(1 - p(X))$ pour une hausse d'une unité de X , ce qui n'a pas d'effet constant sur $p(X)$ elle-même (l'effet sur p dépend du point de départ, comme le montre l'écart entre 0,2689 et 0,6225 en (a) pour un même écart de 30 unités de X).




Correction — Exercice 2

(a) $p = \text{cote}/(1 + \text{cote}) = 3/(1 + 3) = \mathbf{0,75}$.

(b) $\text{Cote} = p/(1 - p) = 0,20/0,80 = \mathbf{0,25}$.

(c) La relation $p = \text{cote}/(1 + \text{cote})$ est une bijection valable pour **toute** cote : une cote de 3 correspond *toujours* à une probabilité de 75 %, ce n'est pas une coïncidence propre à cet exercice – c'est la formule même qui relie les deux notions. Ce qui varie d'un exercice à l'autre, c'est la valeur de la cote elle-même (ici 3, contre 0,25 en (b)), pas la formule de passage entre cote et probabilité.




Correction — Exercice 3

(a) $p(p + 1)/2 = 5 \times 6/2 = \mathbf{15}$ paramètres pour l'ADL.

(b) ADQ : $3 \times 15 = \mathbf{45}$ paramètres de covariance au total.

(c) L'ADQ doit estimer **trois fois plus** de paramètres de covariance que l'ADL (45 contre 15), chacun sur les seules observations de sa propre classe (et non sur l'ensemble de l'échantillon comme l'ADL). C'est exactement le compromis biais-variance du chapitre 1 : l'ADQ réduit le biais en autorisant une frontière quadratique propre à chaque classe, mais augmente fortement la variance de l'estimation, car chaque matrice de covariance dispose de bien moins d'observations pour être estimée de façon stable.




2 Exercices cumulatifs (chapitre 5, chapitre 3, chapitre 2, chapitre 1 et introduction)

Correction — Exercice 4

(a) $X = 30 : z = -4 + 0,06 \times 30 = -2,2, p = e^{-2,2} / (1 + e^{-2,2}) = 0,0998$. $X = 60 : z = -4 + 0,06 \times 60 = -0,4, p = e^{-0,4} / (1 + e^{-0,4}) = 0,4013$.

(b) Avec 100 défauts au total répartis uniformément entre les 5 blocs (stratification), chaque bloc de validation contient $100/5 = 20$ défauts. À chaque itération, l'ensemble d'apprentissage (les 4 autres blocs) contient donc $100 - 20 = 80$ défauts.

(c) Le modèle **logistique** reste le plus raisonnable ici. Avec seulement 80 défauts disponibles pour l'apprentissage à chaque itération – et non 800, car ce sont les défauts, la classe rare, qui limitent réellement l'information disponible sur la frontière de décision –, une ADQ (qui exigerait déjà 45 paramètres de covariance rien que pour 5 variables et 3 classes, exercice 3) serait totalement hors de portée avec si peu d'observations dans la classe minoritaire : sa variance d'estimation exploserait, conformément au chapitre 1. La régression logistique, qui ne modélise pas la distribution complète de X dans chaque classe mais directement $P(Y | X)$ avec un nombre de paramètres bien plus restreint, reste le compromis biais-variance le plus adapté à ce volume de données.




3 Applications en sciences économiques

Correction — Exercice 5

(a) $e^{0,5} \approx 1,6487$.

(b) Ce facteur porte sur la **cote** de résiliation, jamais sur sa probabilité : une réclamation supplémentaire multiplie par 1,6487 le rapport $p/(1 - p)$, ce qui se traduit par une hausse de p elle-même dont l'ampleur dépend du niveau de probabilité de départ.

(c) Nouvelle cote = $0,15 \times 1,6487 \approx 0,2473$. Probabilité correspondante = $0,2473 / (1 + 0,2473) \approx 0,1983$, soit une hausse d'environ 4,8 points de probabilité par rapport à la cote de base ($0,15/1,15 \approx 13,0\%$) pour cette seule réclamation supplémentaire.



Correction — Exercice 6

- (a) ADL : $8 \times 9/2 = 36$ paramètres de covariance. ADQ : $4 \times 36 = 144$ paramètres de covariance.
- (b) Observations moyennes par catégorie = $500/4 = 125$.
- (c) Avec 125 observations par catégorie face à 144 paramètres de covariance nécessaires *par classe* pour l'ADQ (soit davantage de paramètres que d'observations dans chaque catégorie prise isolément), l'ADQ serait manifestement sous-déterminée et sa variance d'estimation exploserait. L'assureur devrait donc privilégier l'ADL (seulement 36 paramètres, estimés sur l'ensemble des 500 sinistres), voire la régression logistique multinomiale, plutôt qu'une ADQ hors de portée avec ce volume de données.