

Chapitre 5

La classification : logistique et analyse discriminante

Feuille d'exercices

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre

Exercice 1 — Calculer une probabilité et une cote logistiques

Un modèle logistique estime $p(X) = e^{\beta_0 + \beta_1 X} / (1 + e^{\beta_0 + \beta_1 X})$ avec $\hat{\beta}_0 = -4$ et $\hat{\beta}_1 = 0,05$ (X = revenu en milliers de dirhams).

- (a) Calculer $p(X)$ pour $X = 60$, puis pour $X = 90$.
- (b) Calculer la cote (odds) de défaut pour $X = 60$, puis le facteur multiplicatif de cette cote pour une hausse de 10 unités de X .
- (c) Interpréter $e^{\hat{\beta}_1}$: porte-t-il sur la probabilité de défaut ou sur sa cote ?

Exercice 2 — Passer d'une probabilité à une cote, et inversement

- (a) Une cote de défaut vaut 3 (trois contre un). Calculer la probabilité de défaut correspondante.
- (b) Une probabilité de défaut vaut 0,20. Calculer la cote correspondante.
- (c) Expliquer, à partir de ces deux calculs, pourquoi une cote de 3 ne signifie pas une probabilité de 75 % en général, mais le devient bien ici – quelle relation entre cote et probabilité rend ce résultat cohérent ?

Exercice 3 — Compter les paramètres de covariance en ADL et en ADQ

On considère un problème de classification à $K = 3$ classes, avec $p = 5$ variables explicatives.

- (a) Une matrice de covariance symétrique de taille $p \times p$ compte $p(p + 1)/2$ paramètres distincts. Calculer ce nombre pour $p = 5$: c'est le nombre de paramètres de covariance estimés par l'ADL (une seule matrice, commune aux 3 classes).
- (b) Calculer le nombre total de paramètres de covariance estimés par l'ADQ, qui estime une matrice propre à chacune des 3 classes.
- (c) Pourquoi l'ADQ, malgré sa frontière de décision plus flexible, exige-t-elle beaucoup plus de données que l'ADL pour être estimée de façon fiable ?

2 Exercices cumulatifs (chapitre 5, chapitre 3, chapitre 2, chapitre 1 et introduction)

Exercice 4 — Un modèle logistique sur le portefeuille de crédit (introduction, chapitre 2, chapitre 1)

Sur le portefeuille de **mille dossiers de crédit, dont cent défauts** (10 %) de l'introduction, un modèle logistique donne $\hat{\beta}_0 = -4$ et $\hat{\beta}_1 = 0,06$ pour le ratio d'endettement X .

- (a) Calculer $p(X)$ pour un ratio $X = 30$, puis pour $X = 60$.
- (b) En reprenant le découpage en validation croisée stratifiée à 5 blocs du chapitre 2 (bloc de 200 dossiers, apprentissage de 800), calculer le nombre de défauts attendu dans chaque bloc de validation, puis le nombre de défauts restant dans l'ensemble d'apprentissage à chaque itération.
- (c) Avec seulement 80 défauts disponibles à l'apprentissage à chaque itération de la validation croisée, et sachant (exercice 3) qu'une ADQ à 3 classes et 5 variables exigerait déjà 45 paramètres de covariance à elle seule, quel modèle de classification – logistique, ADL ou ADQ – serait le plus raisonnable ici ? Justifier en reliant biais, variance (chapitre 1) et disponibilité des données.

3 Applications en sciences économiques

Exercice 5 — Interpréter un coefficient logistique de résiliation

Un opérateur télécom modélise la résiliation d'abonnement (*churn*) par régression logistique. Le coefficient associé au nombre de réclamations déposées dans l'année vaut $\hat{\beta} = 0,5$.

- (a) Calculer $e^{\hat{\beta}}$.
- (b) Un client ayant déposé une réclamation de plus qu'un autre voit-il sa *probabilité* de résiliation multipliée par ce facteur, ou sa *cote* de résiliation? Justifier.
- (c) Un client de référence a une cote de résiliation de base de 0,15. Calculer sa nouvelle cote après une réclamation supplémentaire, puis la probabilité de résiliation correspondante.

Exercice 6 — Choisir entre ADL et ADQ pour un assureur

Un assureur souhaite classer chaque sinistre en $K = 4$ catégories de gravité, à partir de $p = 8$ variables (montant des dommages, type de véhicule, etc.), sur un portefeuille de 500 sinistres passés.

- (a) Calculer le nombre de paramètres de covariance requis par une ADL, puis par une ADQ.
- (b) En supposant les 500 sinistres répartis également entre les 4 catégories, calculer le nombre moyen d'observations disponibles par catégorie.
- (c) Au vu du rapport entre ce nombre d'observations par catégorie et le nombre de paramètres de covariance de l'ADQ calculé en (a), quelle méthode l'assureur devrait-il raisonnablement privilégier?