

Apprentissage statistique

Chapitre 6 : Évaluer un classifieur : matrice de confusion, ROC, AUC

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Construire les mesures à partir d'une matrice de confusion

Un modèle de détection de fraude est testé sur 2 000 transactions, dont 50 frauduleuses. Sa matrice de confusion donne $VP = 30$, $FN = 20$, $FP = 120$, $VN = 1\,830$.

- (a) Calculer l'exactitude, la précision, le rappel et la spécificité de ce modèle.
- (b) Calculer le score F_1 .
- (c) Calculer l'exactitude d'un classifieur trivial qui prédirait «jamais de fraude». Ce classifieur trivial bat-il le modèle sur ce seul critère?

Exercice 2 — Situer un point sur la courbe ROC

Un premier modèle atteint un rappel de 0,72 et une spécificité de 0,65. Un second modèle atteint un rappel de 0,40 pour un taux de faux positifs de 0,55.

- (a) Calculer le taux de faux positifs du premier modèle, et donner son point ROC (taux de FP ; rappel).
- (b) Le premier modèle se situe-t-il au-dessus ou en dessous de la diagonale? Qu'est-ce que cela signifie?
- (c) Le second modèle se situe-t-il au-dessus ou en dessous de la diagonale? Que devrait-on faire, en pratique, d'un tel modèle?

Exercice 3 — Approcher l'AUC par la méthode des trapèzes

Une courbe ROC est connue en cinq points (taux de FP ; rappel) : $(0; 0)$, $(0,1; 0,5)$, $(0,3; 0,75)$, $(0,6; 0,9)$, $(1; 1)$.

- (a) Calculer l'aire du trapèze entre le premier et le deuxième point.
- (b) Calculer l'aire des trois trapèzes restants, puis l'AUC totale (somme des quatre aires).
- (c) Cette AUC correspond-elle plutôt à un modèle acceptable, excellent, ou franchement suspect, au regard des repères du cours?

2 Exercices cumulatifs (chapitre 6, chapitre 2 et introduction)

Exercice 4 — Décliner la matrice de confusion du cours par bloc de validation croisée (chapitre 2, introduction)

On reprend la matrice de confusion officielle du chapitre, obtenue sur les **mille dossiers de crédit** de l'introduction (100 défauts) : $VP = 60$, $FN = 40$, $FP = 90$, $VN = 810$.

- (a) Vérifier, à partir de cette matrice, que le rappel vaut bien 0,60 et la spécificité 0,90, comme annoncé dans le chapitre.
- (b) On reprend le découpage en validation croisée stratifiée à 5 blocs du chapitre 2 : chaque bloc de 200 dossiers contient 20 défauts et 180 bons clients. En supposant que le rappel et la spécificité du modèle restent les mêmes sur chaque bloc qu'à l'échelle du portefeuille entier, calculer les VP , FN , FP et VN attendus sur un seul bloc de validation.
- (c) Calculer l'exactitude du modèle sur ce bloc, puis celle du classifieur trivial « toujours bon client » sur ce même bloc. Retrouve-t-on, au niveau d'un seul bloc, la même mise en garde que celle du chapitre à l'échelle des mille dossiers?

3 Applications en sciences économiques

Exercice 5 — Dépistage médical : pourquoi le rappel prime

Un dépistage médical est testé sur 5 000 patients, dont 200 sont réellement malades. Sa matrice de confusion donne $VP = 170$, $FN = 30$, $FP = 750$, $VN = 4 050$.

- (a) Calculer le rappel et la précision de ce test.
- (b) Calculer l'exactitude du test, puis celle d'un classifieur trivial «jamais malade».
- (c) Bien que l'exactitude du test soit inférieure à celle du classifieur trivial, pourquoi l'équipe médicale devrait-elle malgré tout déployer ce test, conformément à la priorité donnée au rappel pour le dépistage d'une maladie grave?

Exercice 6 — Filtre anti-spam : pourquoi la précision prime

Un filtre anti-spam est testé sur 3 000 courriels, dont 400 sont réellement des spams. Sa matrice de confusion donne $VP = 300$, $FN = 100$, $FP = 30$, $VN = 2 570$.

- (a) Calculer la précision et le rappel de ce filtre.
- (b) Calculer son exactitude.
- (c) Le filtre laisse passer 100 spams sans les bloquer. Pourquoi une précision élevée (0,91) reste-t-elle malgré tout la priorité pour un filtre anti-spam, plutôt qu'un rappel plus élevé qui bloquerait davantage de spams au prix de plus de faux positifs?


1 Exercices du chapitre

Correction — Exercice 1

(a) Exactitude = $(30 + 1\,830)/2\,000 = 1\,860/2\,000 = \mathbf{0,93}$. Précision = $30/(30 + 120) = 30/150 = \mathbf{0,20}$. Rappel = $30/(30 + 20) = 30/50 = \mathbf{0,60}$. Spécificité = $1\,830/(1\,830 + 120) = 1\,830/1\,950 \approx \mathbf{0,9385}$.

(b) $F_1 = 2 \times (0,20 \times 0,60)/(0,20 + 0,60) = 2 \times 0,12/0,80 = \mathbf{0,30}$.

(c) Exactitude du classifieur trivial = $(120 + 1\,830)/2\,000 = 1\,950/2\,000 = \mathbf{0,975}$. Oui, il bat très largement le modèle sur ce seul critère ($0,975 > 0,93$), tout en étant totalement inutile : son rappel est nul, il ne détecte **aucune** fraude – exactement le piège de l'exactitude décrit dans le chapitre.




Correction — Exercice 2

(a) Taux de FP = $1 - 0,65 = \mathbf{0,35}$. Point ROC = $(0,35; 0,72)$.

(b) Le point $(0,35; 0,72)$ est **au-dessus** de la diagonale, puisque $0,72 > 0,35$: le premier modèle fait mieux que le hasard, il ordonne globalement correctement les dossiers.

(c) Le point $(0,55; 0,40)$ est **en dessous** de la diagonale, puisque $0,40 < 0,55$: ce second modèle fait **pire** que le hasard. En pratique, on inverserait purement et simplement ses prédictions (prédire « bon » là où il prédit « défaut », et inversement), ce qui le ramènerait au point $(0,45; 0,60)$, au-dessus de la diagonale.




Correction — Exercice 3

(a) Premier trapèze : $(0,1 - 0) \times (0 + 0,5)/2 = 0,1 \times 0,25 = \mathbf{0,025}$.

(b) Deuxième trapèze : $(0,3 - 0,1) \times (0,5 + 0,75)/2 = 0,2 \times 0,625 = 0,125$. Troisième : $(0,6 - 0,3) \times (0,75 + 0,9)/2 = 0,3 \times 0,825 = 0,2475$. Quatrième : $(1 - 0,6) \times (0,9 + 1)/2 = 0,4 \times 0,95 = 0,38$. AUC totale = $0,025 + 0,125 + 0,2475 + 0,38 = \mathbf{0,7775}$.


(c) Une AUC de 0,7775 se situe dans la fourchette « acceptable » (0,7 à 0,8) du repère du cours : ni médiocre (proche de 0,5), ni suspecte (au-delà de 0,95).



2 Exercices cumulatifs (chapitre 6, chapitre 2 et introduction)

Correction — Exercice 4


- (a) Rappel = $60/(60 + 40) = 60/100 = 0,60$ ✓. Spécificité = $810/(810 + 90) = 810/900 = 0,90$ ✓ – conforme aux valeurs annoncées dans le chapitre.
- (b) Avec un rappel de 0,60 sur 20 défauts : $VP = 0,60 \times 20 = 12$, $FN = 20 - 12 = 8$. Avec une spécificité de 0,90 sur 180 bons clients : $VN = 0,90 \times 180 = 162$, $FP = 180 - 162 = 18$.
- (c) Exactitude du modèle sur le bloc = $(12 + 162)/200 = 174/200 = 0,87$ – exactement la même valeur que sur les mille dossiers, car les taux de rappel et de spécificité, supposés constants, reproduisent mécaniquement le même ratio. Exactitude du classifieur trivial sur le bloc = $180/200 = 0,90$. On retrouve **exactement** la même mise en garde qu'à l'échelle des mille dossiers : même sur un seul bloc de validation croisée du chapitre 2, le classifieur trivial « bat » le modèle sur la seule exactitude ($0,90 > 0,87$), ce qui confirme que ce piège n'est pas un artefact de la taille de l'échantillon complet, mais une propriété structurelle du déséquilibre des classes, présente à toutes les échelles de la validation.



3 Applications en sciences économiques

Correction — Exercice 5

- (a) Rappel = $170/(170 + 30) = 170/200 = 0,85$. Précision = $170/(170 + 750) = 170/920 \approx 0,1848$.
- (b) Exactitude du test = $(170 + 4050)/5000 = 4220/5000 = 0,844$. Exactitude du classifieur trivial « jamais malade » = $(750 + 4050)/5000 = 4800/5000 = 0,96$.
- (c) Malgré une exactitude inférieure (0,844 contre 0,96), l'équipe médicale doit privilégier ce test car, pour le dépistage d'une maladie grave, le coût d'un **faux négatif** (un malade non détecté, qui ne sera pas traité à temps) dépasse de très loin le coût d'un **faux positif** (un patient sain envoyé à tort en examen complémentaire). Le rappel de 0,85 signifie que le test détecte 85 % des cas réels, contre 0 % pour le classifieur trivial : c'est exactement la priorité que le chapitre attribue au rappel dans ce contexte, quel qu'en soit le coût en fausses alertes.



Correction — Exercice 6

(a) Précision = $300 / (300 + 30) = 300 / 330 \approx \mathbf{0,9091}$. Rappel = $300 / (300 + 100) = 300 / 400 = \mathbf{0,75}$.

(b) Exactitude = $(300 + 2\,570) / 3\,000 = 2\,870 / 3\,000 \approx \mathbf{0,9567}$.

(c) Pour un filtre anti-spam, un **faux positif** (un courriel légitime bloqué à tort, potentiellement important : contrat, facture, message professionnel) coûte typiquement bien plus cher à l'utilisateur qu'un **faux négatif** (un spam qui reste visible dans la boîte de réception, simple désagrément que l'utilisateur peut ignorer ou supprimer). Une précision élevée de 0,9091 garantit que, parmi les courriels bloqués, l'immense majorité sont bien des spams – augmenter le rappel au détriment de la précision risquerait de bloquer davantage de courriels légitimes, un coût que le chapitre juge prioritaire à éviter dans ce contexte précis.