

Introduction

Expliquer ou prévoir : deux objectifs distincts

Corrigé


Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger
Exercices et corrigés · Apprentissage statistique

1 Exercices du chapitre


Correction — Exercice 1

- (a) Erreur réductible = $12,5 - 3,2 = 9,3$.
(b) Nouvelle erreur totale = $2,1 + 3,2 = 5,3$.
(c) Non. Le bruit $\sigma^2 = 3,2$ est **irréductible** par construction : aucune amélioration de $\hat{f}$, aussi bonne soit-elle, ne peut faire descendre l'erreur réductible en dessous de 0, donc l'erreur totale ne peut jamais descendre en dessous de 3,2. C'est la limite absolue posée dès l'introduction.




Correction — Exercice 2

- (a) $5\,000 \times 0,60 = 3\,000$ (apprentissage), $5\,000 \times 0,20 = 1\,000$ (validation), $5\,000 \times 0,20 = 1\,000$ (test).
(b) $5\,000 \times 0,70 = 3\,500$ (apprentissage), $5\,000 \times 0,15 = 750$ (validation), $5\,000 \times 0,15 = 750$ (test).
(c) Parce que la moyenne et l'écart-type calculés sur les 5 000 dossiers **contiennent déjà l'information du test**. En normalisant avant de découper, chaque sous-ensemble « voit » indirectement les statistiques des deux autres, ce qui constitue une fuite de données : l'erreur mesurée ensuite sur le test sera artificiellement optimiste, car ce test n'est plus réellement indépendant de l'apprentissage.



Correction — Exercice 3

- (a) Modèle A : $0,35 - 0,02 = 0,33$. Modèle B : $0,31 - 0,28 = 0,03$.
(b) Le modèle A souffre manifestement de **sur-ajustement** : son écart de 0,33 est considérable, avec une erreur d'apprentissage quasi nulle (0,02) mais une erreur de test élevée (0,35) – signe qu'il a mémorisé le bruit de l'échantillon d'apprentissage plutôt qu'appris une structure généralisable. Le modèle B, avec un écart de seulement 0,03, est raisonnablement ajusté : ses deux erreurs sont proches, et surtout son erreur de test (0,31) est **inférieure** à celle du modèle A (0,35), malgré une erreur d'apprentissage plus élevée. C'est bien l'écart entre les deux erreurs qui diagnostique, non le niveau de l'erreur d'apprentissage seule.
(c) Le levier le plus direct est la **régularisation** : brider la flexibilité du modèle A pour accepter un peu de biais (l'erreur d'apprentissage remontera un peu au-dessus de 0,02) en échange d'une forte réduction de variance (l'erreur de test devrait se rapprocher de celle du modèle B).




2 Applications en sciences économiques

Correction — Exercice 4

(a) L'équipe a commis une **fuite de données** : en calculant moyenne et écart-type de normalisation sur l'ensemble des 5 000 dossiers *avant* de découper, les statistiques utilisées pour normaliser l'ensemble d'apprentissage contiennent déjà de l'information issue de l'ensemble de test (et de validation). Le test n'est donc plus réellement « non vu » au moment de l'évaluation.

(b) Écart = $0,91 - 0,68 = 0,23$ point d'AUC – un écart considérable entre la performance annoncée en interne et la performance réellement observée en production.

(c) L'ordre correct est : **d'abord** découper les 5 000 dossiers en apprentissage/validation/test, **puis** calculer la moyenne et l'écart-type de normalisation uniquement sur l'ensemble d'apprentissage, et enfin appliquer ces mêmes statistiques (sans les recalculer) pour transformer les ensembles de validation et de test.



Correction — Exercice 5

(a) Il s'agit clairement de l'objectif « **expliquer** » : l'équipe veut comprendre *pourquoi* les clients résilient, afin de produire des recommandations actionnables pour la direction – pas seulement identifier, sans les comprendre, les clients à risque.

(b) Un modèle très flexible à 40 variables, même avec un excellent ajustement interne ($R^2 = 0,82$), mélange typiquement des effets corrélés, des interactions complexes et parfois des variables qui sont des **conséquences** plutôt que des **causes** du churn (comme le nombre de relances dans l'exemple du chapitre). Ses coefficients, s'il en a, ne sont ni stables ni interprétables un par un : on ne peut pas en tirer une explication fiable, même si sa capacité de prévision brute est bonne.

(c) L'arbitrage à retenir est celui du chapitre entre **expliquer** et **prévoir** : ici, l'équipe doit accepter un modèle plus simple, quitte à perdre du pouvoir prédictif brut (un R^2 interne plus faible), en échange de coefficients peu nombreux et interprétables, seuls capables de répondre à la question « pourquoi ? » posée par la direction.