

Apprentissage statistique

Introduction : Expliquer ou prévoir : deux objectifs distincts

Exercices corrigés

Jaouad Madkour

Faculté d'Économie et de Gestion de Tanger

Apprentissage statistique

Table des matières

Partie 1 --- Énoncés	1
Partie 2 --- Corrections	3

1 Exercices du chapitre

Exercice 1 — Décomposer l'erreur réductible et irréductible

Un modèle de prévision de défaut affiche une erreur quadratique totale de 12,5. Des études antérieures sur ce marché ont établi que le bruit irréductible vaut $\sigma^2 = 3,2$.

- (a) Calculer l'erreur réductible de ce modèle.
- (b) Une nouvelle méthode ramène l'erreur réductible à 2,1. Calculer la nouvelle erreur totale.
- (c) Ce modèle peut-il un jour atteindre une erreur totale strictement inférieure à 3,2 ? Justifier.

Exercice 2 — Découper une base en apprentissage, validation et test

Une base de 5 000 dossiers de crédit doit être découpée en trois ensembles.

- (a) Avec un découpage 60 % / 20 % / 20 %, calculer l'effectif de chacun des trois ensembles.
- (b) Avec un découpage 70 % / 15 % / 15 %, recalculer ces trois effectifs.
- (c) Pourquoi ne faut-il jamais calculer une moyenne ou un écart-type de normalisation sur l'ensemble des 5 000 dossiers *avant* d'effectuer ce découpage ?

Exercice 3 — Diagnostiquer un sous-ajustement ou un sur-ajustement

Deux modèles sont entraînés sur les mêmes données. Le modèle *A* affiche une erreur d'apprentissage de 0,02 et une erreur de test de 0,35. Le modèle *B* affiche une erreur d'apprentissage de 0,28 et une erreur de test de 0,31.

- (a) Calculer l'écart entre erreur de test et erreur d'apprentissage pour chacun des deux modèles.
- (b) Lequel des deux modèles souffre manifestement de sur-ajustement ? Justifier par l'écart calculé, et non par le seul niveau de l'erreur de test.
- (c) Sans changer de méthode, quel levier simple évoqué dans le chapitre permettrait de rapprocher le modèle *A* du modèle *B* ?

2 Applications en sciences économiques

Exercice 4 — Une fuite de données dans un scoring de crédit

Une banque construit un modèle de scoring de défaut. Avant de découper ses données, l'équipe calcule la moyenne et l'écart-type de chaque variable sur l'ensemble des 5 000 dossiers, puis normalise toutes les variables avec ces valeurs, et découpe *ensuite* en apprentissage/validation/test. Le modèle atteint une AUC de 0,91 sur l'ensemble de test interne, mais seulement 0,68 une fois mis en production sur de nouveaux dossiers.

- (a) Identifier précisément l'erreur méthodologique commise par l'équipe.
- (b) Calculer l'écart entre l'AUC annoncée en interne et l'AUC réellement observée en production.
- (c) Décrire l'ordre correct des opérations qui aurait évité cette fuite.

Exercice 5 — Choisir entre expliquer et prévoir dans un projet marketing

Une équipe marketing dispose de 40 variables décrivant ses clients et cherche à comprendre *pourquoi* certains clients résilient leur abonnement, afin d'écrire des recommandations pour la direction. Un data scientist propose un modèle très flexible combinant les 40 variables, dont le pouvoir prédictif interne atteint $R^2 = 0,82$.


- (a) Le besoin de l'équipe marketing correspond-il à l'objectif « expliquer » ou à l'objectif « prévoir » au sens du chapitre ?

- (b) Pourquoi un modèle très flexible à 40 variables, même avec $R^2 = 0,82$, est-il mal adapté à ce besoin précis, indépendamment de sa qualité de prévision ?
- (c) Quel arbitrage du chapitre devrait guider le choix d'un modèle plus simple ici, même au prix d'un R^2 interne plus faible ?

1 Exercices du chapitre


Correction — Exercice 1

- (a) Erreur réductible = $12,5 - 3,2 = 9,3$.
(b) Nouvelle erreur totale = $2,1 + 3,2 = 5,3$.
(c) Non. Le bruit $\sigma^2 = 3,2$ est **irréductible** par construction : aucune amélioration de $\hat{f}$, aussi bonne soit-elle, ne peut faire descendre l'erreur réductible en dessous de 0, donc l'erreur totale ne peut jamais descendre en dessous de 3,2. C'est la limite absolue posée dès l'introduction.




Correction — Exercice 2

- (a) $5\,000 \times 0,60 = 3\,000$ (apprentissage), $5\,000 \times 0,20 = 1\,000$ (validation), $5\,000 \times 0,20 = 1\,000$ (test).
(b) $5\,000 \times 0,70 = 3\,500$ (apprentissage), $5\,000 \times 0,15 = 750$ (validation), $5\,000 \times 0,15 = 750$ (test).
(c) Parce que la moyenne et l'écart-type calculés sur les 5 000 dossiers **contiennent déjà l'information du test**. En normalisant avant de découper, chaque sous-ensemble « voit » indirectement les statistiques des deux autres, ce qui constitue une fuite de données : l'erreur mesurée ensuite sur le test sera artificiellement optimiste, car ce test n'est plus réellement indépendant de l'apprentissage.



Correction — Exercice 3


- (a) Modèle A : $0,35 - 0,02 = 0,33$. Modèle B : $0,31 - 0,28 = 0,03$.
(b) Le modèle A souffre manifestement de **sur-ajustement** : son écart de 0,33 est considérable, avec une erreur d'apprentissage quasi nulle (0,02) mais une erreur de test élevée (0,35) – signe qu'il a mémorisé le bruit de l'échantillon d'apprentissage plutôt qu'appris une structure généralisable. Le modèle B, avec un écart de seulement 0,03, est raisonnablement ajusté : ses deux erreurs sont proches, et surtout son erreur de test (0,31) est **inférieure** à celle du modèle A (0,35), malgré une erreur d'apprentissage plus élevée. C'est bien l'écart entre les deux erreurs qui diagnostique, non le niveau de l'erreur d'apprentissage seule.
(c) Le levier le plus direct est la **régularisation** : brider la flexibilité du modèle A pour accepter un peu de biais (l'erreur d'apprentissage remontera un peu au-dessus de 0,02) en échange d'une forte réduction de variance (l'erreur de test devrait se rapprocher de celle du modèle B).



2 Applications en sciences économiques

Correction — Exercice 4

- (a) L'équipe a commis une **fuite de données** : en calculant moyenne et écart-type de normalisation sur l'ensemble des 5 000 dossiers *avant* de découper, les statistiques utilisées pour normaliser l'ensemble d'apprentissage contiennent déjà de l'information issue de l'ensemble de test (et de validation). Le test n'est donc plus réellement « non vu » au moment de l'évaluation.
- (b) Écart = $0,91 - 0,68 = 0,23$ point d'AUC – un écart considérable entre la performance annoncée en interne et la performance réellement observée en production.
- (c) L'ordre correct est : **d'abord** découper les 5 000 dossiers en apprentissage/validation/test, **puis** calculer la moyenne et l'écart-type de normalisation uniquement sur l'ensemble d'apprentissage, et enfin appliquer ces mêmes statistiques (sans les recalculer) pour transformer les ensembles de validation et de test.



Correction — Exercice 5

- (a) Il s'agit clairement de l'objectif « **expliquer** » : l'équipe veut comprendre *pourquoi* les clients résilient, afin de produire des recommandations actionnables pour la direction – pas seulement identifier, sans les comprendre, les clients à risque.
- (b) Un modèle très flexible à 40 variables, même avec un excellent ajustement interne ($R^2 = 0,82$), mélange typiquement des effets corrélés, des interactions complexes et parfois des variables qui sont des **conséquences** plutôt que des **causes** du churn (comme le nombre de relances dans l'exemple du chapitre). Ses coefficients, s'il en a, ne sont ni stables ni interprétables un par un : on ne peut pas en tirer une explication fiable, même si sa capacité de prévision brute est bonne.
- (c) L'arbitrage à retenir est celui du chapitre entre **expliquer** et **prévoir** : ici, l'équipe doit accepter un modèle plus simple, quitte à perdre du pouvoir prédictif brut (un R^2 interne plus faible), en échange de coefficients peu nombreux et interprétables, seuls capables de répondre à la question « pourquoi ? » posée par la direction.